学校代码：10004　　密级：公开

北京交通大學

BEIJING JIAOTONG UNIVERSITY

硕士学位论文

重载列车在长大下坡区段的运行曲线优化方法研究

作者姓名　黄宇澄

学科专业　交通信息工程及控制

指导教师　宿　帅　副教授

培养院系　电子信息工程学院

二零二一年五月

知网 https://www.cnki.net

北京交通大学

硕士学位论文

重载列车在长大下坡区段的运行曲线优化方法研究

Research on the optimization method of operating curve of heavy-haul train on the long steep downward slope sections

作者：黄宇澄

导师：宿帅

北京交通大学

2021 年 5 月

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

学校代码：10004　　密级：公开

北京交通大学

硕士学位论文

重载列车在长大下坡区段的运行曲线优化方法研究

Research on the optimization method of operating curve of heavy-haul train on the long steep downward slope sections

作者姓名：黄宇澄　　学　　号：18120221

导师姓名：宿帅　　职　　称：副教授

学位类别：工学　　学位级别：硕士

学科专业：交通信息工程及控制　　研究方向：轨道交通节能优化控制

北京交通大学

2021 年 5 月

中国知网　https://www.cnki.net

致谢

在此衷心感谢我的硕士生导师宿帅副教授。本论文是在宿帅副教授的悉心指导下完成的，宿帅副教授勤奋的工作态度、渊博的专业知识、严谨的治学精神以及对于科学问题孜孜不倦的探索都对我产生的极大的影响和帮助，使我受益终身。同时，宿帅副教授对于我的生活也给予了极大的关怀和无微不至的照顾，体现出极大的人格魅力，在此我再次对于我尊敬的导师宿帅副教授致以最诚挚的感谢。

在平时的工作和学习过程中，北京交通大学轨道交通控制与安全国家重点实验室的王悉老师、阴佳腾老师、王义惠老师等，对于我的科研工作和论文都给予了极大的指导和帮助，提出了很多宝贵的意见，在此对于各位老师致以衷心的感谢。

在学习期间，感谢刘文韬师兄，王学楷师兄在算法设计以及程序编写上给予了我大量指导意见；感谢一起在实验室朝夕相处的楼俊杰、张梓轩同学；朱擎阳师弟；程方琳、韩连鸽、曲佳师妹；作为良师益友在学习生活中给我提供了很多帮助，在此一并向他们表达我的感激之情。

最后，特别地感谢我的父亲和母亲，父亲的坚韧与勤勉指引我在硕士研究期间勇往直前，母亲的呵护与无微不至的关爱使我在挫折中重新扬起奋斗的风帆。父母的理解与包容使我能够全身心的投入到学习工作中。

中国知网 https://www.cnki.net

摘要

重载铁路具有运量大，运输效率高的特点，因此在大宗货物的运输中发挥着重要作用。随着货运量的增加，我国单列重载列车的运载量已经从一万吨增加到了两万吨，复杂运行环境条件下带有传统空气制动的长编组重载列车驾驶控制迎来了新的挑战，为进一步减少司机的劳动强度，提升重载铁路的运输能力，研究重载列车的自动驾驶控制问题就显得尤为重要。

我国重载铁路及列车运行的以下几个特点使得实现重载列车的自动驾驶十分困难。首先，重载列车编组多样、车身长，且列车使用同步操控，制动采用传统的空气制动与电制动结合的方式。其次，由于海拔落差大，我国重载铁路具有长大下坡道集中的特点，在长大下坡区段，即使列车采取最大电制动，列车也将缓慢加速运行。为提高运行效率、同时降低维护成本，重载列车通常采用循环制动方式，面向分相区、弯道等复杂条件，给驾驶策略的计算带来了挑战。

论文以朔黄铁路为研究背景，结合重载列车在长大下坡区段的运行特点及对应的约束条件，分别选择基于模型驱动（人工蜂群算法、混合整数线性规划方法）和基于数据驱动（近似动态规划算法）的方法研究重载列车在长大下坡区间的驾驶曲线优化问题。并通过仿真结果对不同算法的优化效果进行比较和分析。本文的研究工作主要有以下几个方面：

（1）分析重载列车的运行特点，考虑了重载列车的充风时间和工况转换等约束，以减小空气制动时长和提高列车运行效率为目标，构建了重载列车在长大下坡区段运行的优化控制模型。

（2）本文将既有的优化控制模型，转化为求解列车的工况转换点问题，基于启发式算法中的人工蜂群算法，设计了一种求解工况转换点的方法。在传统人工蜂群算法的基础上，本文提出了一种结合线路条件的初始解生成方法，缩小了最优解的搜索范围，提高了求解效率。

（3）本文基于数值的方法，将非线性问题线性化，使用混合整数线性规划方法进行求解，与启发式算法相比，该方法求得的结果更准确。本文针对该方法进行了仿真验证，同时对混合整数线性规划方法的有效性以及参数对优化效果的影响进行了分析。

（4） 本文使用基于数据驱动的方法，将优化问题转化为马尔科夫决策过程，结合具体的问题，对智能体（列车）在每个阶段的状态，动作和成本函数进行定义，并对每个阶段的值函数使用基函数进行近似。并使用近似动态规划方法对优化问题进行求解，验证了近似动态规划方法的有效性。

中国知网 https://www.cnki.net

关键词：重载列车；长大下坡；曲线优化；人工蜂群算法；混合整数线性规划；近似动态规划

中国知网 https://www.cnki.net

ABSTRACT

Heavy haul railway has the characteristics of large transportation capacity and high transportation efficiency, so it plays an important role in the transportation of bulk goods. With the increase of freight volume, the capacity of a heavy haul train in China has increased from 10,000 tons to 20,000 tons. The driving control of long heavy haul trains with traditional air braking systems under complex operating conditions has ushered in a new challenge. In order to further reduce the labor intensity of drivers and improve the transportation capacity of the heavy haul railways, it is particularly important to study the automatic driving control of the heavy haul trains.

The following characteristics of the heavy haul railway and train operation make it difficult to realize the automatic driving of heavy haul trains in China. First of all, the marshalling of the heavy haul train is diverse and the length is long. The trains use the synchronous control system to realize the remote control of locomotives. The braking system includes the traditional air braking system and electric braking. Secondly, there are some long downward slope sections of the heavy haul railways in China because of the large altitude difference, even if the train adopts the maximum electric braking, the speed will increase. In order to improve operation efficiency and reduce maintenance costs, heavy haul trains usually adopt a cycle braking strategy on the long downward slope sections. Considering the complex conditions such as neutral zones and curves, more challenges have been brought to the calculation of driving strategies.

Taking the Shuohuang Railway as the research background, this article studies the driving curve optimization problem of heavy haul trains on the long steep downward slope sections based on the model-driven (artificial bee colony algorithm, mixed integer linear programming method) and data-driven (approximate dynamic programming algorithm) methods with considering the operating characteristics and the corresponding constraints of heavy haul trains. The optimization effects of different algorithms are analyzed by the simulation results. The research work of this article mainly includes the following aspects:

(1) This article analyzes the operation characteristics of heavy haul trains. An optimal control model of heavy haul train on the long steep downward slope sections is constructed with considering the constraints of air-recharging time and regimes conversion with the goal of reducing air braking time and improving train operation

中国知网 https://www.cnki.net

efficiency.

(2) In this article, the existing optimization control model is transformed into the problem of solving the switching points of the train's regimes. Based on the artificial bee colony algorithm, which is one of the heuristic algorithms, an optimization method is designed to solve the driving strategy of the heavy haul train. Besides, an initial solution generation method combining the line conditions is proposed, which reduces the search range of the optimal solution and improves the efficiency.

(3) Based on the numerical method, this article linearizes the nonlinear problem and uses the mixed integer linear programming (MILP) method to solve it. Compared with the heuristic algorithm, the result obtained by MILP method is more accurate. The simulations are carried out to illustrate the effectiveness of the MILP method, and the influences of the parameters on the optimization effect are analyzed.

(4) Additionally, the driving strategy of the heavy haul trains is solved based on a data-driven method. The optimization problem is transformed into a Markov decision process. Combined with the specific optimization problem, the state, action and cost function in each stage is defined, and the value function is approximated by the basis function. The approximate dynamic programming (ADP) method is used to solve the optimization problem, and the effectiveness of the ADP method is verified based on some experimental simulations.

Key words: Heavy haul train; Long steep downward slope; Curve optimization; Artificial bee colony algorithm; Mixed integer linear programming; Approximate dynamic programming.

中国知网 https://www.cnki.net

目录

致谢 ..... **II**

摘要 ..... **III**

ABSTRACT ..... **V**

1 引言 **1**

1.1 研究背景及意义 1

1.1.1 研究背景 1

1.1.2 研究意义 5

1.2 国内外研究现状 6

1.2.1 动车组列车驾驶策略优化方法 6

1.2.2 重载列车驾驶策略优化方法 7

1.2.3 已有研究总结与发展趋势 10

1.3 本文主要框架 12

2 模型建立 **15**

2.1 优化目标 15

2.2 列车动力学模型 17

2.2.1 动力学模型 18

2.2.2 列车运行时的牵引力和制动力 18

2.2.3 列车运行阻力 21

2.3 约束条件 22

3 基于人工蜂群算法的重载列车驾驶曲线优化方法 **25**

3.1 人工蜂群算法介绍 25

3.1.1 算法原理 25

3.1.2 算法模型与实现步骤 26

3.2 算法设计 28

3.2.1 决策变量 29

3.2.2 初始解生成 29

3.2.3 约束条件处理 31

3.2.4 离散化方法 34

中国知网 https://www.cnki.net

3.2.4 算法实现 37
3.3 仿真结果与分析 38
3.3.1 仿真参数设置 38
3.3.2 按位移进行离散化 40
3.3.3 按时间进行离散化 44
3.3.4 算法参数分析 48
3.4 本章小结 52
4. 基于混合整数线性规划的重载列车驾驶曲线优化方法 53
4.1 MILP 模型与分支界定法简介 53
4.1.1 MILP 模型与应用 53
4.1.2 分支界定法 54
4.2 算法设计 55
4.2.1 决策变量与优化目标 55
4.2.2 转化规则 56
4.2.3 优化模型的转化 57
4.3 仿真结果与分析 61
4.3.1 算法有效性验证 62
4.3.2 参数分析 64
4.3.3 优化方法对比 67
4.4 本章小结 70
5. 基于近似动态规划的重载列车驾驶曲线优化方法 71
5.1 ADP 基础理论 71
5.1.1 有限 MDP 71
5.1.2 ADP 算法的基本思想 72
5.1.3 值函数的近似方法 73
5.1.4 近似迭代算法 75
5.2 基于 ADP 算法的优化问题建模 77
5.2.1 决策时刻 78
5.2.2 状态 78
5.2.3 动作 78
5.2.4 状态转移函数 79
5.2.5 代价函数 79
5.2.6 目标函数 80

中国知网 https://www.cnki.net

5.2.7 重载列车运行过程描述 80
5.3 基于 ADP 的求解方法 80
5.3.1 基函数结构选取 80
5.3.2 约束条件处理 81
5.3.3 近似值函数算法设计 83
5.4 仿真结果与分析 84
5.4.1 算法有效性验证 84
5.4.2 优化方法对比 88
5.5 本章小结 93
6 总结与展望 95
6.1 研究总结 95
6.2 论文创新点 95
6.3 展望 96
参考文献 97
作者简历及攻读硕士学位期间取得的研究成果 103
独创性声明 105
学位论文数据集 107

中国知网 https://www.cnki.net

1 引言

1.1 研究背景及意义

1.1.1 研究背景

重载铁路具有运能大、运输效率高、运输成本低等优点，是运输大宗货物最经济有效的方式之一[1]。考虑到我国煤炭运输格局呈现出“北煤南运”，“西煤东调”的特点，交通运输部等部门提出了煤炭等大宗货物运输“公路转铁路”政策，未来将会有更多的煤炭通过铁路运输到下游消费区[2]。近年来我国加大了重载铁路的建设步伐，大量开行单元及组合式重载列车，增加了煤炭外运数量，取得了显著的经济效益和社会效益[3]。但目前我国的重载铁路同美国，澳大利亚等重载铁路技术发达国家相比，依然存在着进一步提升的空间，以适应当前我国日益增长的大宗货运需求[4]。

按照国际重载协会（International Heavy Haul Association, IHHA）于 2005 年提出的关于重载铁路的规定，重载铁路需满足以下三个条件中至少两个：

（1）列车轴重不小于 27 t，

（2）列车质量不少于 8000 t，

（3）在长度超过 150 km 的线路区段上的年运量至少达到 4000 万 t。

我国的重载铁路具有以下特点：

（1）海拔落差大，长大下坡道集中

我国煤炭资源主要集中在山西，陕西和内蒙古三省（自治区），总体上分布呈现出“西多东少”的趋势。而我国耗煤量最大的地区集中在东部和东南沿海，这些地区煤炭资源贫乏，因此我国建设了大秦（大同-秦皇岛），朔黄（神池南-黄骅港）等煤运通道干线铁路，以完成 “西煤东调”的任务。以朔黄铁路为例，线路纵断面呈西高东低的走势，有 41%的线路位于山区，海拔落差大。以神池南-肃宁北区间为例，该区间的海拔落差超过了 1500 m 且长大下坡道集中，尤其是宁武西-原平南和南湾-小觉区间，基本上是 10‰-12‰的长大下坡道[5]。例如龙宫-北大牛区间，区间长度为 23592 m，平均坡度超过 10‰，最大坡度为 12‰。

（2）车辆特征复杂

首先，重载列车编组方式多样。为适应日益增长的铁路货运需求，货运列车需要扩大编组，实现重载化。针对不同类型的运输需求，我国开行了不同编组模式的

中国知网 https://www.cnki.net

重载列车，包括单元万吨列车，“1+1”组合万吨列车，“1+1”组合两万吨列车，“1+1+1+1”三万吨列车等。其中单元万吨列车与“1+1”组合万吨列车的示意图分别如图 1-1 和图 1-2 所示：

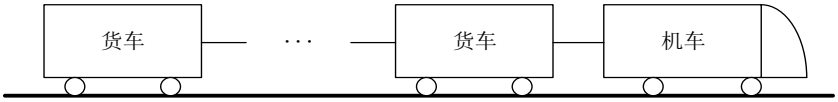


图 1-1 单元万吨列车示意图

Fig. 1-1 Schematic diagram of unit 10,000 ton trains

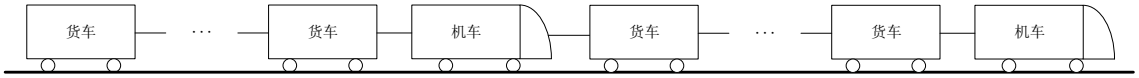


图 1-2 “1+1”组合两万吨列车编组示意图

Fig. 1-2 Schematic diagram of “1+1” 20,000 ton trains

以“1+1”组合两万吨列车为例，编组辆数为 116 辆，每节车长度为 13.7 m，加上机车长度，全列车总长可达 1600 m；组合两万吨列车的长度可达 3000 m。

其次，在车辆控制方面，针对长编组重载列车的运行控制，世界上主要有以下两种方式：LOCOTROL 机车同步操纵技术和使用电控空气制动（Electric Controlled Pneumatic, ECP）系统的列车电空制动技术[6]。LOCOTROL 系统的原理如下图 1-3 所示[7]：

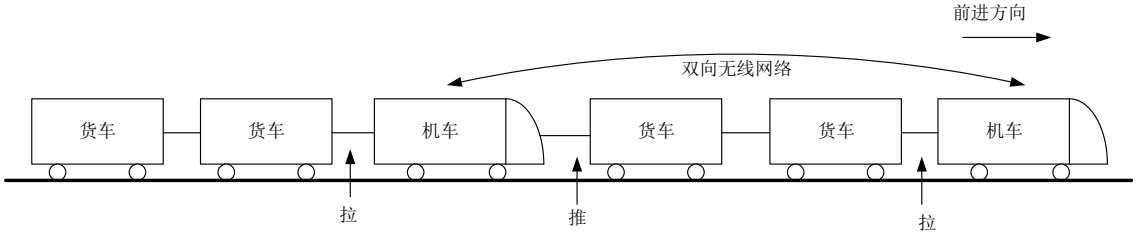


图 1-3 LOCOTROL 系统原理图

Fig. 1-3 System schematic of LOCOTROL

如图 1-3 所示，最右端的机车为主控机车，中部机车为从控机车。列车制动时，主控机车通过 LOCOTROL 系统给从控机车发送制动命令以及空气制动减压量等信息，从控机车接到信号后实施空气制动。由于列车中每台机车均为制动信号的产生源，因此在图 1-3 所示的列车中，制动波由主控机车向后，从控机车向两端传播；相对于传统机辆模式组成的列车而言，使用 LOCOTROL 系统不仅能够减少整列车建立制动的时间，还能够明显缩短每节车辆接收到空气制动的时间差，降低列车的

中国知网 https://www.cnki.net

纵向冲动。

为解决传统空气制动系统中存在的制动波速较慢以及从控机车响应时间过长的问题，ECP 系统应运而生。ECP 系统可以通过电缆以电信号的形式传递制动信号，使用微机系统直接控制副风缸的动作，实现全列车同步进行空气制动与缓解。因此 ECP 系统能够大大减少空气制动的缓解时间和响应时间，通过同步操控减小列车的纵向冲动。

与 ECP 系统相比，LOCOTROL 系统具有以下优点[8]：

1. 结构简单，因此对已有列车的制动系统的改造工作成本更低，工作量更小；
2. 车辆之间无需电缆连接，因此便于列车进行编组与解编；
3. 维护管理更简便。

考虑到以上特点，我国的重载列车使用 LOCOTROL 机车同步操纵技术。当重载列车在进行空气制动和缓解时，控制信号分别由主控机车和从控机车同时通过制动管向所有车辆传递。由于控制信号在制动管中通过空气进行传递，因此控制信号传递到所有车辆的过程需要一定时间完成。对于 120 节编组的列车，从开始进行空气制动减压到最后一辆车的制动缸升压达到最大值，大致需要 14 s 的时间；进行缓解时，从开始缓解到所有车辆的制动缸压力减小为 0 所需的时间约为 35 s[9][10][11]。

（3）驾驶控制的需求高，难度大

重载列车的驾驶控制特点可以由重载列车的牵引制动特性和驾驶控制方式两个方面描述：

1）牵引制动特性

列车的牵引力由机车上的动力装置产生，并且与列车的运动方向相同。目前朔黄铁路使用的电力机车包括 SS4B 和 HXD1 两种型号，这两种机车均通过接触网获得电能，通过机车上的驱动电机将电能转化为机械能，驱动列车向前运行。机车输出的最大牵引力与列车此时的速度相关，因此计算牵引力时需考虑列车的速度。

列车的制动力包括动力制动（或称电制动）和空气制动两种。与牵引力类似，动力制动的最大值与列车当前速度相关。动力制动用于当列车在起伏坡道运行时与牵引力配合使用，实现列车平稳操纵。此外动力制动也可用于坡度较小的下坡道控制列车速度。空气制动通过列车将副风缸中的空气送入制动缸内，进而推动闸瓦抱紧车轮，将列车动能转化为摩擦产生的热能来实现制动效果。与动力制动相比，空气制动可以提供更大的制动力。当列车运行至长大下坡道时，仅使用动力制动无法满足调速的要求，此时应使用动力制动和空气制动结合的方式调速。空气制动力主要与列车当前的减压量相关。当列车需要使用空气制动调速时，空气制动的减压量一般为 50kpa[5].

中国知网 https://www.cnki.net

2）驾驶控制方式

根据重载列车的牵引制动特性，可以得到重载列车的驾驶控制方式。目前重载列车的驾驶由司机通过操纵手柄来完成。牵引力和电制动力的输出通过控制列车手柄实现，牵引力和电制动力的输出是连续变化的。空气制动由机车上的大小闸进行控制。大闸可以对整列车进行空气制动，小闸只能对机车进行空气制动。与牵引力和动力制动力不同，空气制动力在施加空气制动后会逐渐上升至最大值，之后会保持这个最大值直到制动缓解。因此在列车起动以及在非长大下坡区段运行时，司机只需通过牵引手柄进行操纵，当列车在长大下坡区间运行以及停车时，司机需要选择合适时机施加空气制动。

根据以上重载列车的驾驶控制特点，可以总结出在确保安全的前提下提高线路的运输效率，降低运输成本，是重载列车驾驶控制的需求。重载铁路的重车方向多长大下坡道，当重载列车在这类区段上运行时，单用动力制动往往不足以控制列车速度。为了不超过规定速度，需要采取循环制动的方式进行调速[11]。从上一次的缓解到下一次的制动所经历的时间，必须满足副风缸的充风时间需求，即缓解时间，这样在下次的循环制动时能有良好的制动效果[12][13][14]。循环制动时列车速度曲线如图 1-4 所示：

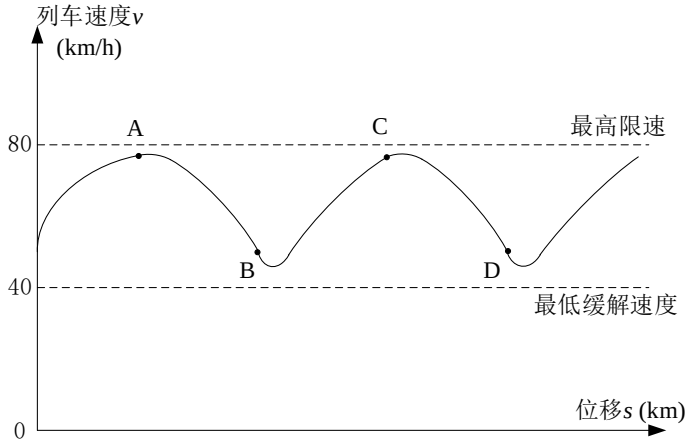


图 1-4 循环制动示意图

Fig. 1-4 Schematic diagram of cycle braking

如图 1-4 所示，A，C 分别是制动点；B，D 分别是缓解点。AB，BC 段分别表示列车制动和缓解。根据重载列车的操作规程可知，当列车进行缓解时，缓解时间不得少于 180 s[5]，在这个时间段内列车不能施加空气制动进行调速；此外缓解时列车的速度不得过低，以免低速缓解时造成车钩断裂的严重事故。列车运行时的经济效益主要通过减少能耗和减少空气制动时闸瓦与车轮踏面之间的磨损来体现，该需求可以通过利用线路坡度和列车当前速度，恰当选取操纵列车的工况来实现。

中国知网 https://www.cnki.net

因此在循环制动过程中，列车制动缓解的时机选择尤为重要，需要综合考虑缓解时间，线路坡度，列车速度等多种因素，是重载列车驾驶控制问题的关键和难点所在。选择合适的制动缓解时机，不仅能确保列车安全运行，还能提高线路的运输效率，实现一定的经济效益；若制动缓解时机选择不当，可能造成超速，车钩断裂等事故，严重影响行车安全。

以上重载列车的特点和驾驶需求给重载列车的驾驶控制带来了巨大挑战。因此需要研究重载列车的优化驾驶控制方法，以实现对列车的安全平稳控制，提高线路运输效率。

1.1.2 研究意义

研究意义主要包括以下几点：

（1）确保列车安全、高效运行

循环制动对驾驶员选择制动缓解时机提出了相当高的要求，因此要求驾驶员具有较高的操作水平。在实际驾驶过程中，驾驶员会受到劳动强度的影响，从而可能导致制动缓解时机选择不合理，进而影响列车的安全高效运行[15]。因此，使用优化算法寻找列车最佳的制动缓解时机，能够进行更为精确的操作，以免出现由于人工驾驶的操作不当导致的纵向冲动过大等问题，从而提高列车运行效率和安全性。

（2）提升线路运力，实现经济效益

铁路线路的运力指铁路基础设施或活动设备在单位时间内所能完成的最大运输量，有通过能力，输送能力等多种表现形式，因此提升线路的通过能力能实现线路运力的提升。以平行运行图为例，通过能力的计算公式为：

$$n=\frac{1440-t_1}{T}n_1 d \tag{1-1}$$

其中 n 为最大通过能力，T 为运行图周期，t_1 为固定占用时间，n_1 为一个运行图周期内的列车对数，d 为有效度系数。通过曲线优化算法减少列车的区间运行时分，可以增加一个运行图周期内的列车对数 n_1，从而实现提升线路运力的目标。

当重载列车在起伏坡道上运行时，如果能利用重力势能，在确保安全的前提下使列车以更高的速度进入上坡道区段，则列车在运行过程中所需的动能就更少，使用牵引工况的时间更少，所消耗的电能也更少。

重载列车进行空气制动时，制动缸内的空气压力通过作用于制动缸活塞，从而产生推力使活塞杆运动，这种推力再经过车辆基础制动系统的放大后作用于轮对的踏面，通过摩擦实现车辆的制动[16]。列车进行制动时，闸瓦会抱紧车轮实现制动效果，由此会带来闸瓦和车轮踏面的磨损。若能在确保安全的前提下减少空气制动

中国知网 https://www.cnki.net

的持续时间，将能够有效减少这种磨损，实现一定的经济效益。

（3）减轻司机工作强度

目前重载列车的驾驶目前还主要依靠司机来人工来完成。随着列车牵引重量的增加，列车长度的延长以及编组方式的日趋灵活，使得对于重载列车司机的驾驶水平要求越来越高，司机只有经过系统的培训并通过长时间的实际操作才能熟练掌握驾驶技能。而朔黄重载铁路线路较长，且一般只在固定的技术站（肃宁北站）进行换班作业，司机的工作强度很大。即使优秀司机也受身体状况和外部环境等影响，而导致失误率升高。目前我国的重载列车司机的工作时间长，工作强度大。研究重载列车的优化驾驶方法，可以有效降低司机的工作强度，同时可以为重载列车ATO 的设计提供技术支持。

1.2 国内外研究现状

1.2.1 动车组列车驾驶策略优化方法

针对列车的驾驶策略优化问题，国内外学者最早将运行能耗视为优化目标，求解在特定条件下的列车节能驾驶策略。Ishikawa 提出列车节能驾驶曲线包括四种工况，分别是最大牵引、巡航、惰行和最大制动[17]。接下来 Howlett 等对列车驾驶控制过程进行分析，使用极大值原理求解列车的最优工况转换点，之后结合列车工况和工况序列获得列车的节能驾驶策略，进而得到列车节能驾驶曲线[18][19][20][21][22]。以上研究中对列车运行过程中的约束条件考虑较少，因此后续对列车节能驾驶曲线的研究中逐渐增加了各项约束条件。例如 Liu 等考虑了列车的牵引制动特性，区间限速等约束条件，使用数值方法求解列车在区间的最优驾驶策略[23]。

在求解动车组列车运行的优化问题时，一种较为常见的方法是混合整数线性规划 （Mixed Integer Linear Programming, MILP）方法。Tan，Wang 等以单列车在区间内的运行能耗为优化目标，首先将运行区段进行离散化，等分为 N 个小段，将非线性的约束条件使用分段线性（Piecewise Linear, PWL）方法转化为分段线性的约束条件，求出每个离散区间内的能耗并进行优化[24][25][26]。Jin 等除了考虑以单列车在区间内的运行能耗外，在优化目标中增加时间误差，将 MILP 方法与状态空间提升策略相结合。仿真结果表明，使用状态空间提升策略能有效减少计算时间[27]。

启发式算法广泛应用于求解列车驾驶策略优化问题。Chang 等将列车运行时的能耗和准点性，以及旅客舒适度视为优化目标，构建多目标优化问题并使用遗传算法求解[28]。Ke 等首先对运行区间进行分段，通过改进后的蚁群算法求解每个区间

中国知网 https://www.cnki.net

的平均速度，进而得到最优控制问题的解，仿真结果证明与遗传算法相比，改进后的蚁群算法计算速度更快[29][30]。同样对区间进行离散化，金炜东等使用神经元网络得到不同类型区间上能耗和运行时分的关系，之后使用遗传算法对运行时分进行分配以获得最小能耗[31]。马超云等将实际能耗和目标能耗，以及实际运行时分和目标运行时分的偏差视为优化目标，将遗传算法中的编码设置为实数，求解列车优化速度曲线[32]。付印平等以能耗为优化目标，将传统的遗传算法中的染色体长度改为可变长度，之后对优化问题进行求解[33]。熊超彬使用萤火虫算法对两段实际线路进行仿真研究，仿真结果表明节能效果可以分别达到 11.21%和 14.01%[34]。李烨等结合列车在区间内的限速，运行时分等约束条件，使用粒子群算法进行优化。仿真结果证明，粒子群算法计算得到的结果与改进后的遗传退火算法进行对比能够节能 4.61%[35]。段玉琼等结合区间内的限速和运行时分这两个约束条件，使用人工蜂群算法分别在节时和节能两种不同的运行模式下进行仿真。仿真结果证明，采用节能模式优化后的能耗比节时模式减少了 14.22%[36]。He 等将粒子群算法与遗传算法相结合，设计了一种使用实数编码的组合算法。仿真结果证明，与常规控制策略相比，该组合算法可以节能 6.76%[37]。针对遗传算法中易陷入局部最优解的问题，He 等设计了一种黄金分割遗传算法，使用北京亦庄线的数据进行仿真研究，证明该算法比遗传算法具有更好的优化性能[38]；杨杰等提出了一种启发式遗传算法，通过仿真结果证明了该算法比遗传算法具有更高的鲁棒性和计算速度[39]。

近年来不少学者使用人工智能相关理论与方法研究列车优化问题。Chen 等基于分类回归树（Classification And Regression Tree, CART）算法，设计了一种用于高速列车多目标优化问题的智能驾驶方法，并使用京沪高铁实际数据进行仿真，证明了算法的有效性[40]。张淼等以列车的牵引能耗和准时性为目标，设计了一种基于 Q 学习的节能优化策略，仿真结果证明该策略能有效减少站间运行能耗[41]。Yin 等分别结合专家系统和强化学习设计对应的列车智能控制算法，通过与实际驾驶数据对比，两种列车智能控制算法均能够降低列车的运行能耗[42]。针对地铁列车的运行场景，张淼等结合现有的驾驶技术和优秀司机经验，设计了一种基于策略梯度的强化学习算法，与现有的 ATO 算法相比，该算法可节能 6.85%[43]。阴佳腾基于近似动态规划，设计了一种城轨列车一体化优化方法，以降低运行中延误现象对乘客和运营商的影响[44]。王鹏以牵引能耗、速度跟踪性能、安全性、准时性和平稳性为优化目标，提出基于多目标约束的自动驾驶控制算法。通过极大值原理求解最优解，进而设计列车自动驾驶 ATO 控制策略。通过仿真验证了该算法具有较高的全局适应度，控制效果良好[45]。

1.2.2 重载列车驾驶策略优化方法

中国知网 https://www.cnki.net

与动车组列车相比，重载列车长度更长，约束条件更多，运行场景更复杂。因此以上针对动车组列车的优化方法不可直接应用于重载列车的优化，应选用其他方法或针对原方法进行对应的改进。

国内外最早对重载列车的优化运行研究以 Howlett 等为代表。Howlett 等针对重载货运列车的驾驶控制特点，使用离散化模型描述重载列车的优化问题[46][47]。Howlett 根据已有工况，使用 KT 条件对工况转换点进行求解，并指出了连续工况序列的离散化逼近方法[48]。

根据重载列车的特点构建多质点模型，并使用最优控制理论针对列车运行时的不同参数进行优化，学者 Zhuan，Xia，Chou 等已有大量研究。Chou 等明确指出，在设计重载列车的优化运行控制器时，有 3 个指标需要考虑，分别是：速度跟踪，列车内力和能耗。基于南非的 COALink 线路上的重载列车，使用了线性二次调节控制器，将这 3 个要素全部视为需调节的变量，对列车的在实际线路上的运行进行仿真研究[49]。Chou 等分别对列车的牵引力，车钩力和电控空气（electric controlled pneumatic, ECP）制动系统构建模型，与已有的列车多质点动力学模型相结合，通过仿真软件将仿真结果与实际线路的运行数据做对比，证明了模型的鲁棒性[50]。Zhuan 以列车的速度跟踪能力和车钩力为优化目标，提出了车钩力的计算方式。分别设计了输出反馈调节控制器和容错控制器，通过仿真结果验证了所设计控制器的有效性和可行性[51]。Zhuan 等将速度跟踪性能视为优化目标，尽可能减少实际速度与目标速度之间的偏差。基于列车的多质点模型，文中提出了 3 种不同的控制策略，分别是：所有机车和车辆使用同一牵引或制动控制信号；机车使用的控制信号相互独立，车辆使用相同的制动控制信号；所有机车和车辆使用的控制信号均相互独立。仿真结果证明，第 3 种策略得到的控制效果最好[52]。Zhuan 等以速度传感器误差为优化目标，提出了一种利用容错控制跟踪已有速度曲线的算法，通过仿真结果证明了所设计的控制器在存在误差时，能有效提高控制性能[53]。Zhang 等以重载列车运行能耗，速度跟踪性能和车钩力为优化目标，分别分析了制动力和钩缓装置振动的产生机理并构建数学模型，将制动力和钩缓装置的振动整合为惩罚函数，使用模型预测控制对优化问题进行求解。通过仿真结果验证了所用方法的有效性[54]。

以上方法虽然都取得了良好的控制效果，但研究的对象都是装备了 ECP 制动系统的重载列车，ECP 制动系统能够提供几乎实时的制动命令，实现全列车同步制动、缓解和再制动。与 ECP 技术相比，Locotrol 系统采用的是无线同步控制方式，具有结构简单，成本较低，利于解编，方便维护等特点，因此为我国的重载铁路所采用。采用 Locotrol 系统开行重载列车面临的其中两大关键技术难题分别是周期循环制动和列车纵向冲动[8]。针对这个问题，国内外学者采用各种方法做了大

中国知网 https://www.cnki.net

量研究。

针对我国重载列车的空气制动系统进行建模，并对制动系统进行研究，是其中一个研究方向。Wei 等使用流体力学方程，详细分析了空气制动过程中制动系统各主要部分的工作情况，对空气制动系统进行建模。通过仿真结果与实际数据的对比证实了所构建模型的有效性[55]。Wu 以列车的运行能耗为优化目标，将纵向动力学特性分为钩缓装置特性和空气制动特性分别进行研究，对列车的钩缓装置和空气制动系统进行建模，将所得到的模型通过仿真软件 TDEAS 进行计算，得到列车的运行曲线和能耗[56]。Gao 针对不同的列车编组，考虑紧急制动时制动波在整列车中的传递情况，结合已构建的钩缓装置和制动装置的数学模型，对于不同的制动初速度分别计算出了最大车钩力的变化情况[57]。

部分学者通过设计控制器，构建优化控制算法，结合我国重载铁路和重载列车的特性进行研究。Gao 等针对输入量的限制和通信延迟问题，设计了一种分散协同控制器，并证明了这种闭环控制器的稳定性。通过基于大秦线数据的仿真结果表明，所设计的控制器具备有效性和鲁棒性[58]。孙俊勇等以安全、平稳、准点、节能作为优化目标，使用粒子群算法生成一条满足需求的最优目标曲线，然后使用模糊 PID 控制算法设计控制器，使列车跟踪目标曲线运行。仿真结果证明所设计的模糊 PID 控制器具有良好的速度跟踪效果[59]。赵巧妮将模糊自适应 PID 控制器与车钩力查表模型相结合，通过仿真结果证明了该方法可以控制列车安全运行[60]。陆小红等以运行时分和能耗为优化目标，综合考虑列车牵引/再生系统特性和空气制动特性，采用模糊预测控制智能算法生成控车指令。现场综合实验的结果表明，控制算法计算得到的运行时间偏差小于 5%，节能效果大于 7%，满足实际需求[61]。

在动车组列车优化问题中应用较多的启发式算法也可用于求解重载列车的优化运行问题。Yu 等以列车区间运行时分为优化目标，在模型中考虑了列车的长度、充风时间、区间限速等约束条件，使用粒子群算法对该优化问题进行求解，通过对朔黄线龙宫-宁武西区间进行仿真研究，证明了算法的可行性[62]。Huang 等将运行时分作为优化目标，将列车的工况转换点视为决策变量，使用改进后的遗传算法进行求解，仿真结果证明改进后的遗传算法能以较快的速度搜索到满足约束条件的最优解[63]。付雅婷等以实现重载列车安全、正点、节能运行为目标，研究其驾驶过程。文中基于钩缓系统的特性曲线，建立重载列车钩缓系统模型及整车纵向动力学模型，运用多目标自适应遗传算法设定列车理想的目标速度曲线并设计重载列车速度跟踪控制器。基于实际线路的仿真结果表明了控制器能够跟踪已有的速度曲线[64]。王新培综合考虑了安全、节能、准点、平稳性和停车精度 5 个方面，建立了多目标评价函数。对于列车在长大下坡道上运行的场景，提出了一种改进算法，以满足充风时间的要求。通过对大秦线湖东-茶坞区间进行仿真研究，证明了所提出

中国知网 https://www.cnki.net

算法的可行性[65]。李玉生等根据重载列车驾驶控制的特点，使用不同位置列车手柄级位描述列车运行过程，提出了重载列车在坡道上运行时手柄级位的改变规则[66]。

使用人工智能相关算法研究重载列车的曲线优化问题，是目前的发展趋势。Wang 等以列车之间的车钩力为优化目标，结合列车的多质点模型，构建了多级随机动态规划模型。使用近似动态规划（Approximate Dynamic Programming，ADP）的方法对重载列车在线路上的运行进行仿真研究，并与 Q-learning 算法进行对比。仿真结果表明，使用 ADP 算法能够得到更优的结果[67]。Wang 等以最小化运行中的车钩力为目标，根据列车多质点模型，使用带有界查找表的 Q-learning 算法求出了列车在坡度为 12‰，长度为 10km 的长大下坡道上的运行曲线[68]。Huang 等以生成列车在长大下坡道上的运行曲线为目标，结合区间的线路条件构建列车的运动学模型。先根据列车制动的非线性特性构建 BP 神经网络，通过对制动过程建模来达到列车制动减压量和缓解时间的目标值。之后利用已有的驾驶数据对已构建的神经网络进行训练，在仿真案例中使用朔黄线数据对已训练的神经网络进行验证。仿真结果表明，在 4 种不同的运行环境下，均能够满足运行需求[69]。Bai 等以重载列车的停车精度为优化目标，使用模糊神经网络对列车制动系统工况进行建模，从而计算出在预定制动率下列车的制动距离，制动初速度等参数。仿真结果表明，使用模糊神经网络计算得到的结果与目前驾驶员采用的驾驶策略相比，不仅保证了停车精度，而且时间减少了 18.6%，运行能耗减少了 2.4%[70]。Zhang 等针对优化运行中的速度防护问题，使用最小二乘支持向量机建立列车的制动模型，提出了一种基于预测控制的速度防护方法，并通过 MATLAB 软件验证了方法的有效性[71]。Wang 等针对最小化车钩力的问题，通过构建列车运动学模型，将优化问题转化为求解施加空气制动的位置。文中将空气制动的施加问题视为一个多级分类模型，使用 EMKD（Easy Ensemble for the Multi-Class with a KNN Based Denoising）算法确定列车在施加空气制动时的减压量，根据减压量可以计算出列车的制动力，进而得到速度曲线[72]。Tang 等针对重载列车在起伏坡道上的运行场景，以列车运行时的车钩力和能耗作为优化目标，使用 Double Switch Q-network（DSQ）求解列车在区间内的驾驶策略，并将仿真结果与 Q-learning 算法进行对比。仿真结果证明，DSQ 比 Q-learning 的收敛速度更快，且所需的存储空间更少[73]。

1.2.3 已有研究总结与发展趋势

表 1-1 总结了部分针对列车运行优化的研究文献。

中国知网 https://www.cnki.net

由表 1-1 可知，与针对动车组列车的优化运行方法相比，针对重载列车的优化运行方法在算法选择和优化目标上均有共同之处，因此在研究重载列车的优化运行问题时，可以选用在动车组优化问题中行之有效的算法。

表 1-1 列车运行优化文献汇总

Table 1-1 Summary of literature on train operation optimization

文献	列车类型	优化算法	优化目标
[18]-[22]	货运列车	极大值原理	能耗
[24]-[26]	动车组列车	MILP	能耗
[27]	动车组列车	MILP	能耗，运行时分误差
[32]-[34]	动车组列车	遗传算法	能耗
[41]	动车组列车	Q-learning	能耗
[42]	动车组列车	ADP	运行时分误差
[49]	重载列车	最优控制理论	车钩力
[54]	重载列车	模型预测控制	车钩力，速度跟踪性能
[59]	重载列车	粒子群算法+模糊 PID 控制	平稳性、准点性、能耗
[60]	重载列车	自适应 PID 控制	车钩力
[61]	重载列车	模糊预测控制	能耗，运行时分
[62]	重载列车	粒子群算法	区间运行时分
[63]	重载列车	遗传算法	区间运行时分
[64]	重载列车	自适应遗传算法	区间运行时分，能耗
[65]	重载列车	多目标优化	能耗、运行时分、平稳性、停车精度
[67]	重载列车	ADP	车钩力
[68]	重载列车	Q-Learning	车钩力
[69]	重载列车	BP 神经网络	停车精度
[70]	重载列车	模糊神经网络	运行时分，能耗
[72]	重载列车	EMKD	车钩力
[73]	重载列车	DSQ	车钩力，能耗

极大值原理是基于模型求解优化问题的经典解析方法。本文研究的优化问题中涉及到多种类型的约束条件，难以转化为使用极大值原理求解优化问题时对应

中国知网 https://www.cnki.net

的不等式约束的形式，因此本文另外选用人工蜂群算法和混合整数线性规划方法进行求解。人工蜂群算法通用性强，求解速度较快；混合整数线性规划方法虽然求解速度较慢，但计算精度更高。

随着人工智能技术的发展，越来越多的学者使用人工智能的相关算法，基于已有数据研究列车驾驶策略优化问题。因此本文选择一种基于数据的优化方法——近似动态规划算法，对列车驾驶策略优化问题进行研究。

1.3 本文主要框架

本文考虑了重载列车进行空气制动时的缓解时间，构建重载列车动力学模型，和运行时分计算模型，使用人工蜂群算法，混合整数线性规划方法和近似动态规划算法对模型进行求解并对结果进行分析比较。人工蜂群算法用于在较短时间内搜索到近似的最优解，混合整数线性规划方法能够搜索到更准确的最优解，而近似动态规划方法则是基于数据进行优化，具有实时性。本文运用朔黄线含有长大下坡道的区段进行仿真，通过实际线路数据验证优化方法的可行性，针对重载列车在长大下坡区段运行的关键技术难题展开研究。本文的技术路线图如图 1-5 所示。

第一章 引言。这一章首先介绍论文的研究背景和意义，分别总结目前国内外针对动车组列车和重载列车曲线优化问题的研究现状，并且对论文的研究内容进行框架式说明。

第二章 模型建立。这一章对重载列车在长大下坡道上的运行场景进行建模，包括列车的动力学模型，优化目标以及列车运行时需满足的约束条件，同时指出了优化问题中的难点。

第三章 基于人工蜂群算法的重载列车驾驶曲线优化方法。本章首先介绍了人工蜂群算法的原理及流程。考虑到重载列车的驾驶特点，本章提出了一种初始解的生成方法，以提高算法的搜索效率。对于列车运行时需满足的各项约束条件，本章提出了罚函数方法，将约束条件用罚函数进行表示并整合到优化问题中，进而求出满足约束条件的解。

第四章 基于混合整数线性规划方法的重载列车曲线优化方法。根据混合整数线性规划方法的适用范围，首先应对列车运行区间进行离散化处理，之后本章提出了针对非线性条件的线性化转化方法。当所有条件均被线性化之后，调用相关求解器进行求解。

第五章 基于近似动态规划的重载列车驾驶曲线优化方法。本章使用近似动态规划算法求解列车运行时在每个决策时刻所应选择的工况。在对近似动态规划算法的有效性进行验证后，分别将算法与人工蜂群算法和混合整数线性规划方法进

中国知网 https://www.cnki.net

行比较，对不同算法的优化效果进行分析。

第六章 总结与展望。总结本文所完成的工作，之后对下一步研究方向进行展望。

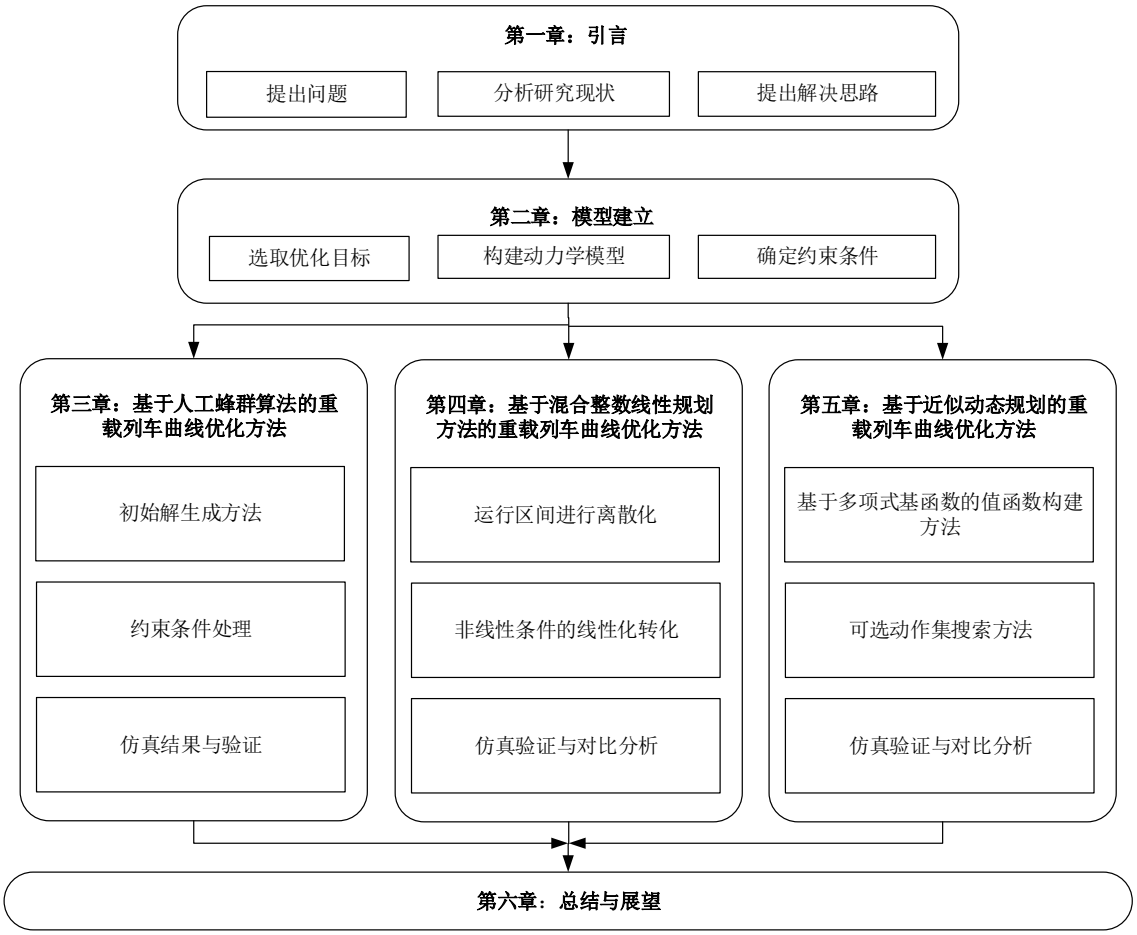


图 1-5 本文技术路线

Fig. 1-5 Technical route of this article

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

2 模型建立

本章首先结合重载列车驾驶控制的实际需求，给出重载列车曲线优化问题中应考虑的优化目标；之后根据列车的牵引制动特性曲线以及列车空气制动系统的特征，结合牛顿动力学公式构建列车的动力学模型，以描述列车在区间内的运行情况；接下来根据实际运行场景和重载列车的相关操作规程，列举出优化问题中应考虑的约束条件。

2.1 优化目标

重载列车的驾驶过程，大致可以分为启动，区间运行和停车三个部分，每部分的操纵特点分别如下所示：

（1）启动：重载列车在启动过程中，机车乘务员先施加一定的牵引力，待整列车开始启动后再逐渐增大牵引力，以免出现空转现象。

（2）区间运行：当重载列车在坡度较缓的区段运行时，机车乘务员只需通过牵引力和电制动力，即可实现对列车的控制。当重载列车运行在长大下坡区段时，列车在制动过程中所需的制动力主要由空气制动系统提供，空气制动系统通过闸瓦与车轮之间的摩擦，将列车动能转化为内能，使列车速度下降。由于我国的重载列车均未装备 ECP 系统，因此制动过程完成后，需要一定时间使制动缸中的气压恢复。当制动缸中的气压恢复至制动前的值后方可进行下一次空气制动。

（3）停车：在停车过程中，先施加电制动力，待列车速度降低至一定值时施加空气制动力，直至整列车完全停稳。

为实现提升线路运力的目标，针对重载列车的在长大下坡区段的驾驶过程，可以总结出减少空气制动和提高运行效率两类优化目标：

（1）减少空气制动：当列车在长大下坡区段运行时，必须使用空气制动调速，因此空气制动时闸瓦与车轮踏面之间的磨损不可避免。由于目前我国的货运列车朝着“重载化”的方向发展，因此闸瓦磨损的问题日益突出[74]。为此，本研究中将减少空气制动作为优化目标之一，在确保安全运行的前提下尽可能减少空气制动的距离或者时间，从而实现减少闸瓦磨损的目的。列车进行空气制动的距离可以表示为：

$$L_{\mathrm{p}}=\int_{0}^{L} k\mathrm{d}l \tag{2-1}$$

其中 k 为与空气制动力大小相关的二值变量，取值情况如下：

中国知网 https://www.cnki.net

$$k=\begin{cases}0 & f_{\text{aero}}=0\\ 1 & f_{\text{aero}}>0\end{cases} \tag{2-2}$$

列车进行空气制动的时间 T_{p} 可以表示为：

$$T_{\text{p}}=\int_0^T k\mathrm{d}t \tag{2-3}$$

其中 k 与（2-1）中 k 的含义相同。

（2）提高运行效率：运行效率可以通过一定时间内的位移，或通过一段区间内的区间运行时分来表示。在不改变线路基础设施的前提下，通过对列车运行曲线进行优化，能够有效提高线路的通过能力。列车的在长度为 L 的区间内的运行时分 T 可以表示为：

$$T=\int_0^L \frac{\mathrm{d}l}{v} \tag{2-4}$$

列车在时间 T 内的位移 L_{dis} 可以表示为：

$$L_{\text{dis}}=\int_0^T v\mathrm{d}t \tag{2-5}$$

结合（1）和（2）可知，重载列车在长大下坡区段的优化问题是一个典型的多目标优化问题。针对多目标优化问题的求解，主要有线性加权法，主要目标法，理想点法等。各种求解方法的特点及主要步骤见表 2-1 所示。

在求解列车优化运行问题时，对于不同的优化目标应综合考虑，不可过度偏重于某项指标[75]，因此在选取求解方法时，首先将主要目标法舍弃。本文中的优化目标具有不同的量纲，因此在构造目标函数时应设法消除不同量纲带来的影响。根据表 2-1，理想点法和功效系数法均能够消除不同量纲带来的影响。因此本文结合理想点法和功效系数法中对不同量纲处理的思路，对优化目标进行归一化，之后使用线性加权法构造目标函数。根据式（2-1）-（2-5），当选择空气制动距离和运行时间作为优化目标时，该优化问题可以转化为最小化目标函数 f_{obj1}，目标函数 f_{obj1} 可以写为：

$$f_{\text{obj1}}=\lambda_1\frac{T}{T_{\text{o1}}}+\lambda_2\frac{L_{\text{p}}}{L} \tag{2-6}$$

其中 L 为区间长度，用于对空气制动距离进行归一化。T_{o1} 用于对列车运行时分进行归一化，由区间长度 L 和最低缓解速度 v_{rmin} 计算，即 $T_{\text{o1}}=L/v_{\text{min}}$，表示列车在该区间运行时理论上所需的最长时间。

中国知网 https://www.cnki.net

表 2-1 求解多目标优化问题方法的步骤及特点

Table 2-1 Process and features of different methods for solving multi-objective optimization problem

求解方法	主要步骤	特点
线性加权法	按各项优化目标的重要程度赋予不同的权重，转化为单目标优化问题	目标函数易构建，但权重需要合理选择，此外优化目标量纲不同时需要另外处理
主要目标法	选择一项优化目标作为主要目标，其余优化目标作为约束条件，转化为单目标优化问题	主要目标函数对结果影响很大，因此必须合理选择主要目标函数
理想点法	找出每项优化目标各自的最优解，构造各优化目标与对应最优解的距离，转化为单目标优化问题	能对每项优化目标都求得最优值，但需要先求出各目标的最优解
功效系数法	对每个评价指标确定上下限，根据上下限计算功效系数，之后通过将每个评价指标的功效系数的几何平均值定义为指标函数，从而转化为单目标优化问题	需要求出每个优化目标的上下限，算法实现较为复杂，但可以消除不同量纲的影响

若将空气制动时间和运行距离作为优化目标，考虑到优化问题中需要最大化运行距离，因此在构建目标函数之前，应根据对偶原理进行如下改动：

$$Max\ \ L_{\mathrm{dis}} \Leftrightarrow\ Min\ \ -L_{\mathrm{dis}}$$

则对应的目标函数 f_{obj2} 应写为：

$$f_{\mathrm{obj2}}=\lambda_1 \frac{T_{\mathrm{p}}}{T_{\mathrm{p1}}}-\lambda_2 \frac{L_{\mathrm{dis}}}{L_{\max}} \tag{2-7}$$

其中 $L_{\max}$ 表示列车在该区间理论上所能达到的最大运行距离，由最高限速 $v_{\max}$ 和区间运行时分 T 确定，即 $L_{\max}=v_{\max}T$。T_{p1} 用于对空气制动时间进行归一化，在实际计算中，取 $T_{\mathrm{p1}}=T/2$。

公式（2-6）-（2-7）中的 λ_1、λ_2 为权重，表示不同优化目标的重要性。一般情况下，λ_1、λ_2 取值范围是[0, 1]，且 $\lambda_1+\lambda_2=1$。

2.2 列车动力学模型

中国知网 https://www.cnki.net

2.2.1 动力学模型

列车动力学模型可以由图 2-1 描述：

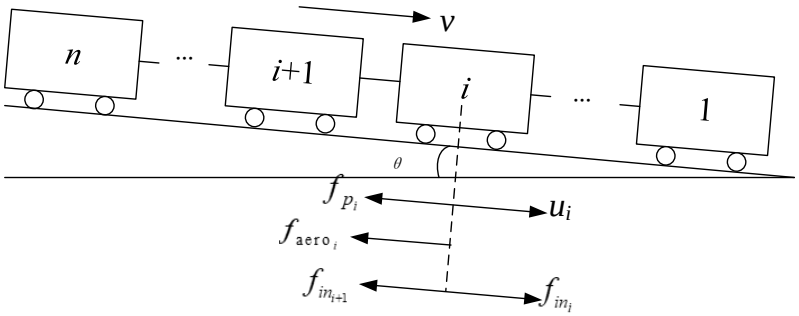


图 2-1 列车动力学模型

Fig. 2-1 Dynamic model of the train

图 2-1 中，$f_{in_{i+1}}$和f_{in_i}分别表示第 i+1 节车和第 i-1 节车通过钩缓装置施加给第 i 节车的车钩力。其中$f_{in_{i+1}}$与列车的运动方向相反，f_{in_i}与运动方向相同。考虑到列车的牵引力和电制动力均由同一个手柄控制，空气制动力由另一个手柄控制，因此使用 u_i 表示列车第 i 节车所受到的牵引力和电制动力。f_{aero_i}表示列车第 i 节车所受到的空气制动力。f_{p_i}定义为第 i 节车受到的阻力之和，由下面的等式定义：

$$f_{p_i}=f_{r_i}+f_{c_i}+f_{g_i} \tag{2-8}$$

其中f_{c_i}，f_{r_i}和f_{g_i}分别表示第 i 节车所受到的曲线阻力，基本阻力和坡道阻力。

根据牛顿运动定律，列车的动力学方程为：

$$m_i\dot{v}=u_i+f_{\text{aero}_i}+f_{p_i}-f_{in_{i+1}}+f_{in_i} \tag{2-9}$$

2.2.2 列车运行时的牵引力和制动力

列车运行时的牵引力由机车提供，机车通过受电弓从接触网中获取电能，之后通过电动机将电能转化为机械能并驱动列车前进。机车能提供的最大牵引力与机车当前速度相关，不同种类的机车有不同的牵引特性曲线。下面分别给出了如图 2-3 和图 2-4 所示的 SS4B 型电力机车的牵引制动特性曲线[76]：

中国知网 https://www.cnki.net

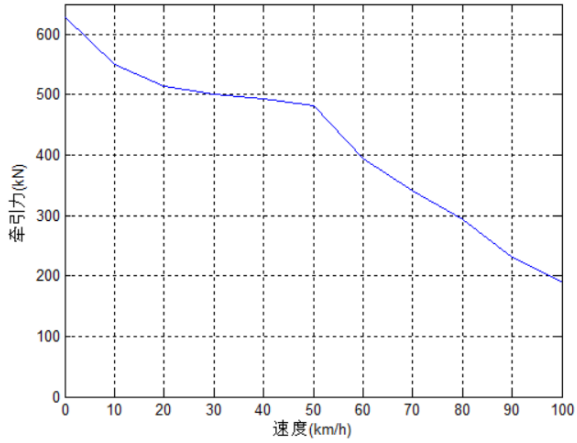


图 2-2 SS4B 型电力机车的牵引特性曲线

Fig. 2-2 Traction characteristic curve of SS4B electric locomotive

图 2-2 中，当列车速度为 0-50km/h 时，机车的牵引力受到粘着力的限制，速度范围在 50-80km/h 时为恒功区。

列车的制动力分为电制动力和空气制动力。其中电制动力由机车提供，与列车当前速度相关。列车的最大电制动力可根据对应型号机车的制动特性曲线进行计算。如图 2-3 所示为 SS4B 型电力机车的制动特性曲线：

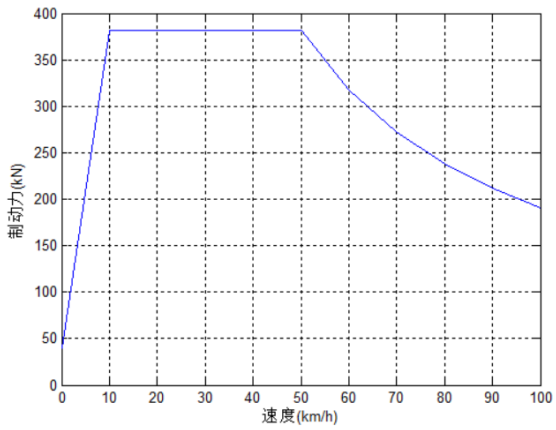


图 2-3 SS4B 型电力机车的制动特性曲线

Fig. 2-3 Braking characteristic curve of SS4B electric locomotive

SS4B 型机车进行电制动的过程中使用准恒速或限制曲线的运行方式，使得机车具有准恒速与最大制动力的特性[8]。当列车速度处于 0-10 km/h 时，制动力与速度的关系呈线性，最小制动力为 27 kN。当列车速度处于 10-50 km/h 时，列车制动力恒为最大值 382 kN，列车速度为 50-80km/h 时，该区段为恒功区，机车电制动力与列车速度成反比，列车速度大于 80 km/h 时进入高速换向限制区。

中国知网 https://www.cnki.net

设列车的最大牵引力和最大电制动力分别为 u_{maxt}，u_{maxb}，则根据图 2-3 和图 2-4，可分别将其视为与列车速度 v 相关的函数 f_1，f_2：

$$u_{maxt}=f_1(v) \tag{2-10}$$

$$u_{maxb}=f_2(v) \tag{2-11}$$

列车空气制动系统的结构如图 2-4 所示[77]：

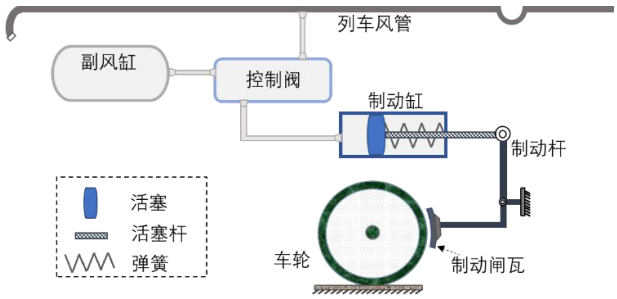


图 2-4 空气制动系统结构

Fig. 2-4 The structure of air braking system

列车的空气制动特性主要包括：列车管压力及各节车制动缸压力值随时间的变化。根据图 2-4 可知列车进行空气制动的基本过程如下：当列车管中的压力减小时，副风缸中的空气通过制动阀进入制动缸中，副风缸中的空气随后压缩制动缸的弹簧，推动闸瓦压紧车轮踏面，当车轮踏面与闸瓦之间产生摩擦时，机车的动能通过摩擦转变为热能消散于大气中，从而产生制动效果使车辆减速[78]。根据空气制动的建立过程可知，从列车产生制动信号到实际产生制动效果，会有一定的延迟时间 t_b。

当制动缸的压力已知时，列车的空气制动力（单位：kN）为[79]：

$$F_i^B=\sum_{n_z} K_i\varphi_i^K \tag{2-12}$$

其中 K_i 为单块闸瓦产生的压力，单位为 kN；φ为对应车辆车轮与闸瓦的摩擦系数，n_k为闸瓦的数目。车轮与闸瓦摩擦系数φ_i^K可以通过查询得到[79]。以 C80 货车为例，摩擦系数φ_i^K的计算公式如下：

$$\varphi_i^K=0.41\cdot\frac{K_i+150}{4K_i+200}\cdot\frac{v_i+150}{2v_i+150} \tag{2-13}$$

公式（2-13）中，v_i 为当前列车的速度。单块闸瓦产生的压力 K_i 可以使用下面的公式计算[79]：

$$K_i=\frac{\pi}{4}d^2P_i^B(t)n_b\eta_z\gamma_z\cdot10^{-6}/n_z \tag{2-14}$$

中国知网 https://www.cnki.net

其中，η_z为基础制动装置的传动效率；n_b为制动缸数；d为制动缸直径（单位：mm）；γ_z为制动倍率。$P_i^B(t)$应根据空气制动的建立和缓解分别进行计算，其计算方法如下所示：

1）空气制动建立过程：

$$P_i^B(t)=\begin{cases}0, & t\le t_i^{delay_1}\\ \left(\dfrac{t-t_i^{delay_1}}{t_{\max_1}}\right)^{\lambda_{P1}}\cdot P_{\max} & t_i^{delay_1}\le t\le t_i^{delay_1}+t_{\max_1}\\ P_{\max} & t\ge t_i^{delay_1}+t_{\max_1}\end{cases} \tag{2-15}$$

2）缓解建立过程：

$$P_i^B(t)=\begin{cases}P_{\max}, & t\le t_i^{delay_2}\\ \left(1-\dfrac{t-t_i^{delay_2}}{t_{\max_2}}\right)^{\lambda_{P2}}\cdot P_{\max} & t_i^{delay_2}\le t\le t_i^{delay_2}+t_{\max_2}\\ 0 & t\ge t_i^{delay_2}+t_{\max_2}\end{cases} \tag{2-16}$$

其中$P_{\max}$为制动缸最大压强；λ_{p1}、λ_{p2}是与制动阀特性相关的常数；t_{max1}、t_{max2}分别是制动缸压强从0到最大值，和制动缸压强从最大值到0的时间；$t_i^{delay_1}$和$t_i^{delay_2}$分别是进行空气制动和缓解的延迟时间，与制动波和缓解波的波速，车辆位置，车厢长度有关。计算公式如下：

$$t_i^{delay_1}=\frac{L}{v_a} \tag{2-17}$$

$$t_i^{delay_2}=\frac{L}{v_r} \tag{2-18}$$

其中L为该车辆中心点与机车中心点的距离，以机车型号为SS4B，车辆型号为C80的重载列车为例，相邻车辆的中心点距离为12.5 m，机车与车辆之间的中心点距离为24 m。v_a，v_r分别是制动波和缓解波的波速，制动波速v_a=220 m/s，缓解波速v_r=180 m/s。

2.2.3 列车运行阻力

列车运行阻力包括基本阻力和附加阻力，附加阻力又包括坡道附加阻力和曲线附加阻力等。

在实际计算过程中，基本阻力按以下公式计算：

$$f_r=m(c_0+c_1v+c_2v^2) \tag{2-19}$$

中国知网 https://www.cnki.net

其中 c_0，c_1 和 c_2 均为戴维斯系数，v 为列车当前速度。

列车运行时受到的坡道附加阻力 f_g 的计算公式为：

$$f_g=mg\sin\theta \tag{2-20}$$

当 θ 值很小时，可以做以下近似处理：

$$\sin\theta=\theta \tag{2-21}$$

在实际的线路的坡度一般用千分数表示。以朔黄铁路为例，全线最大坡度为12‰。结合（2-20）和（2-21），设 i 为对应线路的坡度，则列车的坡道阻力计算公式可以简化为：

$$f_g=mgi \tag{2-22}$$

在计算过程中考虑到列车的长度时，可能出现列车的不同部分位于不同坡度的坡道上。为了在确保计算精度的同时简化运算，可以使用等效坡度法进行处理[80]：假设列车长度为 l，列车当前的位移为 s，则此时整列车对应的等效坡度 $G(s)$ 可按以下公式计算：

$$G(s)=\begin{cases}\dfrac{\sum_{i=1}^{s}g_i}{s} & s<l\\ \dfrac{\sum_{i=s-l+1}^{k}g_i}{l} & s\geq l\end{cases} \tag{2-23}$$

其中 g_i 为列车上第 i 个离散点处对应的坡度值。

曲线附加阻力与列车所处线路的曲线半径有关。根据《列车牵引计算规程》，列车的曲线阻力计算公式为：

$$f_c=mg\frac{700}{R} \tag{2-24}$$

其中 R 为对应的曲线半径。

2.3 约束条件

考虑实际运行场景，结合重载列车的车辆特性，重载列车在含有长大下坡道的区间内运行时应满足如下约束条件：

（1）限速

列车限速包括区间最高限速 v_{max} 和最低缓解限速 v_{rmin}，当缓解速度过低时，列车的车钩力会急剧增大，严重的时候会造成车钩断裂。因此，列车缓解时的速度不得低于 v_{rmin}，设 v 为列车在区间内运行时的速度，v_r 为列车缓解时的速度，上述约束条件可以写为：

中国知网 https://www.cnki.net

$$\begin{cases} v \le v_{\max} \\ v \ge v_{\mathrm{rmin}} \end{cases} \tag{2-25}$$

（2）缓解时间

根据空气制动的特点，当列车进行完一次空气制动后，在进行下一次空气制动之前，应该留有足够的时间使副风缸内的压力恢复至上一次空气制动之前的值，以便列车在进行下一次空气制动时能够获得足够的空气制动力。这个时间被称为缓解时间。设缓解时间为 t_{r}，最小缓解时间为 t_{rmin}，有：

$$t_{\mathrm{r}} \ge t_{\mathrm{rmin}} \tag{2-26}$$

（3）工况转换规则

重载列车运行时，可能用到的工况有以下几种：牵引（traction, T）、惰行（coasting, C）、电制动（electric braking, EB）、空气制动（pneumatic braking, PB）和电制动加空气制动（electric braking and pneumatic braking, EPB）。司机通过操纵驾驶控制手柄，使列车不同种工况之间进行切换时，应满足表 2-2 所示的切换规则（“√”表示可以转换，“×”表示不可转换，“–”表示无需转换）：

表 2-2 工况转换规则

Table 2-2 Conversion rules of regimes

当前工况 / 下一工况	T	C	EB	PB	EPB
T	-	√	×	×	×
C	√	-	√	√	
EB	×	√	-	×	√
PB	×	√	×	-	√
EPB	×	√	√	√	-

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

3 基于人工蜂群算法的重载列车驾驶曲线优化方法

列车实际的运行过程可以结合列车的工况，由一组工况转换序列描述[36]。机车乘务员在操纵重载列车时，往往会根据已有经验，采用特定的驾驶策略进行操纵。在实际驾驶过程中，实际进行工况转换操作的位置与应进行工况转换操作的位置之间可能会受到环境影响而产生一定的偏差，因此，如何准确选取工况转换点的位置，是实现重载列车优化运行的重难点。在本章中，将工况转换点的位置设置为决策变量，研究如何使用人工蜂群算法寻找合适的工况转换点位置，并结合实际线路数据进行仿真研究。

3.1 人工蜂群算法介绍

3.1.1 算法原理

人工蜂群算法（Artificial Bee Colony，ABC）由学者 Karaboga 于 2005 年提出[81]，是一种模拟蜜蜂群体采蜜过程的群智能算法，通过设置不同种类的蜜蜂群体的行为以实现群体智能。ABC 算法具有控制参数少，易实现，收敛速度快等优点。

一个蜜蜂种群包括三种蜜蜂：雇佣蜂，跟随蜂和侦察蜂，跟随蜂和侦察蜂又统称为非雇佣蜂。三种蜜蜂的作用分别介绍如下：

雇佣蜂：每只雇佣蜂对应着一处蜜源。雇佣蜂能够利用之前的蜜源信息搜索新的蜜源，在得到新蜜源后记忆与新蜜源相关的信息，并且将这些信息与其他蜜蜂（跟随蜂）分享。

跟随蜂：在蜂房中等待并依据雇佣蜂分享的信息寻找新的蜜源。

侦查蜂：在蜂房附近随机的寻找新的有价值的蜜源。

蜜蜂之间信息的交换是蜜蜂群体智慧形成过程中最重要的一步。舞蹈区是蜂巢中最为重要的信息交换地，蜜蜂的舞蹈称为摇摆舞。雇佣蜂在舞蹈区通过摇摆舞的形式与其他蜜蜂分享蜜源的信息，通过特殊的动作来表现对应蜜源的质量，跟随蜂通过观察雇佣蜂的特殊动作来决定所要采蜜的蜜源。

ABC 算法就是模拟蜜蜂的采蜜过程而提出的一种新型智能优化算法。在 ABC 算法中，各部分的含义如下：

蜜源：蜜源的位置对应优化问题的一个解，是 ABC 算法中所要处理的基本对象。蜜源的优劣对应着可行解的好坏，由蜜源所含的花蜜量大小来决定。在优化问

中国知网 https://www.cnki.net

题中，使用适应度函数来评价这项指标，适应度函数值越大，搜索到的蜜源质量越优。

雇佣蜂：雇佣蜂的任务是发现蜜源，获得蜜源信息并以一定的概率与跟随蜂分享。这个概率应结合蜜源的有关信息进行定义，一般是根据适应度值以轮盘赌的方法计算。

非雇佣蜂：在 ABC 算法中，跟随蜂依据雇佣蜂传递的信息，在已搜索到的蜜源附近继续搜索新蜜源，并进行贪婪选择。若一个蜜源在经过一定次数开采后仍未被更新，则此雇佣蜂变成侦查蜂，侦查蜂寻找新的蜜源代替原来的蜜源。

使用 ABC 算法求解优化问题时，优化问题中相关参数和蜜蜂采蜜过程中涉及到的对象或指标的对应关系如表 3-1 所示：

表 3-1 优化问题中相关参数与蜜蜂采蜜过程对应表

Table 3-1 The relationships between parameters of optimal problem and honey collection process

采蜜过程对应参数或指标	优化问题中相关参数
蜜源	优化问题的解
蜜源质量	解的适应度函数值
最优蜜源	最优解
蜂蜜含量	最大开采度

3.1.2 算法模型与实现步骤

ABC 算法包括初始化模型，雇佣蜂模型，跟随蜂模型和侦察蜂模型[82]，分别介绍如下：

（1）初始化模型：设初始解 $X=[x_1, x_2, \ldots, x_j]$，其中 x_j（$j=1,2,\ldots, N/2$）为 D 维列向量，N 为蜜蜂的种群数量，D 由当前的优化问题维度决定。采蜜蜂和跟随蜂的数量均为 $N/2$。设向量 x_j 中的元素为x_j^i（$i=1,2,\ldots, D$），x_j^i根据式（3-1）产生：

$$x_j^i=x_{\min}^i+\text{rand}(0,1)\left(x_{\max}^i-x_{\min}^i\right) \tag{3-1}$$

其中$x_{\max}^i$和$x_{\min}^i$分别表示取值范围的上下界。

（2）雇佣蜂模型：在 ABC 算法中，每个雇佣蜂对应一个蜜源，雇佣蜂在当前位置会进行随机搜索，这个过程可以用公式（3-2）描述：

$$v_{i,j}=x_{i,j}+r\left(x_{i,j}-x_{k,j}\right) \tag{3-2}$$

其中，$v_{i,j}$是新生成的蜜源位置（新生成的解）；$x_{i,j}$为当前雇佣蜂所在位置（当

中国知网 https://www.cnki.net

前解）；r 为[-1,1]之间的随机数，$x_{k,j}$为根据当前得到的向量 x_j 随机生成的一个参考位置，k 为随机数且 $k\in\{1,2,\ldots,D\}$。搜索到新蜜源后，需要计算该蜜源的适应度，计算公式如下：

$$fitness_i=\begin{cases}\dfrac{1}{1+f(x_i)} & f(x_i)\geq 0\\ |f(x_i)| & f(x_i)<0\end{cases} \tag{3-3}$$

其中 $f(x_i)$为根据第 i 个解计算得到的目标函数值。

通常情况下，雇佣蜂根据贪婪原则判定当前搜索到的新蜜源质量是否优于旧蜜源。具体方式为比较两个蜜源对应的适应度值，若新蜜源的适应度值大于旧蜜源的适应度值，使用新蜜源代替旧蜜源，反之保留旧蜜源。

算法 3.1. ABC 算法流程

1. 初始化设置：蜜蜂总数 N(采蜜蜂的数量 $N/2$，跟随蜂的数量 $N/2$)、最大迭代次数 *MaxCycle*、最大开采次数 *limit*
2. 生成初始解。
3. 重复以下步骤：

   3.1 雇佣蜂在蜜源附近根据式（3-2）搜索新蜜源并根据式（3-3）计算适应度值，之后比较新旧蜜源的适应度值。若新蜜源优于当前旧蜜源，则令开采次数 *trial*=0，否则保留旧蜜源并令开采次数 *trial*= *trial*+1。

   3.2 跟随蜂根据式（3-4）计算选择概率P_i，将其与生成的[0,1]之间的随机数进行比较，若P_i大于该随机数则跟随蜂转变为雇佣蜂，之后回到上一步；若P_i不大于该随机数，则进行下一步。

   3.3 判断此时的开采次数 *trial* 是否达到上限，若达到上限 *limit*，侦察蜂搜寻新的蜜源，并进入下一步，否则直接进入下一步。

   4）保留目前最好的蜜源信息，并令迭代次数加 1.
4. 判断是否达到最大迭代次数 *MaxCycle*，若是，则停止运算并输出最优解，否则返回步骤 3。

（3）跟随蜂模型：跟随蜂是否跟随雇佣蜂前去采蜜，由概率 P_i 决定。P_i 的计算公式如下：

$$P_i=\frac{fitness_i}{\sum_{i=1}^{n}fitness_i} \tag{3-4}$$

首先随机生成一个[0,1]之间的随机数，若该随机数小于 P_i，则跟随蜂变成雇佣蜂前往采蜜并根据式（3-2）进行搜索，否则跟随蜂不会跟随。

中国知网 https://www.cnki.net

（4）侦察蜂模型：在雇佣蜂模型和跟随蜂模型中，若出现新蜜源适应度值不大于旧蜜源时，旧蜜源的开采度会增加 1。当该蜜源开采度达到最大开采次数 *limit* 时，雇佣蜂和跟随蜂会放弃开采变成侦察蜂，使用公式（3-1）生成新的蜜源代替当前被开采完的蜜源。

根据以上模型，可以得到使用 ABC 算法求解优化问题的步骤如算法 3.1 所示。

3.2 算法设计

ABC 算法能够很好地解决函数优化问题，在求取具有多个极小值点的函数的最小值时表现出良好的性能。与函数优化问题相比，本研究中的列车驾驶策略优化问题大致有以下区别：

（1）决策变量的取值

在函数优化问题中，决策变量的取值通常为一给定的连续闭区间。在列车驾驶策略优化问题中，若将列车当前的控制量（牵引制动力）作为决策变量，则该控制量与列车当前的速度，线路坡度等条件密切相关，不可任意取值。此外相邻决策时刻列车控制量的变化还需遵循 2.3 节中的工况转换规则。

（2）解的可行性

在求解列车驾驶策略优化问题时，所求出的工况转换点可能如图 3-1 所示：

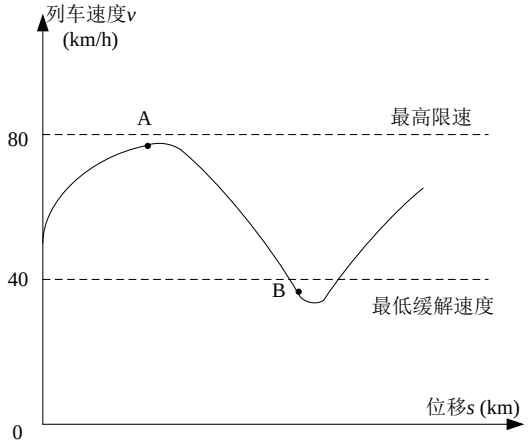


图 3-1 不可行解示意

Fig. 3-1 Schematic diagram of infeasible solution

在图 3-1 中，A 和 B 为两个工况转换点。列车在 A 点开始进行空气制动，一段时间后空气制动建立过程完成，列车速度逐渐下降，之后列车在 B 点进行空气

中国知网 https://www.cnki.net

制动缓解。由图 3-1 可知，列车进行空气制动缓解时，列车速度已经低于最低缓解速度，不满足约束条件，这一类解被称为不可行解，在求解过程中应予以舍弃。

根据以上特点，本章将在本节的剩余部分分别介绍决策变量的选取方法，初始解的生成算法以及约束条件的处理过程，之后通过对运行区间进行合理的离散化处理，设计适用于求解重载列车运行优化问题的算法。

3.2.1 决策变量

当列车在长大下坡区间运行时，为防止列车超速，司机往往会在进行电制动的基础上施加空气制动，以确保列车能够安全运行。根据 2.4 节中的介绍，列车在长大下坡区间可以通过循环制动的方式，在满足安全运行的前提下提高运行效率。本章中将列车本身产生的加速度定义为列车的外部输入 u_c，其表达式如下:

$$u_c=u_i+f_{\mathrm{aero}_i} \tag{3-5}$$

其中u_i表示列车的牵引力或电制动力，f_{aero_i}表示列车的空气制动力。根据列车操纵系统的结构，u_i和f_{aero_i}分别由对应的操纵手柄进行控制。在列车驾驶过程中，空气制动力和牵引力不可同时施加。

在实际运行过程中，为了延长车辆设备的使用寿命，列车司机在驾驶过程中会尽可能减少工况转换的次数，在相邻两个工况转换点之间，列车采用同种工况运行。本章中决策变量选取为列车工况转换点的位置，由一组工况转换点组成的工况转换序列构成一个解，如下所示：

$$P=[p_1,p_2,\ldots,p_i]$$

其中 p_i（i=1, 2, … , n）表示对应的工况转换点位置，P 为该优化问题的一个解。转换点的个数 n 可以结合实际线路数据预先设定[36]。首先可以根据线路基础数据确定不同的工况转换点数目，在不同工况转换点数目的条件下分别计算出列车的优化驾驶曲线和优化目标，之后比较根据不同工况转换点计算得到的优化目标，从中选取最优值，这个最优值对应的工况转换序列为原问题的最优解。指定工况转换点个数的方法虽然流程简单且计算速度快，但对于不同的线路而言，工况转换点个数需要重新设定，算法可移植性和灵活性较差，因此本章设计了一种初始化程序，用来计算在当前线路条件下可供选择的工况转换点个数并生成初始解。初始化程序的设计方法及流程将在 3.2.2 节中详细介绍。

3.2.2 初始解生成

中国知网 https://www.cnki.net

在使用 ABC 算法求解函数优化问题时，解向量中的每个元素取值一般是相互独立的，各个元素可以在取值范围内任意取值。而在列车运行优化问题中，考虑到列车的动力学特性、线路坡度和约束条件等信息，在每一个解向量中，后一个元素的取值需要根据前一个元素的值来确定。若将解向量定义为不同工况转换点的位置，则相邻工况转换点位置的选择如图 3-2 所示：

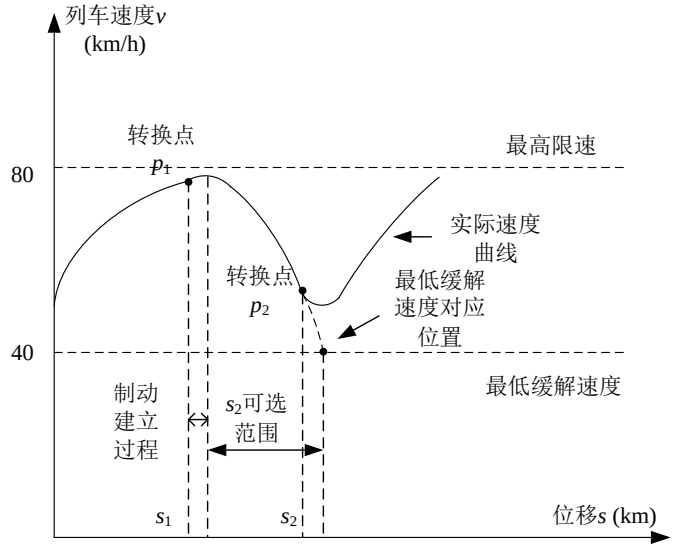


图 3-2 相邻工况转换点的选择方法示意

Fig. 3-2 Schematic diagram of the selection method of adjacent transition points of regimes

如图 3-2 所示，p_1 为是否施加空气制动的转换点，列车在 p_1 处施加空气制动；p_2 为空气制动到空气制动缓解的转换点。当 p_1 的位置 s_1 确定后，p_2 的位置 s_2 应根据空气制动的建立过程，列车当前速度以及最低缓解速度来确定。s_2 的范围如图 3-2 所示：缓解工况应在空气制动完全建立后进行，且缓解时速度不得低于最低缓解速度。与函数优化问题相比，在列车运行优化问题中，可行解需要满足的条件更多且更难生成。如果直接使用式（3-1）生成初始解，无法保证所生成初始解的可行性，进而会严重影响算法的搜索效率。

针对列车运行优化问题和函数优化问题的区别以及列车运行优化问题中初始解的重要性，已有研究中使用的处理方法大致分为以下两种：

1. 根据线路坡度和长度，车辆的基本参数等相关信息，计算列车在该区间运行时工况转换点的个数和工况转换点位置的大致范围。在接下来求解最优解的过程中，工况转换点始终在对应的位置范围内进行搜索。该方法优点是算法设计简单，搜索速度较快；缺点是灵活性低且准确性不够。
2. 首先读取线路坡度，车辆的基本参数等相关信息并将运行区间划分为若干

中国知网 https://www.cnki.net

个子区间，之后结合列车在该段线路的各项约束条件，使用运动学公式实时计算列车当前的速度。当列车的速度位于特定区间时，方可进行对应工况的转换。

与方法 1 相比，方法 2 的算法设计更复杂，且由于需要逐段计算，搜索速度更慢。但方法 2 的灵活性更强，准确性更高。另外在重载列车的实际驾驶过程中，当列车在长大下坡区段运行时，司机会根据列车当前的速度调整列车的工况，使用方法 2 更贴近实际情况。因此在本研究中使用方法 2 生成初始解。

为确保生成初始解的多样性，在确定工况转换点时，采用如图 3-3 所示的方法：

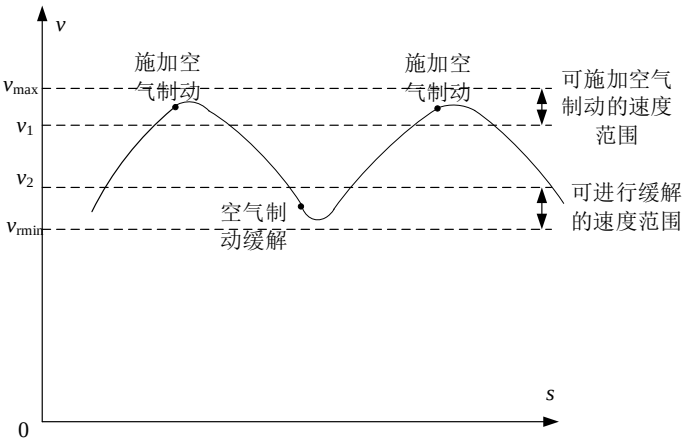


图 3-3 工况转换点可选择的范围

Fig. 3-3 The available ranges for ensuring the switching points

如图 3-3 所示，v_{max} 和 v_{rmin} 分别表示区间的最高限速和最低缓解速度。v_1 为允许列车进行空气制动的最低速度，若该速度过低则会影响列车的运行效率，v_2 为允许列车进行空气制动缓解的最高速度。由于列车进行空气制动缓解时，制动力全部由动力制动提供，因此当列车在长大下坡道上运行时，若该速度值过高则可能导致列车完成缓解后超速，该速度值可以结合实际线路数据进行计算。当列车的速度落入区间$[v_1, v_{max}]$或$[v_{rmin}, v_2]$时，改变列车当前的工况。

根据以上分析，可以设计出以下的初始解生成算法，具体流程见算法 3.2。

3.2.3 约束条件处理

中国知网 https://www.cnki.net

算法 3.2 初始解生成算法

1：读取基本参数，包括车辆参数，线路数据，初速度 v_0 以及整个运行区间的长度 L，子区间长度 ΔL 和区段数目 $n=L/\Delta L$。当前已有的工况转换点个数 $s=0$，

2：根据 v_0 确定初始工况。

3：若初始工况为动力制动，进行以下步骤：

for $i=1, 2, \ldots, n$，

3.1：结合线路的坡度信息，获得列车在动力制动工况下，在区段 i 内的加速度a_{i1}，并更新速度：

$$v_{i+1}=\sqrt{v_i^2+2a_{i1}\Delta L}$$

3.2：若列车仅有动力制动，则计算当列车速度处于$[v_1, v_{\max}]$区间内时，对应区段编号的区间$[i_1, i_2]$：

if $v_i > v_1$，then $i_1=i$；if $v_i > v_{\max}$，then $i_2=i$

计算转换点 point= i_1+round(rand*(i_2- i_1))；

3.3 若列车已施加空气制动，则计算当列车速度处于$[v_{rmin}, v_2]$区间内时，对应区段编号的区间$[i_3, i_4]$：

if $v_i < v_2$，then $i_3=i$；if $v_i < v_{rmin}$，then $i_4=i$

计算转换点 point= i_3+round(rand*(i_4- i_3))

3.4：$s=s+1$；$i=i+1$;

3.5：若 s 是奇数，根据列车当前速度等信息获得列车在电制动+空气制动时的加速度值a_{i2}，返回 3.1；若 s 为偶数，则直接返回 3.1。

4：若初始工况为空气制动+动力制动，进行以下步骤：

for $i=1, 2, \ldots, n$，

4.1：结合线路的坡度信息，获得列车在空气制动+动力制动工况下，在区段 i 内的加速度a_{i2}，并更新速度：

$$v_{i+1}=\sqrt{v_i^2+2a_{i2}\Delta L}$$

4.2：若列车仅有动力制动，则计算当列车速度处于$[v_1, v_{\max}]$区间内时，对应区段编号的区间$[i_1, i_2]$：

if $v_i > v_1$，then $i_1=i$；if $v_i > v_{\max}$，then $i_2=i$

计算转换点 point= i_1+round(rand*(i_2- i_1))；

4.3：若列车已施加空气制动，则计算当列车速度处于$[v_{rmin}, v_2]$区间内时，对应区段编号的区间$[i_3, i_4]$：

if $v_i < v_2$，then $i_3=i$；if $v_i < v_{rmin}$，then $i_4=i$

计算转换点 point= i_3+round(rand*(i_4- i_3))

4.4：$s=s+1$；$i=i+1$;

4.5：若 s 是奇数，根据列车当前速度等信息获得列车在仅有动力制动时的加速度值a_{i2}，返回 3.1；若 s 为偶数，则直接返回 3.1。

5. 若 $i=n$，则输出所有的转换点 point，结束算法；否则根据初始工况返回至 3.1 或 4.1

中国知网 https://www.cnki.net

根据 ABC 算法的更新公式（3-1）可知，计算过程中引入的新解可能为不可行解。为消除不可行解的影响，Karaboga 等提出了针对有约束问题的 ABC 算法[83]。对于不可行解的处理，提出了如下所示的 Deb 方法，在选择过程中根据 Deb 方法选取当前得到的最优解。Deb 方法由以下三条规则组成：

1.所有可行解优于不可行解；

2.对于两个可行解，具有更好目标函数值的解更优；

3.对于两个不可行解，与所有约束条件之间的偏差更小的解更优；

与原始的 ABC 算法中根据适应度函数使用贪婪原则选取最优解相比，Deb 方法允许不可行解参与到运算中，增加了算法的多样性。同时确保在选择过程中逐渐舍弃不可行解。但由于该方法主要用于函数优化，对于列车优化问题中具有的复杂约束条件不易表示和处理，因此具有一定的局限性。

使用 ABC 算法对列车运行优化问题进行研究时，对约束条件的处理主要包括两种方法：第一种方法是在初始化过程中，结合所有的约束条件生成搜索空间，搜索空间内的解均为可行解，之后基于已生成的搜索空间进行寻优操作。例如李瑶使用该方法，基于北京地铁亦庄线的数据研究列车节能运行优化问题[84]。第二种方法是在优化过程中，将约束条件整合到适应度函数中，通过算法在寻优过程中不断选取适应度函数更优的解来实现满足约束条件的目的。例如方春林等将其应用于京津城际铁路的行车运营优化[85]。

以上两种方法中，第一种方法通过指定搜索空间，不仅可以确保满足所有的约束条件，而且可以提高搜索效率，但同时算法也会失去多样性；第二种方法虽然确保了多样性，但在解空间过大的情况下，不能有效舍弃不可行解，搜索到可行解的速度较慢。结合以上两种方法的特点，本文在初始化过程中，采用算法 3.2 介绍的方法生成初始解；在求解过程中使用惩罚函数表示约束条件，从而满足搜索效率和算法多样性的要求。以下介绍使用惩罚函数处理约束条件的方法：

设优化问题的约束条件可以由下列公式表示：

$$\begin{cases} g(x) = 0 \\ h(x) \geq 0 \end{cases} \tag{3-6}$$

其中 $g(x)$，$h(x)$分别表示优化问题中的等式约束和不等式约束。则算法 1 中的目标函数应改写为：

$$f_{\text{new}} = f(x) + M_1 \max(g(x), 0) + M_2 \text{abs}(h(x)) \tag{3-7}$$

上面的等式中，f_{new} 表示新得到的目标函数，$f(x)$为算法 3.1 中的原目标函数，M_1，M_2 均为惩罚因子，实际运算中可以取较大的正数，因此当约束条件（3-6）中有任意一项不满足时，f_{new} 的取值将会很大。由算法 1 中的公式（3-3）可知，f_{new}

中国知网 https://www.cnki.net

的取值越大，对应的适应度值将更小，所得到的解在接下来的计算中会随着找到适应度值更大的解而被舍弃。约束条件包括限速，缓解时间以及缓解速度。与限速不同，缓解时间，以及缓解速度仅具有最小值，因此与限速的处理方式有所不同。下面分别使用惩罚函数对这些约束条件进行表示。

1）限速

列车的速度 v 应满足 $0\leq v\leq v_{\max}$，其中 $v_{\max}$ 表示线路的最高限速。对应的惩罚函数 f_{pv} 如下：

$$f_{\text{pv}}=p_1\sum_{i=1}^{n}(\max(0,-v_i)+\max(0,v_i-v_{\max})) \tag{3-8}$$

式（3-8）中，v_i 为每个分段点对应的速度值，p_1 为惩罚因子，在实际计算过程中取一个较大的正数。

2）缓解时间以及缓解速度

关于缓解时间以及缓解速度的约束条件分别用惩罚函数 f_{prt}， f_{prv} 表示：

$$f_{\text{prt}}=p_2\max\left(0,t_{r_j}-t_{\text{rmin}}\right) \tag{3-9}$$

$$f_{\text{prv}}=p_3\max\left(0,v_{r_j}-v_{\text{rmin}}\right) \tag{3-10}$$

其中 p_2 和 p_3 为惩罚因子，设置方式与 p_1 相同。t_{r_j}和v_{r_j}分别表示第 j 次缓解操作的缓解时间，以及第 j 次缓解时的列车速度。

结合公式（3-8）-（3-10），改写后的目标函数 f_{new} 为：

$$f_{\text{new}}=f(x)+f_{\text{prt}}+f_{\text{prv}}+f_{\text{pv}} \tag{3-11}$$

在函数（3-11）中，若出现任何不满足约束条件的解，则通过惩罚因子 p_1，p_2 或 p_3 的作用，目标函数值将明显变大，之后可以通过后续的选择机制将其舍弃。

在 ABC 算法中，适应度函数用于表示对应解的质量的优劣。适应度函数由函数（3-3）表示[81]。结合函数（3-11），改进后的适应度函数应表示为：

$$fitness_i=\begin{cases}\dfrac{1}{1+f_{\text{new}}(x_i)} & f_{\text{new}}(x_i)\geq 0\\ \left|f_{\text{new}}(x_i)\right| & f_{\text{new}}(x_i)<0\end{cases} \tag{3-12}$$

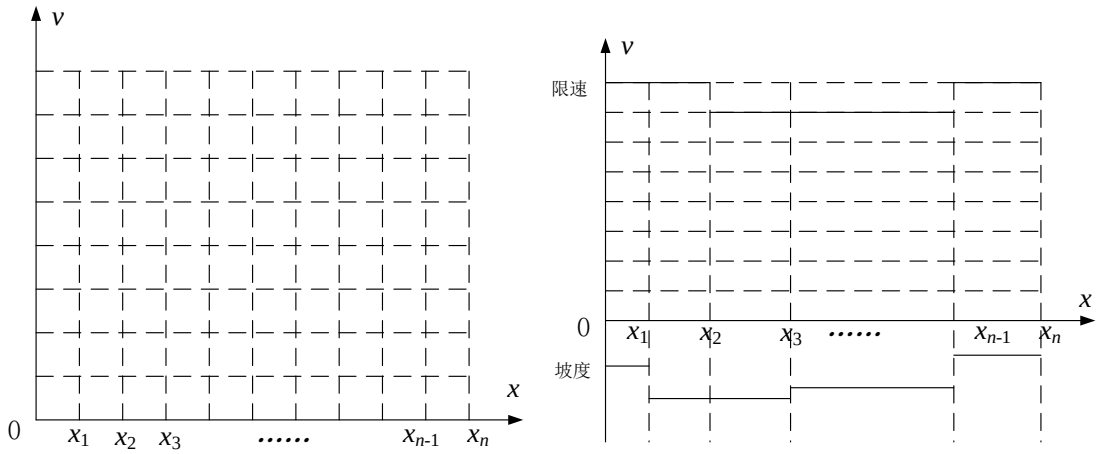
3.2.4 离散化方法

由于 ABC 算法适用于离散系统，因此在求解列车最优驾驶曲线之前，应先将相关指标做离散化处理。下面分别介绍按位移和时间进行离散化的方法。

针对运行区间的离散化方法有根据位移和运行时分进行离散化的两种方法。

中国知网 https://www.cnki.net

根据位移进行离散化时，分别有根据区间长度和线路坡度信息进行等分分区和不等分分区的两种方法，两种方法的分段示意如下图 3-4（a）（b）所示：



（a）等分分区　　（b）按限速和坡度划分的不等分分区

图 3-4 线路等分分区和不等分分区示意图

Fig. 3-4 The schematic diagram of equal and unequal division of operation sections

与等分分区相比，不等分分区结合了线路的坡度、限速等信息，能够有效提高运算速度，同时满足一定的精确性，在城轨列车运行优化问题中已有应用。与重载列车相比，城轨列车驾驶控制方法更为简单，且运行区间无长大下坡道，因此可以通过牵引-惰行的工况组合实现列车优化运行的目标。而重载列车在长大下坡区段运行时必须使用循环制动，即空气制动-电空联合制动的操作方式，列车加速度变化明显，使用不等分分区法不能满足计算的精度要求，因为本文选用等分分区法对运行区间进行离散化：在距离为 ΔL 或运行时分为 Δt 的区间内，假设列车做匀变速运动，即列车在每个区间内的加速度为定值。当 ΔL 或 Δt 的值越小时，在每个分段点处计算得到的速度值误差越小。因此在实际计算过程中，ΔL 和 Δt 取值足够小时，可以确保计算精度满足要求。

（1）按位移进行离散化

设区间长度为 L，现将其均分为 n 段，每段长度为 ΔL。则列车在进入到第 i 个区段时的瞬时加速度 a_i 为：

$$a_i=\frac{u_i+f_{p_i}+f_{aero_i}}{m} \tag{3-13}$$

其中 u_i 为列车在第 i 个区段的牵引力或电制动力，f_{aero_i} 表示列车在第 i 个区段的空气制动力，f_{p_i} 由第 i 个区段的坡道阻力，基本阻力和曲线阻力共同决定。

u_i 的取值范围：

中国知网 https://www.cnki.net

$$-u_{max\,b} \le u_i \le u_{max\,t} \tag{3-14}$$

其中 u_{maxt}，u_{maxb} 分别表示最大牵引力和最大电制动力（计算时均取正数），设列车在进入第 i 个区段时的速度为 v_i，根据机车的牵引制动特性曲线，u_{maxt}，u_{maxb} 由下面的函数确定：

$$\begin{cases} u_{max\,t}=f_t(v_i) \\ u_{max\,b}=f_b(v_i) \end{cases} \tag{3-15}$$

得到列车的加速度后，根据运动学公式，可以得到列车在进入到第 i+1 个区段时的速度：

$$v_{i+1}=\sqrt{v_i^2+2a_i\Delta L} \tag{3-16}$$

根据公式（3-13）-（3-16），结合列车所受到的空气制动力，基本阻力和附加阻力，可以依次计算出列车在各个分段点的速度值，进而得到列车的驾驶曲线。

列车施加空气制动的距离 L_{p} 可改写为：

$$L_{\mathrm{p}}=\sum_{i=1}^{n} k_i\Delta l \tag{3-17}$$

其中 $k_i\in\{0, 1\}$为二值变量，取值为 1，0 时分别表示已施加空气制动和未施加空气制动。

根据假设，列车在每个子区间内做匀变速运动，因此列车的区间运行时分 T 可由每个子区间的运行时分 t_i 累加求和得到。

$$t_i=\begin{cases} \dfrac{v_{i+1}-v_i}{a_i} & a_i \neq 0 \\ \dfrac{\Delta l}{v_i} & a_i = 0 \end{cases} \tag{3-18}$$

$$T=\sum_{i=1}^{n} t_i \tag{3-19}$$

根据公式（3-17）-（3-19），以及 2.1 节中的公式（2-6），得到按位移离散化后得到的目标函数为：

$$f_{\mathrm{obj}}=\lambda_1\frac{\sum_{i=1}^{n} t_i}{T_{\mathrm{o}1}}+\lambda_2\frac{\sum_{i=1}^{n} k_i\Delta l}{L} \tag{3-20}$$

其中 λ_1-λ_2 为权重，表示不同优化目标的重要性。$T_{\mathrm{o}1}$ 和 L 与公式（2-6）中的含义相同。

（2）按时间进行离散化

设列车的区间运行时分为 T，将运行区间按时间等分为 n_1 段，每段时间为 Δt，

中国知网 https://www.cnki.net

即 $T=n_1\Delta t$。列车在第 i 个区段运行时的加速度可根据公式（3-13）计算。列车的速度更新公式为：

$$v_{i+1}=v_i+a_i\Delta t \tag{3-21}$$

在运行时分 T 内，列车的运行距离 L_{dis} 为

$$L_{\text{dis}}=\sum_{i=1}^{n-1}\frac{v_i+v_{i+1}}{2}\Delta t \tag{3-22}$$

空气制动时间 T_{p} 的计算公式为：

$$T_{\text{p}}=\sum_{i=1}^{n}k_i\Delta t \tag{3-23}$$

其中 k_i 与式（3-17）中的含义相同。

根据时间进行离散化时，优化目标为空气制动时间 T_{p} 和列车运行距离 L_{dis}。结合 2.1 节中的公式（2-7），具体的目标函数为：

$$f_{\text{obj2}}=\lambda_1\frac{\sum_{i=1}^{n}t_i}{T_{\text{p1}}}+\lambda_2\frac{\sum_{i=1}^{n-1}\frac{v_i+v_{i+1}}{2}\Delta t}{L_{\max}} \tag{3-24}$$

其中 T_{p1} 和 $L_{\max}$ 与公式（2-7）中的含义相同。

3.2.5 算法实现

当使用算法 3.1 寻找列车的最优工况转换点时，每求出一组工况转换序列，均需要根据这一组求得的工况转换序列计算目标函数值，以便进行后续的寻优计算。在计算目标函数值之前，应先计算列车根据当前工况转换序列获得的驾驶曲线。本节首先给出基于工况转换序列求解列车驾驶曲线的流程，之后结合计算列车驾驶曲线的流程，得到基于 ABC 算法的重载列车优化驾驶曲线生成算法。

根据列车当前的工况，可以确定出列车的受力情况，进而根据列车的动力学方程，计算出列车当前的速度。因此，重载列车的驾驶曲线可以通过工况描述。根据列车工况求列车驾驶曲线的流程如图 3-5 所示。

当列车工况发生变化时，列车的牵引力和制动力也相应发生变化。因此由图 3-5 可知，已知列车在该区段应选用的工况和所有工况转换点的位置，即可计算出列车的驾驶曲线。

算法 3.3 中给出了基于 ABC 算法的重载列车优化驾驶曲线生成流程。

中国知网 https://www.cnki.net

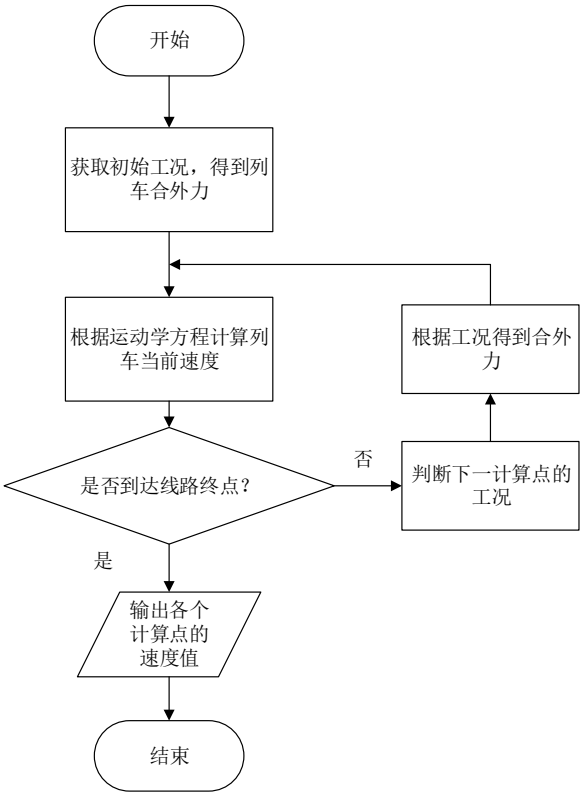


图 3-5 驾驶曲线计算流程

Fig. 3-5 Flow chart of the calculation of driving curve

3.3 仿真结果与分析

3.3.1 仿真参数设置

本节使用 Matlab 语言来实现本章中提出的算法，并在 Matlab 软件中通过不同的仿真算例验证算法的优化效果。下面给出了相关仿真参数的设置。

（1）牵引制动特性曲线参数

根据对应机车的牵引制动特性曲线，列车的最大牵引力和最大电制动力可以分别用以下的线性函数和分段线性函数进行拟合：

$$u_{\max t}=-17.76v+673.8 \tag{3-25}$$

$$u_{\max b}=\begin{cases}104.3v+35.1 & 0<v\leq 3.33\\ 382 & 3.33<v\leq 13.89\\ -19.22v+642 & v>13.89\end{cases} \tag{3-26}$$

（2）ABC 算法相关参数设置

中国知网 https://www.cnki.net

对 ABC 算法的相关参数进行设置时，应注意最大循环次数可取一个较大值，以便搜索到最优解。具体参数设置如表 3-2 所示。

算法 3.3 基于 ABC 算法的重载列车优化驾驶曲线生成算法

1：初始化设置，分为对 ABC 算法的初始化设置以及仿真参数的初始化设置。对 ABC 算法的初始化设置包括：设置蜜蜂种群数量 N（雇佣蜂的数量 $N/2$，跟随蜂的数量 $N/2$）、最大迭代次数 *MaxCycle*、蜜源开采度 *limit* 和当前蜜源的开采度 *trial*（*trial* 的初值为 0）；对仿真参数的初始化设置包括车辆基本数据，线路数据，运行时分和运行里程等。

2：根据算法 3.2 生成初始解。

3：对于每一组初始解，进行以下步骤：

3.1：根据分段点速度计算流程计算出列车在各个分段点的速度，从而求出 f_{new}。

3.2：将 f_{new} 代入公式（3-3），求出适应度函数值。

4：根据算法 1 中的公式（3-2）产生新解（工况转换序列），然后依次进行步骤 3.1，3.2。

5：将步骤 4 中得到的适应度函数与初始解的适应度函数对比，保留适应度更高的解。若新解的适应度函数值更高，则令 *trial*=0，否则 *trial*=*trial*+1。

6：根据公式（3-4）计算步骤 5 中保留下来的每个解对应的概率。将这个概率值与[0, 1]之间的一个随机数 *k* 进行比较。若概率值大于 *k*，则返回步骤 4 并按顺序运行，若概率值小于 *k*，直接令 *trial*=*trial*+1 并进入下一步。

7：若 *trial*=*limit*，则通过式（3-1）产生新的解，之后返回步骤 4；否则进入下一步。

8：储存得到的最优解。若迭代次数等于 *MaxCycle*，则停止运算，输出经过所有步骤得到的最优解；否则令迭代次数加 1，返回步骤 2。

表 3-2 ABC 算法参数设置

Table 3-2 Parameters setting of ABC algorithm

参数	值	参数	值
最大循环次数 *MaxCycle*	1000	蜜源最大开采次数 *limit*	100
蜜蜂种群数量	200	惩罚因子 $p_i(i=1,2,3)$	10^6
v_1	65km/h	v_2	45km/h

3. 列车参数设置

本章选取由两台 SS4B 型电力机车牵引 108 辆 C80 货车组成的“1+1”编组万吨列车作为仿真研究的对象。在实际运行过程中，为留出一定安全余量，列车运行时的最高速度不超过 80km/h，最低缓解速度不低于 40km/h。相关参数如表 3-3 所示：

中国知网 https://www.cnki.net

表 3-3 列车相关参数
Table 3-3 Parameters of vehicles

参数名称	值	单位
列车质量	$1.168\bullet10^{7}$	kg
列车长度	1360	m
区间最高限速	80	km/h
最大单位空气制动力	$8.5\bullet10^{-3}$	N/kN
c_0	$8.0\bullet10^{-3}$	N/kg
c_1	$1.08\bullet10^{-4}$	$Ns(mkg)^{-1}$
c_2	$2.0\bullet10^{-5}$	$Ns^2(m^2kg)^{-1}$
最低缓解速度	40	km/h
最小工况持续时间	10	s
最小缓解时间	180	s

4. 线路坡度

仿真案例中使用到的线路坡度信息如图 3-6 所示：

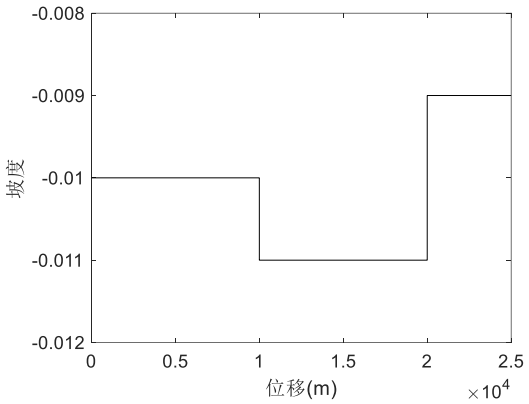


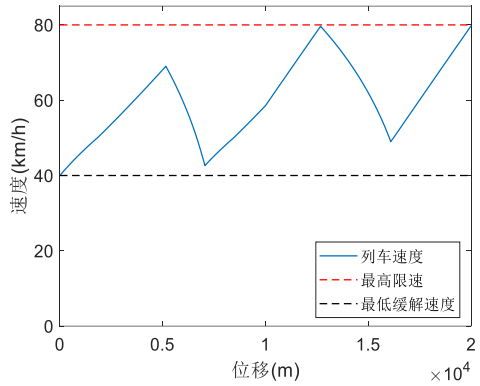
图 3-6 线路坡度信息

Fig. 3-6 The gradient of the line

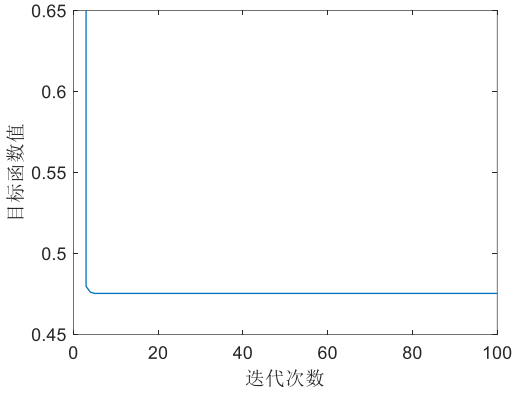
3.3.2 按位移进行离散化

在该仿真案例中，选取运行区间长度 L 为 20km，子区间长度 ΔL=10m。根据以上参数，分别设置初速度为 40km/h，50km/h 和 60km/h，权重 $\lambda_1=\lambda_2=0.5$，得到按位移分段计算得到的最优驾驶曲线和算法收敛情况如图 3-7 所示：

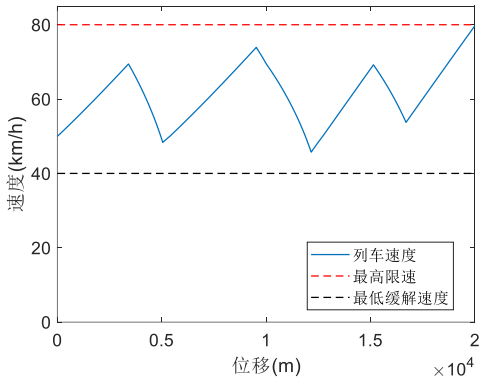
中国知网 https://www.cnki.net



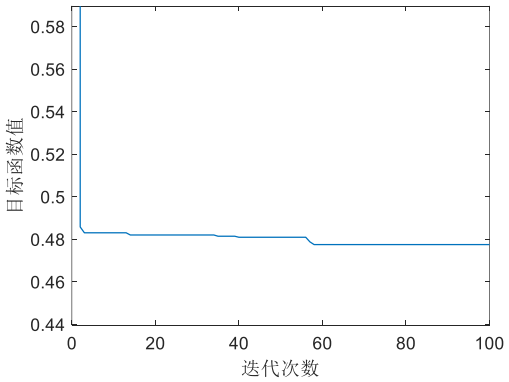
（a）v_0=40km/h 时得到的驾驶曲线



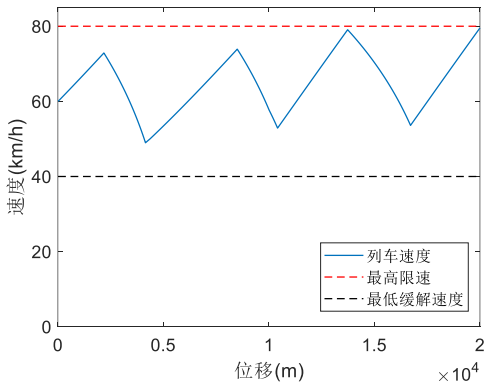
（b）v_0=40km/h 时的收敛情况



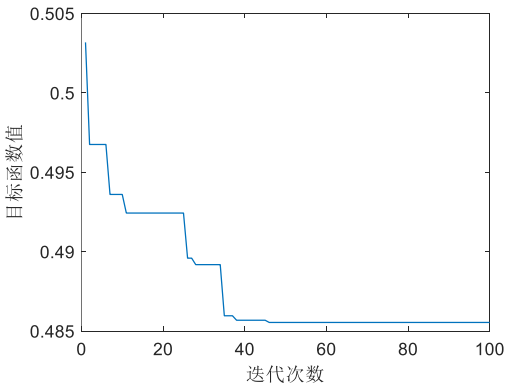
（c）v_0=50km/h 时得到的驾驶曲线



（d）v_0=50km/h 时的收敛情况



（e）v_0=60km/h 时得到的驾驶曲线



（f）v_0=60km/h 时的收敛情况

图 3-7 最优驾驶曲线和算法收敛情况

Fig. 3-7 Optimal driving curve and the convergence of the algorithm

图 3-7 中给出了优化后的重载列车驾驶曲线。图 3-7 中黑色虚线表示最低缓解速度，红色虚线表示区间最高限速。根据图 3-7(a)，(c)，(e)可以看出，列车在长大下坡区段运行时，算法能够对列车的工况转换点位置和数目进行优化，使得列车速

中国知网 https://www.cnki.net

度始终不低于最低缓解限速，不超过最高限速，并且在确保安全运行的前提下使用了较少次数的空气制动，进而达到优化运行的目的。根据图 3-7(b)，(d)，(f)可以看出，算法在初期收敛速度较快，此后收敛速度逐渐减慢，并且在 100 代以内寻找到最优解。以上三种场景的计算结果如表 3-4 所示：

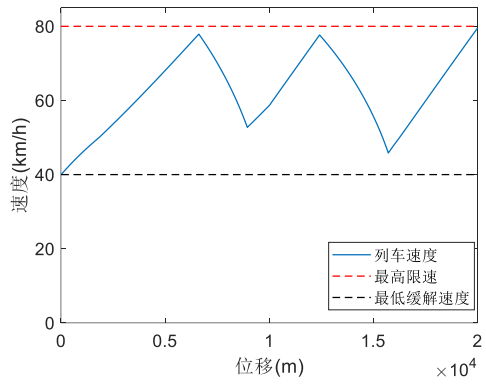
表 3-4 按位移离散化得到的仿真结果

Table 3-4 Simulation results obtained by discretization of displacement

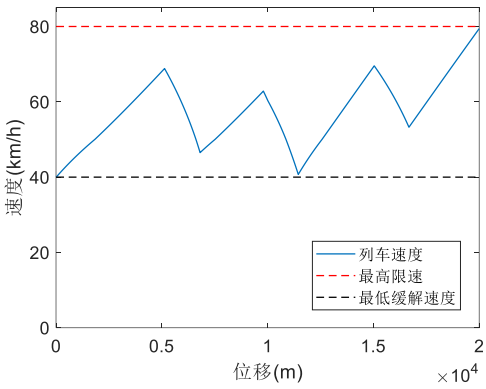
初速度 v_0(km/h)	目标函数值 f_{obj}	区间运行时分 T(s)	空气制动距离 L_p(m)
40	0.475	1223	5310
50	0.478	1195	5830
60	0.486	1126	6860

根据表 3-4 可以看出，列车的空气制动距离随着列车的初速度呈现明显的正相关趋势：当列车初速度较高时，列车速度更容易接近最高限速，因此需要尽早施加空气制动使得列车速度下降，从而导致空气制动的距离增加。列车的区间运行时分则随着列车初速度的增加而逐渐减小。由于列车的初速度较高，结合图 3-7(e)可知列车速度始终在速度值较大的范围内变化，因此虽然空气制动距离明显高于初速度为 40km/h 和 50km/h 时的空气制动距离，但区间运行时分仍低于初速度为 40km/h 和 50km/h 时的区间运行时分。

接下来通过改变目标函数中权重的值，以验证算法有效性。其中 λ_1，λ_2 分别对应于运行时间 T 和空气制动距离 L_p 的权重。计算得到的驾驶曲线如下图 3-8 所示：

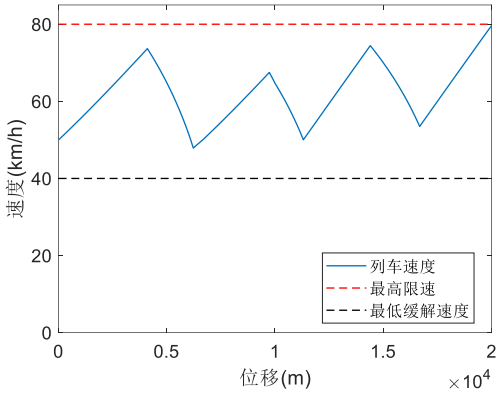


（a）v_0=40km/h，λ_1=0.8，λ_2=0.2

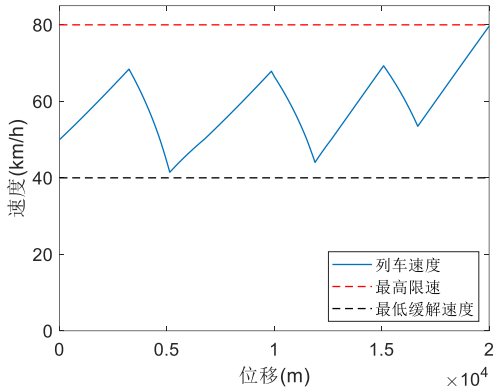


（b）v_0=40km/h，λ_1=0.2，λ_2=0.8

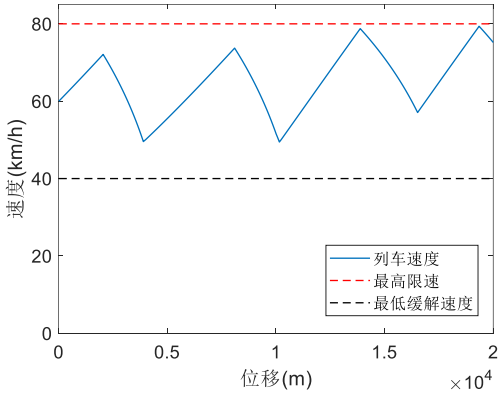
中国知网 https://www.cnki.net



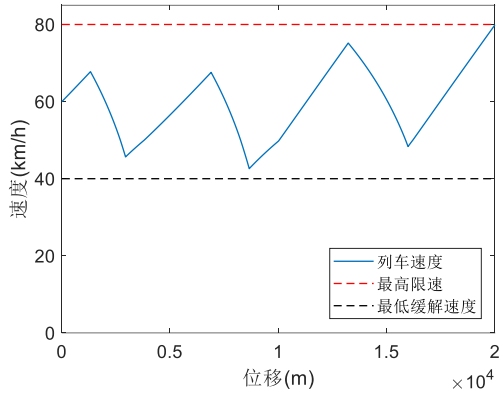
（c）v_0=50km/h，λ_1=0.8，λ_2=0.2



（d）v_0=50km/h，λ_1=0.2，λ_2=0.8



（e）v_0=60km/h，λ_1=0.8，λ_2=0.2



（f）v_0=60km/h，λ_1=0.2，λ_2=0.8

图 3-8 优化目标权重不同时得到的列车驾驶曲线

Fig 3-8 Driving curve obtained when the target weight is different

表 3-5 改变权重后得到的仿真结果

Table 3-5 Simulation results obtained after changing the weight

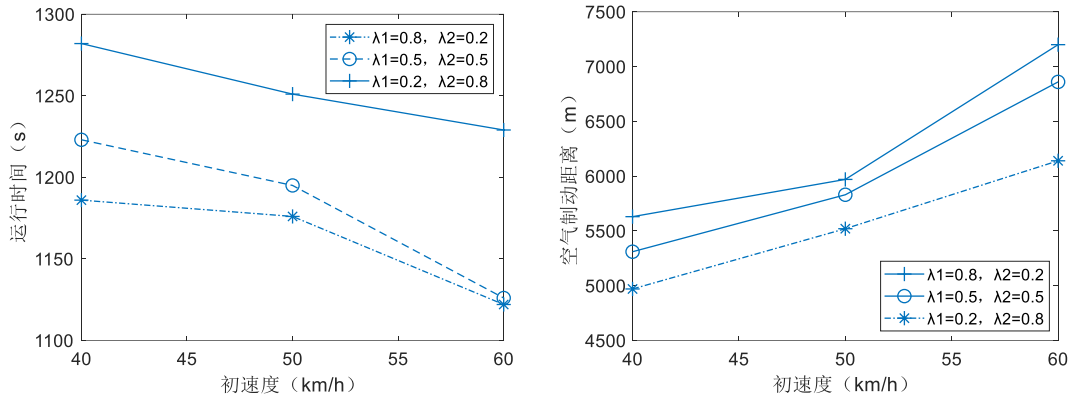
v_0（km/h）	λ_1	λ_2	f_{obj}	T(s)	L_p(m)
40	0.5	0.5	0.475	1223	5310
	0.8	0.2	0.583	1186	5630
	0.2	0.8	0.341	1282	4970
50	0.5	0.5	0.478	1195	5830
	0.8	0.2	0.582	1176	5970
	0.2	0.8	0.360	1251	5520
60	0.5	0.5	0.486	1126	6860
	0.8	0.2	0.571	1122	7200
	0.2	0.8	0.382	1229	6140

具体的计算结果如表 3-5 所示。为体现权重变化对计算结果的影响，表 3-5 中

中国知网 https://www.cnki.net

统计了 λ_1=λ_2=0.5 的结果。

不同指标随权重的变化趋势如图 3-9 所示。



（a）列车运行时分随权重的变化趋势　　（b）空气制动距离随时间的变化趋势

图 3-9 不同优化指标随时间的变化趋势

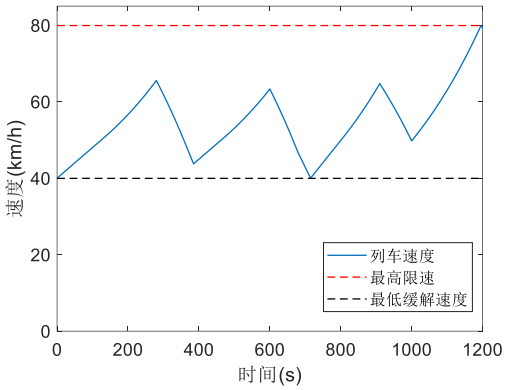
Fig.3-9 The trend of operation time air braking distance with corresponding weight

结合表 3-5 中的计算结果和图 3-9 所示的结果可知，当权重 λ_1，λ_2 的取值发生变化时，对应指标均有明显变化。以 v_0=60km/h 的计算结果为例，当 λ_1=0.8，λ_2=0.2 时，优化算法更偏重于减少区间的运行时分，据此计算得到的运行时分为 1122 s，空气制动距离为 7200 m，与 λ_1=λ_2=0.5 时的计算结果相比，运行时分减少了 0.4%，空气制动距离增加了 5.0%；与 λ_1=0.2，λ_2=0.8 时的计算结果相比，运行时分减少了 9.1%，空气制动距离增加了 10.5%。当 v_0=50km/h 和 v_0=40km/h 时权重和对应指标的变化情况与 v_0=60km/h 时相同。通过改变权重的值，算法仍然表现出较好的优化性能，能够有效求解该优化问题。

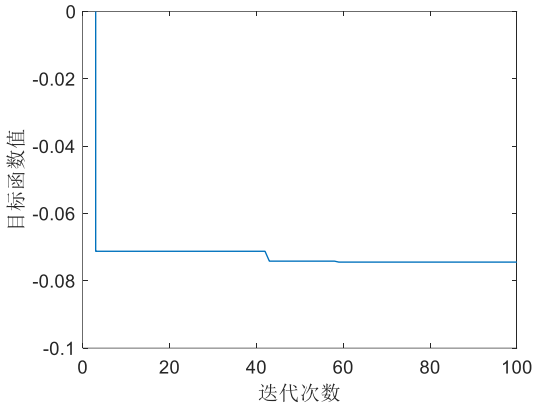
3.3.3 按时间进行离散化

在该算例中，选取列车在区间内的运行时分为 1200s，离散化后分为 240 个子区间，每个子区间的时间长度 Δt=5s。分别设置初速度为 40km/h，50km/h 和 60km/h，权重 λ_1=λ_2=0.5。根据以上设置得到的最优驾驶曲线和算法收敛情况如图所示：

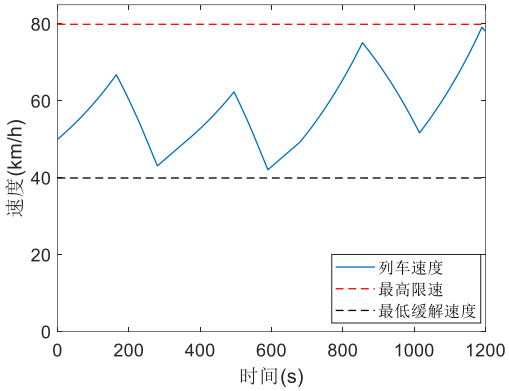
中国知网 https://www.cnki.net



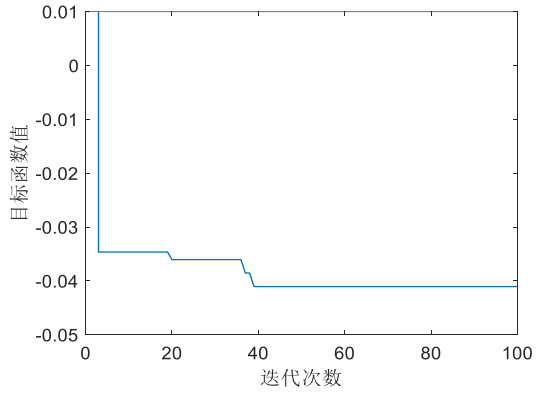
（a）v_0=40km/h 时得到的驾驶曲线



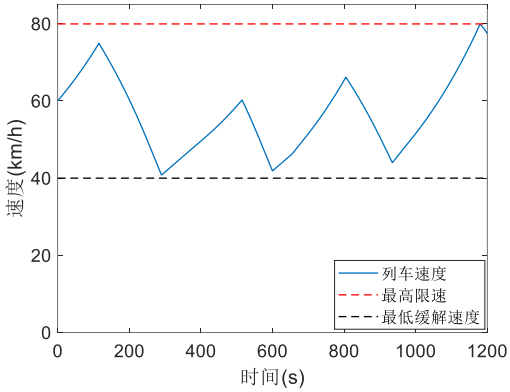
（b）v_0=40km/h 时的收敛情况



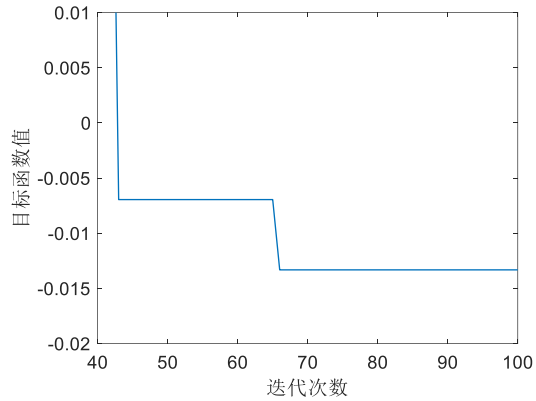
（c）v_0=50km/h 时得到的驾驶曲线



（d）v_0=50km/h 时的收敛情况



（e）v_0=60km/h 时得到的驾驶曲线



（f）v_0=60km/h 时的收敛情况

图 3-10 最优驾驶曲线和算法收敛情况

Fig. 3-10 Optimal driving curve and the convergence of the algorithm

图 3-10 中给出了按照时间进行离散化后得到的最优驾驶曲线。与图 3-8 类似，在 3 种不同初速度条件下列车均能够在满足安全运行的前提下尽可能减少空气制动的时间，从而提高列车在区间内的运行效率。由图 3-10 中(b)，(d)，(f)可以看出，根据初始解得到的目标函数较大，表明生成的初始解为不可行解，但算法能够通过

中国知网 https://www.cnki.net

寻优过程舍弃不可行解，并且在 20 次迭代内迅速搜索到可行解，由此证明了算法中引入惩罚函数的有效性。具体仿真结果如表 3-6 所示：

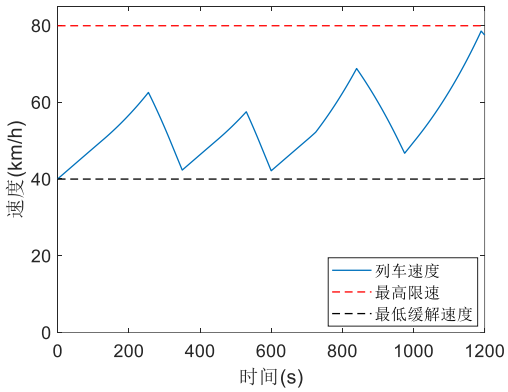
表 3-6 按时间离散化得到的仿真结果

Table 3-6 Simulation results obtained by discretization of time

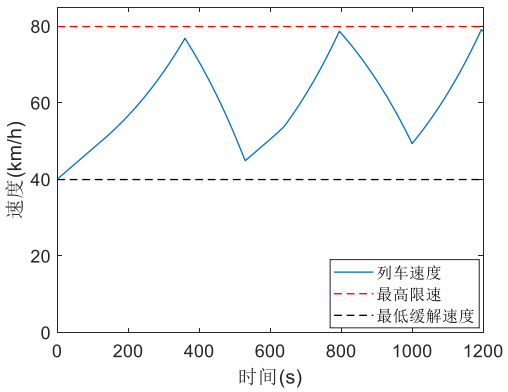
初速度 v_0(km/h)	目标函数值 f_{obj}	空气制动时间 T(s)	运行距离 L(m)
40	-0.074	315	18220
50	-0.041	375	19301
60	-0.013	405	18942

由表 3-6 可以看出，目标函数值与初速度的取值呈负相关趋势，空气制动时间的值与初速度呈正相关趋势。当列车初速度更高时，运行过程中速度值更容易接近最高限速，因此列车会更早进行空气制动，从而使得空气制动的时间增加。当列车初速度为 50km/h 时，计算得到的运行距离最大。因为当 v_0=40km/h 时列车初速度较低，对列车的平均速度有影响；而 v_0=60km/h 时列车初速度虽然较高，但列车进行空气制动时间较长，从而降低了列车的平均速度，因此 v_0=40km/h 和 60km/h 时计算得到的运行距离低于 v_0=50km/h 时计算得到的运行距离。

接下来通过改变目标函数中权重的值，进一步验证算法有效性。计算得到的驾驶曲线如图 3-11 所示：

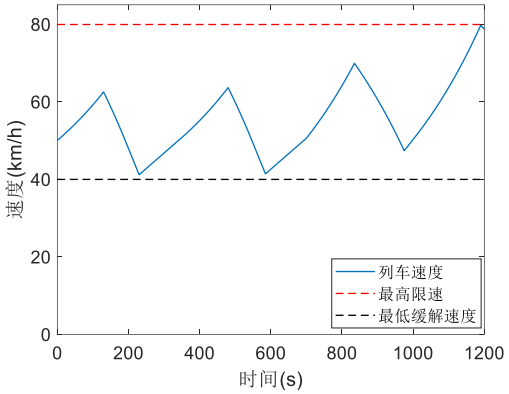


（a）v_0=40km/h，λ_1=0.8，λ_2=0.2

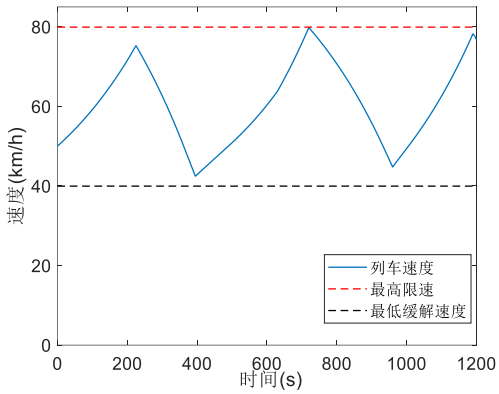


（b）v_0=40km/h，λ_1=0.2，λ_2=0.8

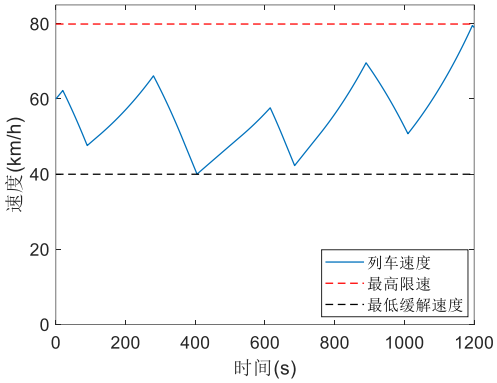
中国知网 https://www.cnki.net



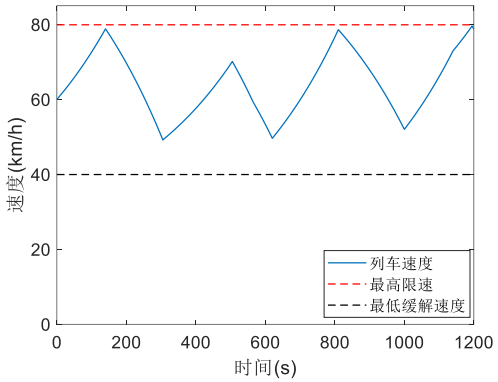
（c）v_0=50km/h，λ_1=0.8，λ_2=0.2



（d）v_0=50km/h，λ_1=0.2，λ_2=0.8



（e）v_0=60km/h，λ_1=0.8，λ_2=0.2



（f）v_0=60km/h，λ_1=0.2，λ_2=0.8

图 3-11 优化目标权重不同时得到的列车驾驶曲线

Fig. 3-11 Driving curve obtained when the target weight is different

表 3-7 改变权重后得到的仿真结果

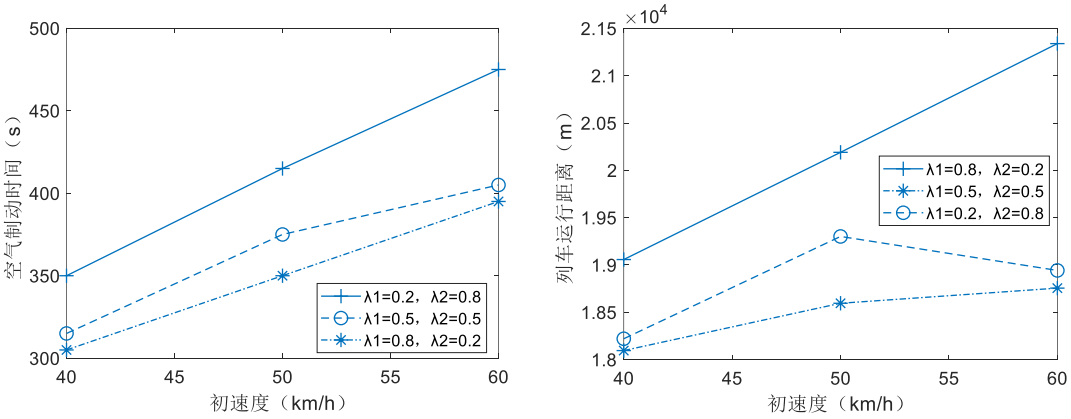
Table 3-7 Simulation results obtained after changing the weight

v_0（km/h）	λ_1	λ_2	f_{obj}	T_p(s)	L (m)
40	0.5	0.5	-0.074	315	18220
	0.8	0.2	0.271	305	18095
	0.2	0.8	-0.455	350	19057
50	0.5	0.5	-0.041	375	19301
	0.8	0.2	0.327	350	18595
	0.2	0.8	-0.467	415	20190
60	0.5	0.5	-0.013	405	18942
	0.8	0.2	0.386	395	18755
	0.2	0.8	-0.482	475	21339

中国知网 https://www.cnki.net

具体的计算结果如表 3-7 所示。为体现权重变化对计算结果的影响，表 3-7 中统计了 λ_1=λ_2=0.5 的结果。

由表 3-7 中不同优化目标随着对应的权重变化的趋势见下图 3-12：



（a）空气制动时间随权重的变化趋势　　（b）列车运行距离随权重的变化趋势

图 3-12 空气制动时间和列车运行距离随权重的变化趋势

Fig. 3-12 The trend of air braking time and operation distance with corresponding weight

根据图 3-12 可知，不同优化指标随权重变化趋势一致，即列车运行距离随权重 λ_1 增加而增大，空气制动时间随权重 λ_2 增加而减小。可以注意到在图 3-12（b）中，初速度为 60km/h 时计算得到的列车运行距离小于初速度为 50km/h 时的列车运行距离。因为当列车初速度为 60km/h 时，空气制动时间更长，进而影响了列车在区间内的平均速度，所以列车的运行距离更短。对于 3.3.3 节中的算例，算法仍然能够保持较好的优化性能，进一步证明了算法的有效性。

3.3.4 算法参数分析

在 ABC 算法中，蜜蜂的种群数量和蜜源开采次数是两个比较重要的参数。在已有研究中，通常根据经验确定这两个参数的具体数值，但针对两种参数对算法优化效果的影响研究较少。本章 3.3.2 节和 3.3.3 节中的仿真结果已经证明根据已有经验取值具备有效性，因此本节中使用控制变量法，研究种群数量和蜜源开采次数的取值对优化效果的影响。

（1）种群数量 NP

在接下来的算例中，种群数量的最小值设置为 100，最大值设置为 600，蜜源开采次数 *limit* 为 50，列车初速度为 60km/h，目标函数中 λ_1=0.8，λ_2=0.2，迭代次数设置为 1000 次，其他仿真参数与 3.3.3 节中相同，由于 ABC 算法在求解过程中

中国知网 https://www.cnki.net

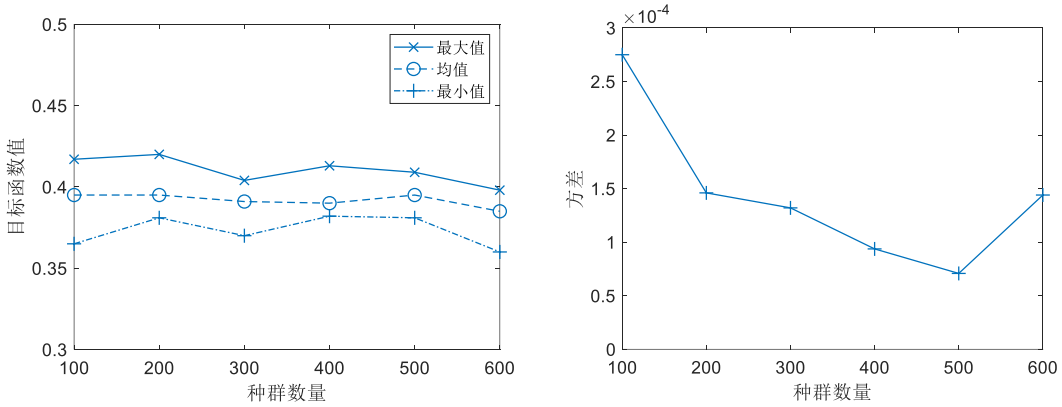
具有一定的随机性，因此对相同初始条件的程序运行 10 次，得到在对应初始条件下的目标函数值，并统计 10 次结果中的最大值，最小值，均值和方差，以及平均运行时间。具体结果如下表 3-8 所示：

表 3-8 不同种群数量对计算结果的影响

Table 3-8 The influence of the number of different populations on the calculation results

种群数量	最大值	最小值	均值	方差	平均运行时间（s）
100	0.417	0.365	0.395	2.75×10^{-4}	116
200	0.420	0.381	0.395	1.46×10^{-4}	178
300	0.404	0.370	0.391	1.32×10^{-4}	207
400	0.413	0.382	0.390	9.37×10^{-5}	244
500	0.409	0.381	0.395	7.08×10^{-5}	238
600	0.398	0.360	0.385	1.44×10^{-4}	261

表 3-8 中不同指标随种群数量的变化趋势如下图 3-13 所示：



（a）最值和均值的变化趋势　　（b）方差的变化趋势

图 3-13 不同指标随种群数量的变化趋势

Fig. 3-13 Variation trends of different indicators with population size

根据图 3-13 可知，虽然根据不同种群数量计算得到的均值变化幅度很小，但是当种群数量为 100 和 600 时，目标函数的最小值明显小于根据其他种群数量计算得到的结果，对应的两组数据的方差大于种群数量为其他值对应的数据方差。以上结果表明当种群数量为 100 和 600 时，每次试验结果变化较大，算法的探索能力更强。根据不同种群数量计算 10 次，每次得到的目标函数值如图 3-14 所示。

中国知网 https://www.cnki.net

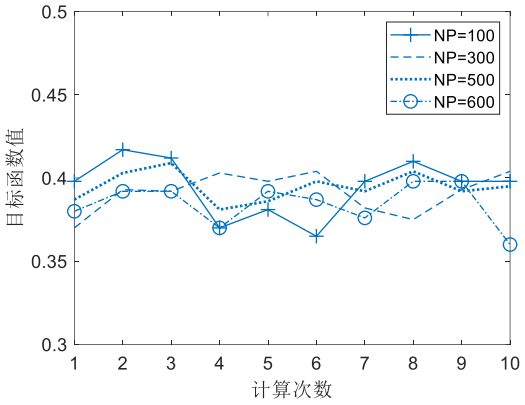


图 3-14 不同种群数量下计算得到的目标函数值

Fig. 3-14 Objective function value calculated under different population numbers

如图 3-14 所示，横轴为计算次数，纵轴为 10 次计算得到的目标函数值。当种群数量 NP 为 100 和 600 时，计算结果的波动幅度明显大于种群数量 NP 为 300 和 500 时的结果。算法以增加随机性为代价，获得了更强的搜索能力。根据表 3-7 中最后一列数据可知，当种群数量增加时，程序的运行时间显著增加，因此在实际计算中，种群数量的取值不宜过大。因此若想在短时间内获得更准确的最优解，可以将种群个数设置为一个较小的值。

（2）蜜源开采次数 *limit*

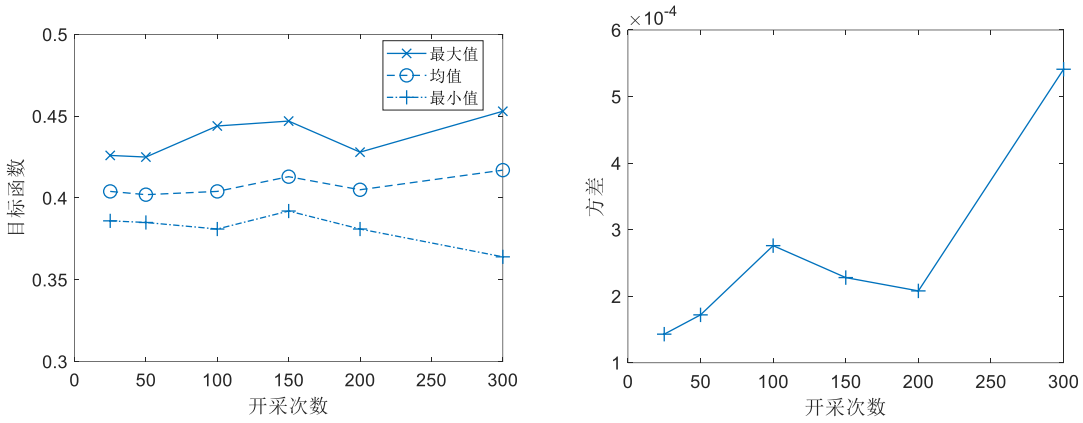
接下来研究蜜源开采次数的影响。根据上述结论，设置蜜蜂的种群数量 NP 为 100，其他仿真参数与上节均相同。分别对相同初始条件的程序运行 10 次，得到在对应初始条件下的目标函数值，并统计 10 次结果中的最大值，最小值，均值和方差，以及平均运行时间。具体结果如表 3-9 所示：

表 3-9 不同开采次数对计算结果的影响

Fig. 3-9 The influence of different mining times on the calculation results

开采次数	最大值	最小值	均值	方差	平均运行时间（s）
25	0.426	0.386	0.404	1.43×10^{-4}	119
50	0.425	0.385	0.402	1.72×10^{-4}	125
100	0.444	0.381	0.404	2.76×10^{-4}	126
150	0.447	0.392	0.413	2.28×10^{-4}	95
200	0.428	0.381	0.405	2.08×10^{-4}	81
300	0.453	0.364	0.417	5.41×10^{-4}	57

中国知网 https://www.cnki.net



（a）最值和均值的变化趋势　　（b）方差的变化趋势

图 3-15 不同指标随开采次数的变化趋势

Fig. 3-15 Variation trends of different indicators with mining times

如图 3-15（a）所示，当开采次数较小时（例如为 25 和 50），最小目标函数值较大，且结合图 3-15（b）可知对应的方差较小，因此 10 次计算的结果波动较小，此时算法的搜索能力不足；当开采次数较大时（300），算法的搜索能力得到增强，同时波动幅度增大。图 3-16 中展示了根据几种不同开采次数进行 10 次试验得到的结果。

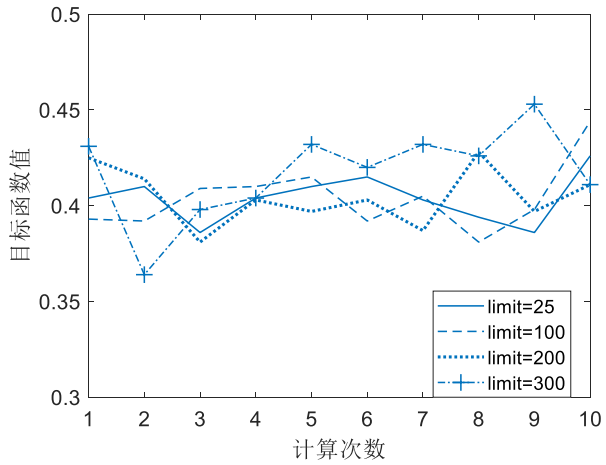


图 3-16 不同开采次数下计算得到的目标函数值

Fig. 3-16 Objective function value calculated under different mining times

如图 3-16 所示，横轴为计算次数，纵轴为 10 次计算得到的目标函数值。当开采次数为 300 时，虽然在第 2 次求出的目标函数值最小，但在 10 次试验中，大部分的结果均大于其他开采次数计算得到的结果，计算结果的波动幅度较大，在实际

中国知网 https://www.cnki.net

求解过程中，可能需要重复多次实验才能求出更好的解。而当开采次数设置为 100 或 200 时，可以实现求解精度与随机性的平衡，既能够保证解的质量，同时结果的稳定性也较强。根据以上结果以及对结果的相关分析可知，在设置开采次数时，取值不可过小。若需要满足算法的探索性能，则开采次数可以适当增大。

3.4 本章小结

本章介绍了使用 ABC 算法对列车驾驶曲线进行优化的方法。首先根据列车运行优化问题的特点，结合 ABC 算法求解优化问题的步骤，设计了初始解的生成算法，接下来对区间进行离散化，将原列车运行优化问题转化为 ABC 算法可以求解的标准形式，对优化问题中的约束条件使用惩罚函数进行处理，之后分别按照时间和位移分段，结合实际线路和车辆数据进行仿真验证，同时通过改变目标函数中不同优化目标的权重检验了算法的有效性。仿真结果表明，ABC 算法能够通过寻找列车的最优工况转换点，进而求出列车的最优驾驶曲线。最后本章对算法中涉及到的两个重要参数进行分析，通过控制变量法研究参数对计算结果和算法运行情况的影响，给出了参数设置的建议。

中国知网 https://www.cnki.net

4. 基于混合整数线性规划的重载列车驾驶曲线优化方法

混合整数线性规划（Mixed Integer Linear Programming，MILP）方法可以通过分支界定法（Branch and Bound，B&B）搜索到最优解。在求解过程上，与其他方法相比，使用 MILP 方法可以直接调用已有的求解器进行求解，但在求解之前需要将问题模型和约束条件线性化。对非线性条件的线性拟合精度将决定最优解的可靠性。使用 MILP 方法求解列车的最优驾驶曲线时，应首先将列车运动学模型和约束条件全部线性化，之后在 Cplex 中调用 YALMIP 求解器直接进行求解。本章首先介绍 MILP 方法及求解 MILP 方法常用的分支界定法，然后研究将列车模型和约束条件线性化的方法，最后通过仿真结果验证 MILP 方法的有效性。

4.1 MILP 模型与分支界定法简介

4.1.1 MILP 模型与应用

设优化问题如下所示：

$$\begin{aligned} &\min f(x_i) \\ &s.t\ h_j(x)=0 \quad j=1, 2, \ldots, m \\ &g_k(x)\le 0 \qquad k=1,\ 2,\ \ldots,\ n \\ &x_i \in \mathrm{R} \qquad i=1, 2, \ldots, l \end{aligned} \tag{4-1}$$

其中 $f(x_i)$是目标函数，h_j，g_k 分别表示等式约束和不等式约束，x_i 为决策变量。若目标函数和约束条件均为线性的，决策变量 x_i 中既有连续变量，又有整数变量，则称该问题为 MILP 问题。

考虑到 MILP 模型可以通过调用已有的求解工具进行求解，并且具有较高的计算精度，因此 MILP 模型广泛应用于求解优化问题，例如任务指派问题，旅行商问题和 0-1 规划问题等。在已有研究中，卢艺等将 MILP 模型应用于求解抽水蓄能机组的组合运行问题，能够获得较高的计算精度和运算速度[86]；李大东等使用 MILP 方法对无人机运行进行建模，将单无人机的避障运行和多无人机的防撞约束使用 MILP 模型进行描述，使用 ILOG CPLEX 软件进行仿真，仿真结果证明对于单无人机系统，设计的算法可以有效实现不同条件下的无人机路径寻优及避障[87]；对于多无人机系统可以很好地处理任务分配问题。岳荣刚等基于 City-Climber 动力学模型，使用 MILP 方法研究了爬壁机器人的路径规划问题[88]。首先对 City-Climber

中国知网 https://www.cnki.net

动力学模型中的 3 个数学模型进行线性化，之后基于 MILP 方法建立了优化问题的表达式并进行仿真验证。仿真结果证明设计的算法能够完成避障和路径规划。

在列车运行优化问题中，MILP 方法广泛应用于列车时刻表（运行图）的优化。Kang 等研究了城市轨道交通运输中末班车时刻表优化以及与公交车接驳的问题。文中将原始优化问题分解为两个较小的 MILP 问题，最小化末班地铁乘客乘坐公交车的等待时间，该方法的有效性通过应用于维也纳地铁系统得到的结果而得以验证[89]。Wang 等提出了一种综合模型，对列车时刻表和周转计划同时进行优化。该模型涉及列车服务，周转操作，进/出库操作以及可用列车的数量。文中将优化模型转化为 MILP 问题并通过亦庄线实际数据进行验证，证明了设计算法的有效性[90]。针对路网中列车的实时交通管理，Luan 等使用混合整数非线性规划（Mixed Integer Non-linear Programming, MINLP）和混合整数线性规划（MILP）方法研究进行研究。为了提出综合问题，文中首先提出一个 MINLP 问题，然后通过使用分段仿射函数逼近非线性项来重新构造该 MINLP 问题，从而产生 MILP 问题。文中使用来自荷兰铁路网的数据进行了仿真研究，根据仿真结果，MILP 方法在规定的计算时间内能够获得最佳的整体性能[91]。MILP 方法也可用于单列车运行优化问题。Lai 等使用 MILP 方法，针对中低速磁悬浮列车的节能优化运行问题进行建模，之后通过实际数据进行仿真验证，证明了求解方法的有效性[92]。

以上使用 MILP 方法求解列车运行优化问题中，研究对象均为城轨列车等普通动车组列车。动车组列车装备了 ECP 制动系统，与重载列车装备的空气制动相比，ECP 系统所需的充风时间大大减少，因此在计算过程中无需考虑充风时间的约束。此外重载列车的运行环境更为复杂，列车长度更长，总质量更大，因此相比于针对动车组列车的优化问题，针对重载列车的优化问题中需要考虑更多的约束条件。本章剩余章节将介绍使用 MILP 方法求解重载列车的优化运行问题的方法，并进行仿真验证。

4.1.2 分支界定法

可以证明，MILP 问题必存在最优解[93]。当优化问题的变量数目较小时，可以直接通过穷举的方法进行求解；但是当优化问题的规模很大时，可行解数量很多，使用穷举法不可行，此时可以通过检查部分可行解来确定最优解。其中最常用的一种方法是分支界定法。

分支界定法的基本思想是使用“分而治之”的方法解决优化问题。将原问题分解为多个线性规划问题，在求解的过程中实时追踪原问题的上界（最优可行解）和下界（最优线性松弛解）。分支界定法广泛应用于求解整数规划问题，其基本步

中国知网 https://www.cnki.net

骤如算法 4.1 所示：

算法 4.1 分支界定法

1. 将原整数规划问题转化为松弛问题，即取消 x_i 只能取整数的限制，则有

   1.1 若松弛问题无可行解，则原问题无可行解；

   1.2 若松弛问题有最优解，且满足取得最优解时 x_i 全为整数，则该最优解即为原问题的最优解；

   1.3 若松弛问题有最优解，但取得最优解时 x_i 不全为整数，设松弛问题的最优解为 X^0，进行下一步

2. 定界：设原问题的目标函数最优值为 f_{opt}，取下界为某个整数可行解对应的目标函数值 f_l，上界为 X^0，则有 $f \leq f_{opt} \leq X^0$，

3. 分枝：在 X^0 中任选一个非整数的变量 X_r，构造两个约束条件：

$$X_r \leq [X_r]，X_r \geq [X_r]+1$$

   将这两个约束条件加入到原优化问题中，记形成的新优化问题分别为优化问题 1 和 2，解这两个问题的松弛问题。

4. 修改上下界：上界：各分枝问题中目标函数最大值；下界：已符合整数条件的分枝问题中，目标函数的最大值。

5.比较与剪枝：各分枝的目标函数值中，若有小于 f_l 的，则剪去此枝，否则继续分枝。

6.若上下界之间的差 Gap 小于阈值，则停止运算，否则返回步骤 2。

在实际研究中，通常使用已有的优化求解引擎，可以有效提高运算效率。由于在求解 MILP 问题时，可以借助于已有工具而不必重新设计算法，因此 MILP 模型广泛应用于求解优化问题，例如最优路径、资源分配、时刻表优化等。对于 MILP 问题的求解，最常使用的引擎是 CPLEX。CPLEX 综合了多种算法的优点，可以有效求解多变量的混合整数线性规划问题[94]。由于 CPLEX 可求解的优化问题是线性的，因此在求解之前，应先将已有的列车动力学模型和所有的约束条件线性化。

4.2 算法设计

4.2.1 决策变量与优化目标

1）决策变量

合理选择决策变量，能够显著提高使用 MILP 方法求解优化问题的效率。使用 MILP 方法求解列车运行优化问题时，可以将列车的速度 v 或列车单位质量的动能

中国知网 https://www.cnki.net

$\widetilde{E_k}$视为决策变量[95]。单位质量的动能$\widetilde{E_k}$定义为：

$$\widetilde{E_k}=0.5v^2 \tag{4-2}$$

在使用 MILP 方法求解列车运行优化问题时，使用单位质量的动能$\widetilde{E_k}$取代列车速度 v 作为决策变量，可以消除部分非线性条件的影响。例如根据公式（2-19）计算列车运行阻力时，利用单位质量的动能，可以将（2-19）改写为：

$$f_r=m\left(R_1+a_t\widetilde{E_k}\right) \tag{4-3}$$

其中R_1和a_t在每个决策时刻均视为常数。与（2-19）相比，可以消除二次方项带来的影响，同时满足精度要求。

在已有研究中，使用单位质量的动能$\widetilde{E_k}$作为决策变量的研究对象为动车组列车，涉及到的约束条件均可使用列车当前位置或速度描述，因此使用$\widetilde{E_k}$作为决策变量能够对原问题进行简化。与动车组列车不同，在计算重载列车的控制量时，需要单独考虑空气制动力的施加情况。当重载列车进行空气制动缓解时，必须满足充风时间的约束条件，因此约束条件中必须考虑列车的运行时间。若选用$\widetilde{E_k}$作为决策变量，则充风时间的约束条件难以表示。考虑到以上区别，并且结合本研究中提出的重载列车运行优化问题的特点，本章选取列车速度 v 作为决策变量，列车当前状态由当前运行时间 t 和列车速度 v 组成的有序数对（v, t）表示。

2）优化目标

当状态变量由当前的运行时分和列车速度组成时，根据 2.1 节中的描述，优化目标设定为最小化该区间内的空气制动时间，同时最大化列车的运行距离。即优化目标根据公式（2-7）构建。

4.2.2 转化规则

在对列车动力学模型以及约束条件进行线性化之前，首先根据文献[93]，给出以下适用于不等式条件转化的规则：

设关于仿射函数$f(x)$的不等式为$k \le f(x) \le K$，给出以下条件：

$$f(x) \le 0 \Leftrightarrow \delta = 1 \tag{4-4}$$

$$\begin{cases} f(x) \le K(1-\delta) \\ f(x) \ge \varepsilon + (k-\varepsilon)\delta \end{cases} \tag{4-5}$$

其中 δ 为逻辑变量，取值为 0 或 1；ε 为一个很小的正数。（4-4）和（4-5）的对应关系是：当（4-4）成立时，（4-5）成立。

两个逻辑变量 δ_1，δ_2 的乘积可以表示为：

$$\begin{cases} -\delta_1+\delta_2 \le 0 \\ -\delta_1+\delta_3 \le 0 \\ \delta_1+\delta_2-\delta_3 \le 1 \end{cases} \tag{4-6}$$

中国知网 https://www.cnki.net

其中 $\delta_3=\delta_1\delta_2$。进一步得到仿射函数 $f(x)$与逻辑变量 δ 的乘积 $z=\delta f(x)$可以表示为：

$$\begin{cases} z \le K\delta \\ z \ge k\delta \\ z \le f(x) - k(1-\delta) \\ z \ge f(x) - K(1-\delta) \end{cases} \tag{4-7}$$

4.2.3 优化模型的转化

根据优化模型的特点，对模型的转化大致分为两个部分，分别是动力学模型和约束条件，下面分别介绍如下：

（1）动力学模型

在区间$[t_i, t_{i+1}]$内，列车动力学方程（2-19）可以改写为：

$$\frac{dv(t_i)}{dt_i} = \frac{u_i(v) + f_{aero_i}(t) + f_{p_i}(v,t)}{M} \tag{4-8}$$

其中$u_i(v)$，$f_{aero_i}(t)$分别表示在第 i 个区间内的牵引/动力制动力，空气制动力；$f_{p_i}(v,t)$表示在第 i 个区间内基本阻力，坡道阻力与曲线阻力的和，计算公式如下：

$$f_{p_i}(v,t) = f_r(v) + f_g(v,t) + f_c(v,t) \tag{4-9}$$

公式（4-7）中，$f_g(v,t)$和$f_c(v,t)$仅与列车当前所处的位置相关，因此$f_g(v,t)$和$f_c(v,t)$可以用第 i 个区间起点处的公里标表示，并且在该区间内为一定值，则$f_g(v,t)$和$f_c(v,t)$可以改写为：

$$f_g(v,t) = g_{s_i} \tag{4-10}$$

$$f_c(v,t) = c_{s_i} \tag{4-11}$$

其中g_{s_i}，c_{s_i}分别表示列车在第 i 个区间内对应的坡道阻力和曲线阻力，且g_{s_i}，c_{s_i}均为常数。

根据公式（2-12），基本阻力$f_r(v)$与速度 v 的对应关系如图 4-1 所示：

中国知网 https://www.cnki.net

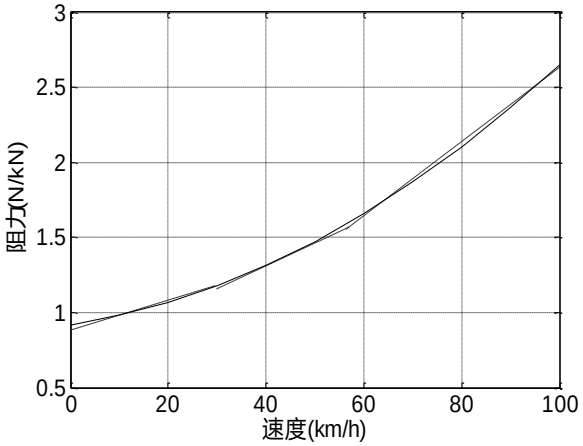


图 4-1 基本阻力与速度的关系

Fig. 4-1 Relationship between basic resistance and train velocity

假设将图 4-1 所示的曲线用两段线性函数进行拟合，则基本阻力与速度的关系可以表示为：

$$f_r(v)=\begin{cases}k_1v+b_1 & 0<v\le v_{r1}\\ k_2v+b_2 & v>v_{r1}\end{cases} \tag{4-12}$$

其中 v_{r1} 为分段点处的速度，取值可根据图 4-1 中的具体数值确定。k_1，k_2，b_1 ，b_2 均为比例系数，当 v_{r1} 的值确定后可以使用线性拟合方法确定。

根据图 2-1 所示的牵引特性曲线，列车的最大牵引力 u_{maxt} 为非线性函数。根据 4.1 中介绍的方法，非线性函数 y 可以通过分段仿射（piecewise affine, PWA）函数在区间[x_{min}，x_{max}]上进行线性拟合，因此最大牵引力可以转化为如下的 PWA 函数的形式：

$$u_{max\,t}(v)=\begin{cases}a_{t1}v+b_{t1} & 0\le v\le v_{t1}\\ a_{t2}v+b_{t2} & v_{t1}<v\le v_{t2}\\ a_{t3}v+b_{t3} & v\ge v_{t2}\end{cases} \tag{4-13}$$

其中分段处的速度值v_{t1}，v_{t2}可以根据图 2-1 确定。

u_{maxb} 为列车的最大牵引制动力，根据图 2-2 所示的制动特性曲线，u_{maxb} 为标准的分段仿射函数。结合图 2-2，则有：

$$u_{max\,b}(v)=\begin{cases}a_{b1}v+b_{b1} & 0\le v\le v_{b1}\\ a_{b2}v+b_{b2} & v_{b1}<v\le v_{b2}\\ a_{b3}v+b_{b3} & v\ge v_{b2}\end{cases} \tag{4-14}$$

分段处的速度值v_{b1}，v_{b2}可以根据图 2-2 确定。

a_{t1}-a_{t3}, b_{t1}-b_{t3}; a_{b1}-a_{b3}, b_{b1}-b_{b3} 是关于函数（4-13）和（4-14）的系数，当分段处的速度值v_{t1}，v_{t2}以及v_{b1}，v_{b2}确定后，可以通过线性拟合方法确定。

在 MILP 模型中，函数（4-13）和（4-14）应通过引入逻辑变量进一步转化为更为紧凑的形式。根据文献[20]中的方法，以函数（4-13）为例，引入逻辑变量 δ_1，

中国知网 https://www.cnki.net

δ_2，定义：

$$v \le v_{t1} \Leftrightarrow \delta_1=1,$$
$$v \le v_{t2} \Leftrightarrow \delta_2=1.$$

则函数（4-13）可以改写为：

$$u_{maxt}(v)= \delta_1\delta_2(a_{t1}v+b_{t1})+(1-\delta_1)\delta_2(a_{t2}v+b_{t2})+ (1-\delta_1)(1-\delta_2)(a_{t3}v+b_{t3}) \tag{4-15}$$

根据（4-4）-（4-7），通过引入逻辑变量$\delta_3 = \delta_1\delta_2$，以及辅助变量 $z_1=\delta_1 v, z_2= \delta_2 v$ 和 $z_3= \delta_3 v$，函数（4-14）可以改写为如下带有逻辑变量的矩阵形式：

$$u_{maxt}(v)=[-a_{t3}, a_{t2}-a_{t3},a_{t1}-a_{t2}+a_{t3}][z_1, z_2,z_3]^T+ [-b_{t3}, b_{t2}-b_{t3},b_{t1}-b_{t2}+b_{t3}][\delta_1, \delta_2,\delta_3]^T+a_{t3}v+b_{t3} \tag{4-16}$$

使用相同的方法，列车的最大电制动力u_{maxb}可以表示为：

$$u_{maxb}(v)=[-a_{b3}, a_{b2}-a_{b3},a_{b1}-a_{b2}+a_{b3}][z_4, z_5,z_6]^T+ [-b_{b3}, b_{b2}-b_{b3},b_{b1}-b_{b2}+b_{b3}][\delta_4, \delta_5,\delta_6]^T+a_{b3}v+b_{b3} \tag{4-17}$$

其中 $\delta_6= \delta_5\delta_4$，$z_4=\delta_4 v$，$z_5= \delta_5 v$ ，$z_6= \delta_6 v$。

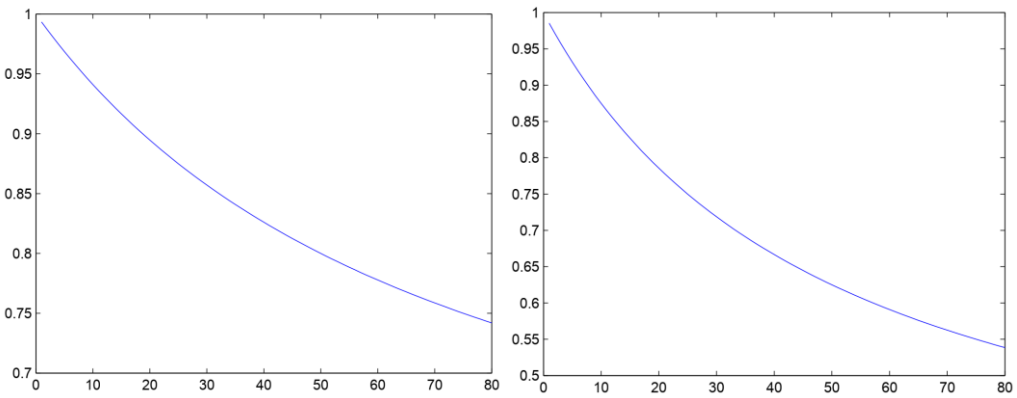
根据列车空气制动力的计算公式，列车空气制动力由以下两个公式共同决定：

$$\varphi_1=\frac{K_i+200}{4K_i+200} \tag{4-18}$$

$$\varphi_2=\frac{v_i+150}{2v_i+150} \tag{4-19}$$

以上关于φ_1和φ_2的计算公式与不同的变量相关，且均为非线性公式。在实际计算过程中，结合φ_1和φ_2的变化趋势以及相关变量的取值特点，可以将φ_1和φ_2设定为常数参与计算，具体方法如下：

1. 首先给出φ_1和φ_2的变化趋势。φ_1和φ_2的变化趋势如图 4-2 所示：



(a)φ_1随 K_i 的变化趋势　　(b)φ_2随 v_i 的变化趋势

图 4-2 φ_1和φ_2的变化趋势

Fig. 4.2 The trend of $\varphi_1$and φ_2

中国知网 https://www.cnki.net

2.结合变量的取值特点，确定φ_1和φ_2的值。

根据列车空气制动力的计算公式可知，K_i 的取值仅与制动缸压力$P_B^i(t)$相关，且与制动缸压力$P_B^i(t)$成正比。当列车进行空气制动时，制动缸压力会在短时间内由 0 上升至最大值 $P_{\max}$ 并保持恒定，直到空气制动开始缓解。因此在计算 K_i 时令制动缸压力$P_B^i(t)=P_{\max}$。当制动缸压力取最大值时，K_i=37.8，代入到公式（4-18）可得此时φ_1=0.68。

当列车在长大下坡区段运行时，列车最低缓解速度为 40km/h，最高速度不超过 80km/h，因此列车在长大下坡区间运行时的速度范围是 40-80km/h。结合图 4-2（b），当列车速度范围在 40-80km/h 时，φ_2的取值范围是[0.56，0.83]。计算过程中φ_2取平均值 0.70。

综合以上讨论，在计算过程中，$\varphi_1 = 0.68$，$\varphi_2 = 0.70$。

根据 2.2.1 节中的模型可得，空气制动的建立和缓解需要一个过程来实现。为了描述这个过程，本章中引入逻辑变量 b_i 用于描述在第 i 个区间内空气制动的情况。b_i 的定义如下（i=1, 2, … , n）：

1）b_i=0 ⇔ 空气制动力未使用

2）b_i=1 ⇔ 空气制动力已使用

制动和缓解的过程可以通过 b_i 的变化来描述。若 b_i=0，b_{i+1}=1，则表示列车前一阶段无空气制动力，后一阶段有空气制动力，即制动建立过程，同理可得若 b_i=1，b_{i+1}=0，则表示缓解过程。因此制动和缓解的表达式可以写为：

1）制动：b_{i+1}-b_i=1；

2）缓解：b_i-b_{i+1}=1；

结合列车空气制动力的计算公式，在本章中，列车空气制动力表示为：

$$F_{\text{pb}}=b_i f_{\text{pb}} \tag{4-20}$$

f_{pb}与第二章中空气制动力的计算公式相同。

（2）约束条件

在 MILP 模型中，约束条件需要按如下形式进行描述：

$$\begin{cases} A_1 x + B_1 y = C_1 \\ A_2 x + B_2 y \le C_1 \end{cases} \tag{4-21}$$

其中 A_i，B_i 和 C_i 均表示参数矩阵（i=1,2）。

关于 u_i 的约束条件可以转化为：

$$u_i(v) \le P_1 z + Q_1 \delta + R_1 v_x \tag{4-22}$$

$$u_i(v) \ge P_2 z + Q_2 \delta + R_2 v_x \tag{4-23}$$

其中：

$$P_1=[-a_{t3} \quad a_{t2}-a_{t3} \quad a_{t1}-a_{t2}+a_{t3}]$$

中国知网 https://www.cnki.net

$$P_2=[-a_{b3} \quad a_{b2}-a_{b3} \quad a_{b1}-a_{b2}+a_{b3}]$$

$$Q_1=[-b_{t3} \quad b_{t2}-b_{t3} \quad b_{t1}-b_{t2}+b_{t3}]$$

$$Q_2=[-b_{b3} \quad b_{b2}-b_{b3} \quad b_{b1}-b_{b2}+b_{b3}]$$

$$R_1=\begin{bmatrix}a_{t3}\\ b_{t3}\end{bmatrix}, R_2=\begin{bmatrix}a_{b3}\\ b_{b3}\end{bmatrix}, v_x=\begin{bmatrix}v\\ 1\end{bmatrix}$$

列车运行速度应满足的约束条件为：

$$V_{min}\le V\le V_{max} \tag{4-24}$$

其中

$$V_{min}=[v_{1min} \quad v_{2min} \quad \cdots \quad v_{nmin}]$$
$$V_{max}=[v_{1max} \quad v_{2max} \quad \cdots \quad v_{nmax}]$$

v_{imin}，v_{imax}分别表示在第 i 个区间内的最低限速和最高限速（i=1,2, …, n）。

计算列车的缓解速度和缓解时间之前，均需要通过判断列车的工况是否发生转化。根据 4.2.2 节中的描述，当列车结束空气制动并进行缓解到列车开始进行下一次空气制动的过程，可以按照以下步骤使用逻辑变量 b_i 进行描述：

1）列车开始缓解 $\Leftrightarrow b_i-b_{i+1}=1$

2）充风过程 $\Leftrightarrow b_i=0$

3）进行下一次制动 $\Leftrightarrow b_{i+1}-b_i=1$

当列车进行缓解时，缓解时间表示为：

$$if \ \ b_i-b_{i+1}=1\Rightarrow t_r=\sum_{i=1}^{n_r} i\Delta t \tag{4-25}$$

最小缓解时间可以通过设置空气制动控制变量 b_i 表示，即在一个时间段内，b_i=0。因此关于缓解时间的约束条件可以写为：

$$if \ \ b_i-b_{i+1}=1\Rightarrow \sum_{i=1}^{n_r} b_i=0 \tag{4-26}$$

其中 $n_r=t_{release}/\Delta t$。

根据以上对缓解过程的描述，列车最低缓解速度的约束条件可以表示为：

$$if \ \ b_i-b_{i+1}=1\Rightarrow v_i\ge v_{release} \tag{4-27}$$

当以上转化工作全部完成后，即可调用已有的求解器（例如 Cplex）对该 MILP 问题进行求解。

4.3 仿真结果与分析

将 MILP 方法应用于重载列车运行优化问题的主要步骤如图 4-3 所示。

中国知网 https://www.cnki.net

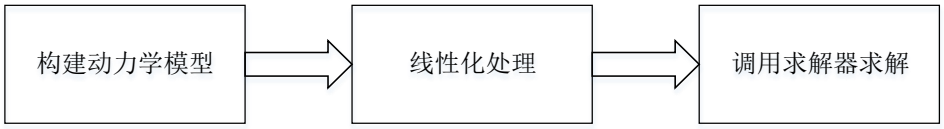
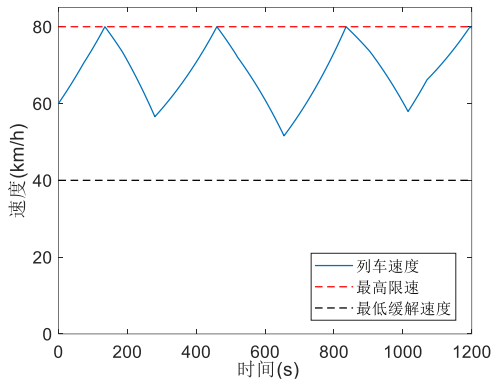


图 4-3 MILP 方法求解重载列车运行优化问题流程

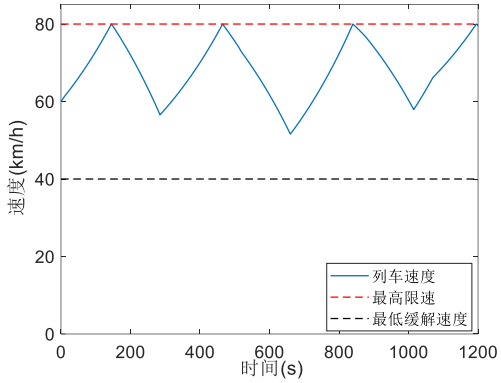
Fig. 4-3 The process for solving the heavy haul train's optimal operation problem by MILP method

本节剩余内容首先将通过改变目标函数中不同优化目标对应的权重来验证 MILP 方法的有效性，接下来分析离散化精度对优化效果以及优化性能的影响，最后将 MILP 方法与上一章中提出的 ABC 算法进行对比，比较两种算法的优化性能差异。本章仿真算例均在 Matlab 中使用 Cplex 12.0，并调用 Yalmip 工具箱进行仿真。在本章的仿真算例中，区间运行时分设置为 T=1200s，其余参数与 3.3.1 节中的设置相同。

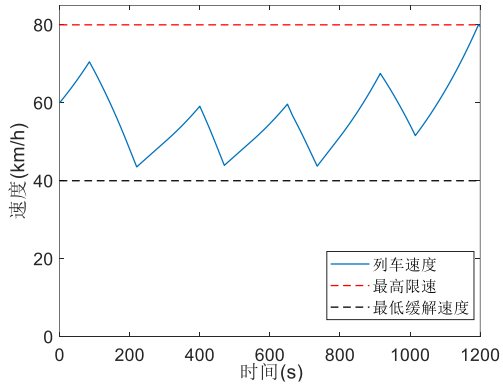
4.3.1 算法有效性验证



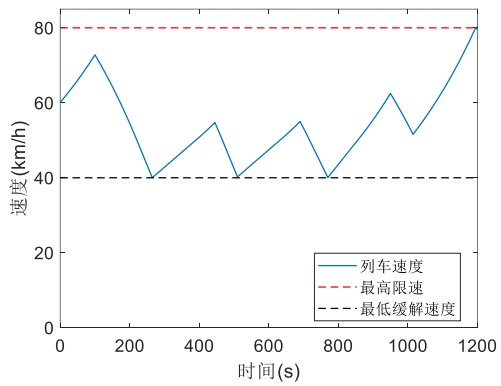
（a）λ_1=0，λ_2=1



（b）λ_1=0.2，λ_2=0.8

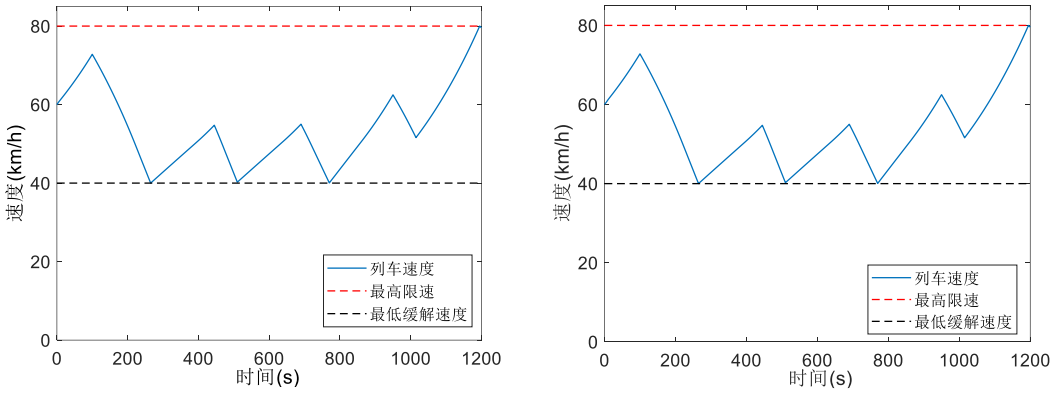


（c）λ_1=0.4，λ_2=0.6



（d）λ_1=0.6，λ_2=0.4

中国知网 https://www.cnki.net



（e）λ_1=0.8，λ_2=0.2　　（f）λ_1=1，λ_2=0

图 4-4 改变权重得到的列车速度曲线

Fig. 4-4 Speed profiles with different weight coefficients.

在 4.3.2 节中首先通过改变优化目标对应的权重，以验证算法的有效性。在仿真算例中，设置列车的初速度为 60km/h，得到的列车速度曲线如图 4-4 所示。

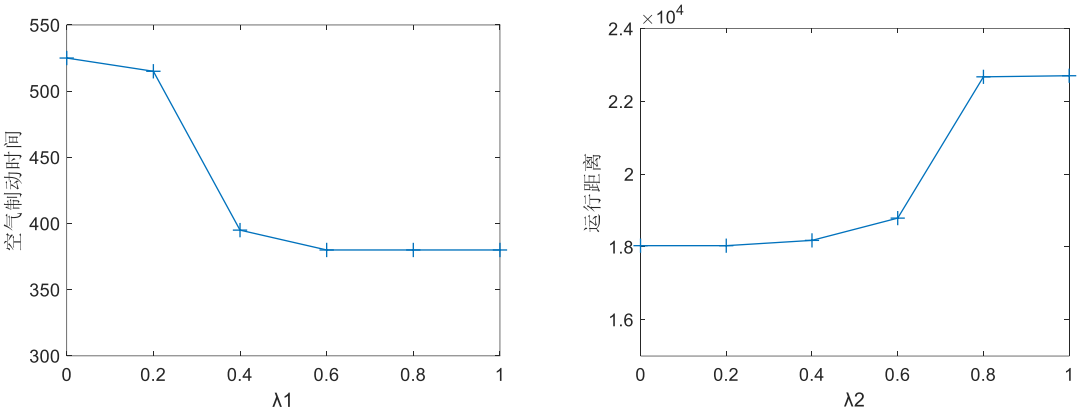
根据图 4-4 (a)-(b)可以看出，当 λ_1 的值较小，而对应的 λ_2 的值较大时，算法偏重于优化运行距离，因此当列车速度接近最高限速时才使用空气制动，且列车的平均速度维持在一个较高的值。将图 4-4 (c)-(d)中的结果与图 4-4 (a)-(b)中的结果作对比，可以看出随着空气制动时间对应的权重逐渐增加，运行距离对应的权重逐渐减小，算法逐渐偏向于优化空气制动时间，列车进行空气制动时的速度明显降低，且平均速度也明显低于图 4-4 (a)-(b)中的结果。算例中具体的仿真结果和不同优化指标随着权重的变化趋势分别如表 4-1 和图 4-5 所示。

表 4-1 4.3.1 节中算例的仿真结果

Table 4-1 Simulation results of case in section 4.3.1

λ_1	λ_2	空气制动时间（s）	运行距离（m）
0	1	525	22705
0.2	0.8	515	22675
0.4	0.6	395	18791
0.6	0.4	380	18179
0.8	0.2	380	18034
1	0	380	18034

中国知网 https://www.cnki.net



(a) 不同权重对应的空气制动时间的变化趋势 (b) 不同权重对应的运行距离的变化趋势

图 4-5 不同权重对应的优化指标的变化趋势

Fig. 4-5 The trend of the optimization indicators corresponding to different weights

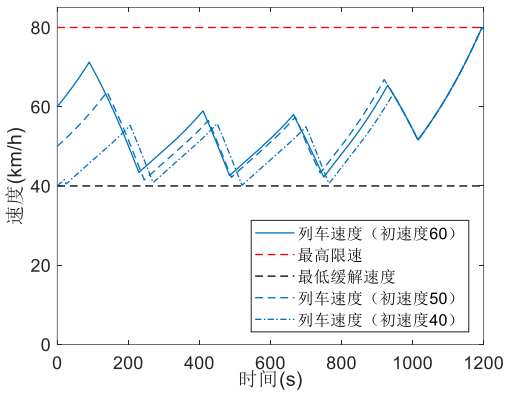
根据表 4-1 和图 4-5 中的结果可知，从整体变化趋势上看，当 λ_1 和 λ_2 的值分别逐渐增大时，对应的优化指标空气制动时间和运行距离逐渐趋近于最优值，因此可以证明所设计的算法是有效的。考虑到计算精度以及两种优化指标具有一定的关联性，对于每一项优化指标而言，当 λ_1 的值位于区间[0.2, 0.6]，对应的 λ_2 位于区间[0.4, 0.8]时，优化指标随权重的变化比较明显；而当 λ_1 和 λ_2 的值接近 0 或 1 时，两种不同的优化指标随权重基本不发生变化。

4.3.2 参数分析

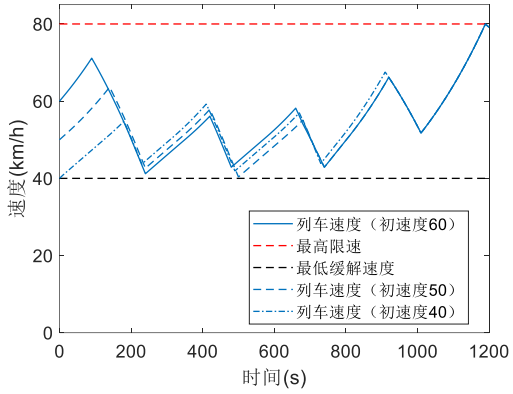
使用 MILP 方法求解优化问题时，离散化精度决定了结果的优劣，使用更高的精度能够获得更精确的最优解，但提高精度的同时也会使得算法的计算时间增大。本章所研究的问题中，离散化的精度由 Δt 决定，因此本节研究不同 Δt 对应的优化问题的解，以及求出这个解所需要的时间。

本节涉及的仿真算例中，λ_1 和 λ_2 的值均设置为 0.5，列车的初速度分别设置为 40km/h ，50km/h 和 60km/h，其他条件与 4.3.1 节中的算例相同。得到的列车速度曲线如图 4-6 所示：

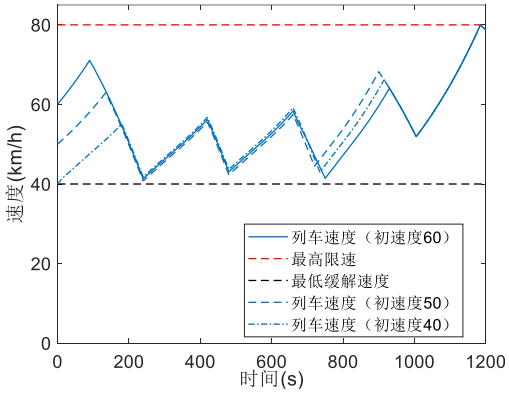
中国知网 https://www.cnki.net



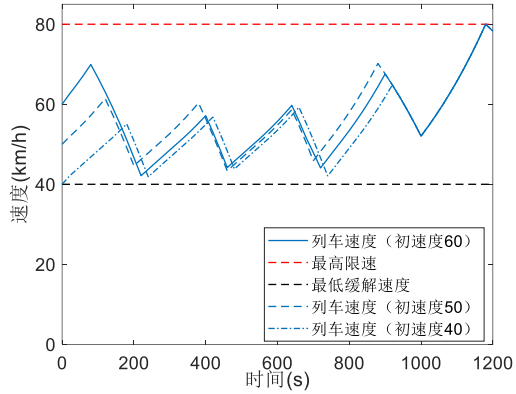
（a）Δt=5s



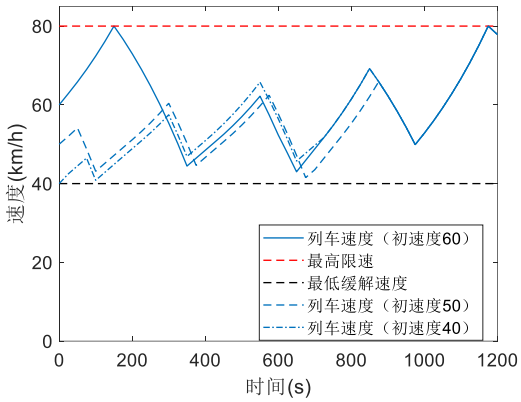
（b）Δt=10s



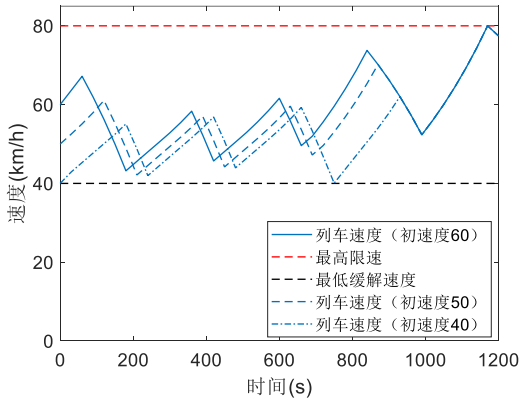
（c）Δt=15s



（d）Δt=20s



（e）Δt=25s



（f）Δt=30s

图 4-6 不同离散化精度得到的列车速度曲线

Fig. 4-6 Train speed curve obtained with different discretization accuracy

根据不同 Δt 计算得到的结果如表 4-2 所示。注意到表 4-2 中的最后一列，当 Δt=5 时与 Δt=10 相比，计算精度增加了一倍，决策阶段的数目也随之增加了一倍进而导致优化问题的规模急剧增大。由于 MILP 方法是基于分支界定法进行搜索，因此当优化问题的规模急剧增大时，算法的搜索时间也会明显增加。

中国知网 https://www.cnki.net

表 4-2 不同离散化精度得到的计算结果

Table 4-2 Calculation results obtained with different discretization accuracy

Δt（s）	初速度（km/h）	空气制动时间（s）	列车运行距离（m）	目标函数值	计算时间（s）
5	40	280	17140	-0.0880	1232
	50	340	18146	-0.0569	1125
	60	390	18569	-0.0232	503
10	40	300	17904	-0.0857	28
	50	340	18093	-0.0559	52
	60	390	18520	-0.0223	20
15	40	300	17849	-0.0847	7
	50	345	18287	-0.0554	5
	60	390	18429	-0.0206	5
20	40	300	17808	-0.0839	4
	50	360	18797	-0.0524	4
	60	400	18809	-0.0193	4
25	40	325	18562	-0.0772	3
	50	350	18371	-0.0528	3
	60	450	20067	-0.0131	3
30	40	300	17708	-0.0820	3
	50	360	18764	-0.0518	3
	60	420	19481	-0.0153	3

目标函数值随 Δt 的变化趋势如下图 4-7 所示：

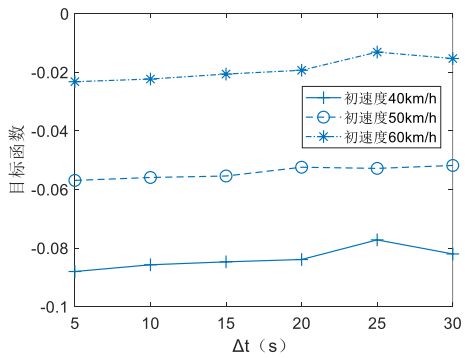


图 4-7 不同初速度下目标函数值随 Δt 的变化趋势

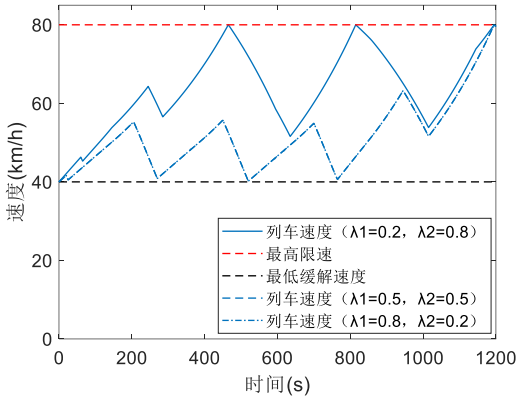
Fig. 4-7 The trend of the objective function value with Δt under different initial speeds

中国知网 https://www.cnki.net

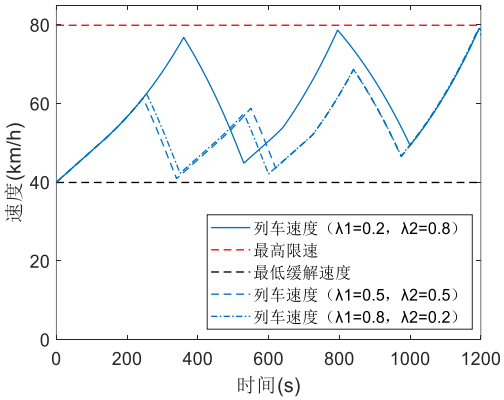
如图 4-7 所示，目标函数值随 Δt 的逐渐增大而增大。当 Δt 逐渐增大时，离散化的精度逐渐降低，因此算法求出的最优目标函数值的精确性逐渐降低，因此目标函数值逐渐增大。根据表 4-3 中对应的数据可知，当 Δt=25s 时计算得到的目标函数值不符合整体的变化趋势。在该仿真算例中，列车空气制动的缓解时间不等于 25 的整数倍，为满足约束条件，在使用 MILP 方法求解时进行了向上取整，从而影响了计算精度，使得求出的目标函数值与其他目标函数值的变化趋势不同。根据表中最后一列对计算时间的统计，在满足优化问题精度要求的前提下，可以通过适当减小离散精度，实现计算时间与计算精度的平衡。

4.3.3 优化方法对比

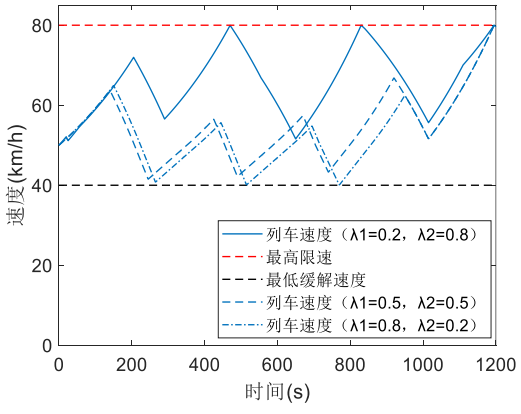
为比较两种基于数值的优化方法的优化效果，在本节中分别使用 MILP 方法和 ABC 算法对同一算例进行研究，并对结果进行分析。在仿真算例中，初速度分别设置为 40km/h，50km/h 和 60km/h，使用 MILP 方法和 ABC 算法进行仿真得到的仿真结果如图 4-8 所示。



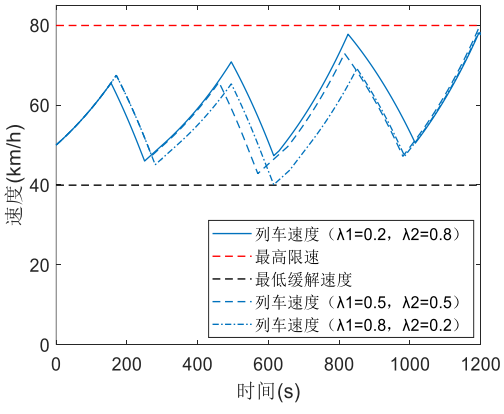
（a）初速度为 40km/h，MILP 方法



（b）初速度为 40km/h，ABC 算法

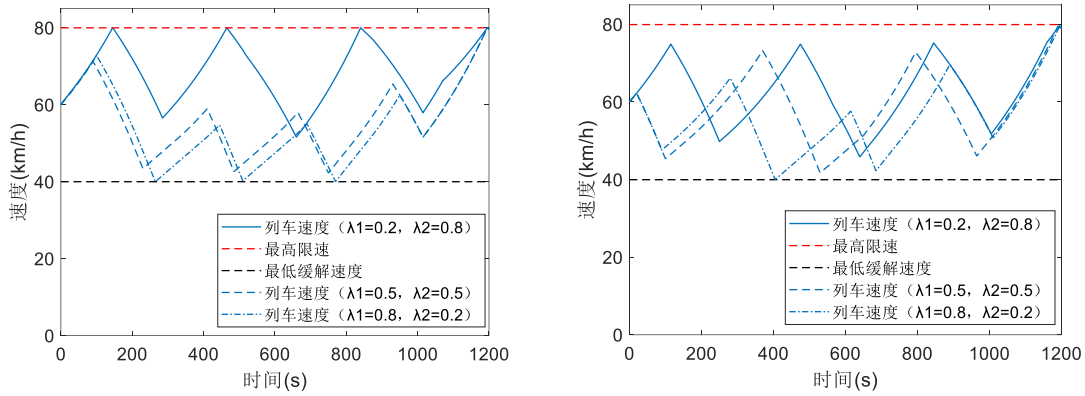


（c）初速度为 50km/h，MILP 方法



（d）初速度为 50km/h，ABC 算法

中国知网 https://www.cnki.net



（e）初速度为 60km/h，MILP 方法　　（f）初速度为 60km/h，ABC 算法

图 4-8 不同初速度情况下根据 MILP 方法和 ABC 算法得到的列车速度曲线

Fig. 4-8 Speed profiles with different initial speeds calculated by MILP method and ABC algorithm.

表 4-3 4.4.3 节中的仿真结果对比

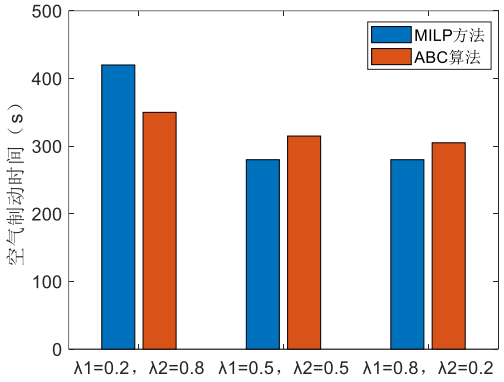
Table 4-3 The comparison of the simulation results in section 4.4.3

初速度（km/h）	优化方法	权重	空气制动时间（s）	列车运行距离（m）	目标函数值
40	MILP	λ_1=0.2，λ_2=0.8	420	21182	-0.496
		λ_1=0.5，λ_2=0.5	280	17140	-0.088
		λ_1=0.8，λ_2=0.2	280	17140	0.245
	ABC	λ_1=0.2，λ_2=0.8	350	19057	-0.455
		λ_1=0.5，λ_2=0.5	315	18220	-0.079
		λ_1=0.8，λ_2=0.2	305	18095	0.271
50	MILP	λ_1=0.2，λ_2=0.8	460	21902	-0.504
		λ_1=0.5，λ_2=0.5	340	18146	-0.057
		λ_1=0.8，λ_2=0.2	330	17670	0.308
	ABC	λ_1=0.2，λ_2=0.8	415	20190	-0.467
		λ_1=0.5，λ_2=0.5	375	19301	-0.049
		λ_1=0.8，λ_2=0.2	350	18595	0.327
60	MILP	λ_1=0.2，λ_2=0.8	515	22675	-0.509
		λ_1=0.5，λ_2=0.5	390	18569	-0.023
		λ_1=0.8，λ_2=0.2	380	18034	0.371
	ABC	λ_1=0.2，λ_2=0.8	475	21339	-0.482
		λ_1=0.5，λ_2=0.5	405	18942	-0.017
		λ_1=0.8，λ_2=0.2	395	18755	0.386

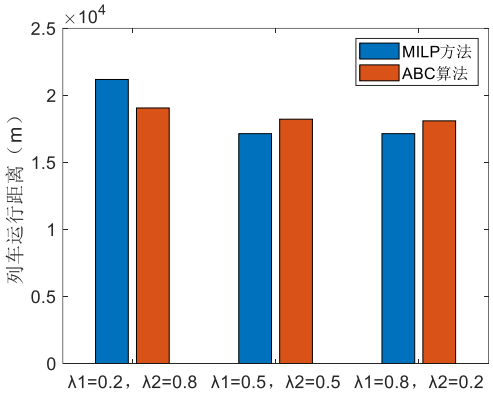
中国知网 https://www.cnki.net

图 4-8 中分别展示了 MILP 方法和 ABC 算法根据不同的初速度，以及不同的权重计算得到的速度曲线。对比在相同初始条件下使用两种方法求出的列车速度曲线可知，使用 MILP 方法求出的列车速度曲线随优化指标权重的变化更为明显。根据两种方法求出的具体仿真结果如表 4-3 中所示。

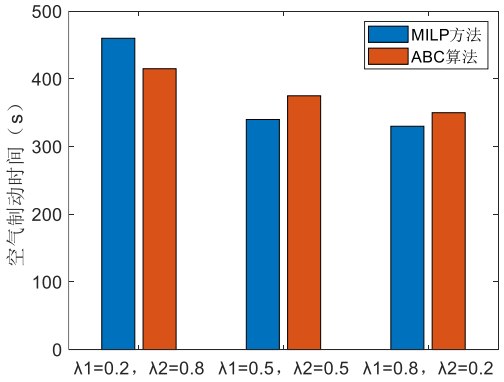
表 4-3 中分别对根据 MILP 方法和 ABC 算法计算得到的目标函数值 f_{obj}，空气制动时间 T_{air} 和运行距离 L_{dis} 进行比较。根据表中最后一列数据可知，当初速度和权重相同时，使用 MILP 方法计算得到的目标函数值 f_{obj} 始终小于使用 ABC 算法计算得到的目标函数值，因此使用 MILP 方法求出的结果更准确。下面分别通过比较两种优化方法在不同条件下计算得到的空气制动时间和列车运行距离，以进一步验证 MILP 方法的准确性。根据不同优化方法得到的不同优化指标的对比见图 4-9。



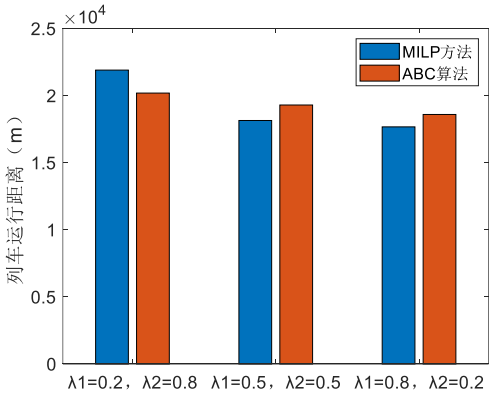
（a）空气制动时间，初速度 40km/h



（b）列车运行距离，初速度 40km/h

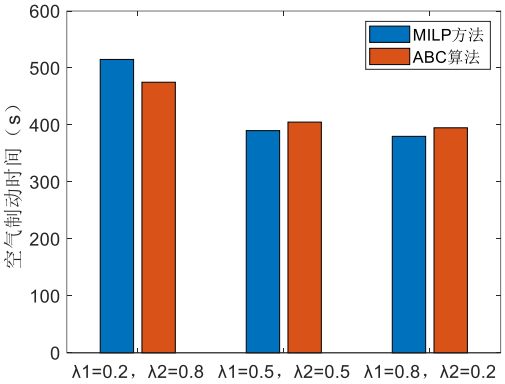


（c）空气制动时间，初速度 50km/h

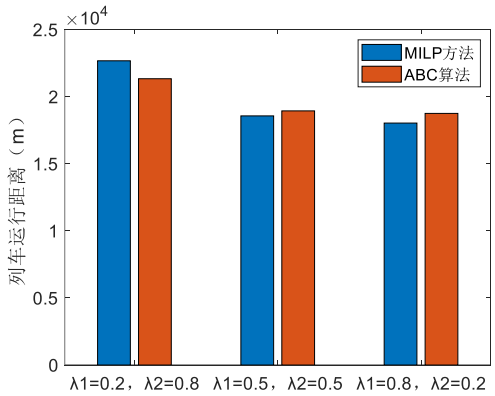


（d）列车运行距离，初速度 50km/h

中国知网 https://www.cnki.net



（e）空气制动时间，初速度 60km/h



（f）列车运行距离，初速度 60km/h

图 4-9 根据不同方法得到的不同优化指标对比

Fig. 4-9 Comparison of different optimization indicators obtained by different methods

图 4-9 中的每张子图均展示了使用 ABC 算法与 MILP 方法，得到的不同指标随权重的变化情况。与 ABC 算法相比，MILP 方法对不同优化指标的权重变化更加敏感，因此当权重发生变化时，MILP 方法能够更好地响应权重变化，从而使得求出的目标函数值更为精确。

4.4 本章小结

本章设计了一种基于 MILP 方法求解重载列车驾驶曲线优化问题的方法。在求解之前需要将问题转化为 MILP 问题，即所有的条件均为线性形式，因此本章提出了线性化方法，将重载列车驾驶曲线优化问题转化为 MILP 问题并求解。对于不同的约束条件，采用不同的方法进行线性化。例如使用分段仿射函数拟合牵引制动特性曲线，引入逻辑变量描述空气制动与缓解等。在仿真算例中，首先改变目标函数中不同优化目标对应的权重，证明了算法的有效性。接下来对 MILP 方法中离散化精度进行分析，比较了不同初始条件下，使用不同离散化精度计算得到的结果以及计算时间，结果证明在一定范围内降低离散化精度，对计算精确性影响较小，同时能大幅减少计算时间。最后对 MILP 方法和 ABC 算法计算得到的结果进行比较，仿真结果证明，与 ABC 算法相比，MILP 方法由于能够对解空间内的所有可行解进行遍历并逐渐搜索到当前条件下的最优解，因此计算精度更高，能够获得更好的优化效果。

中国知网 https://www.cnki.net

5. 基于近似动态规划的重载列车驾驶曲线优化方法

当重载列车在长大下坡区间运行时，机车乘务员会根据列车当前状态（列车速度，列车所处位置的坡度，列车当前工况等信息）对列车进行操纵。考虑到状态转移的过程中，列车当前状态仅与上一决策时刻的状态相关，因此重载列车在长大下坡区间的运行可以转化为马尔科夫决策过程（Markov Decision Process，MDP），从而使用动态规划进行求解。由于经典动态规划算法在求解过程中可能存在“维数灾难”的问题，本章采用了近似动态规划算法（Approximate Dynamic Programming, ADP），使用基函数法对值函数进行近似，进而求解出列车在长大下坡区段运行时的最优策略，同时获得列车的驾驶曲线。

5.1 ADP 基础理论

5.1.1 有限 MDP

MDP 是通过智能体与环境的交互学习实现目标的框架。能够进行决策和学习的本体称为智能体，能够与智能体相互作用，且在智能体之外的事物称为环境。在 MDP 中，智能体选择一个动作，之后环境对选择的动作产生响应，并转移到一个新的状态，在这个过程中，环境会产生一个奖励（假设目标是最大化某项指标）。智能体与环境的交互过程如图 5-1 所示[96]：

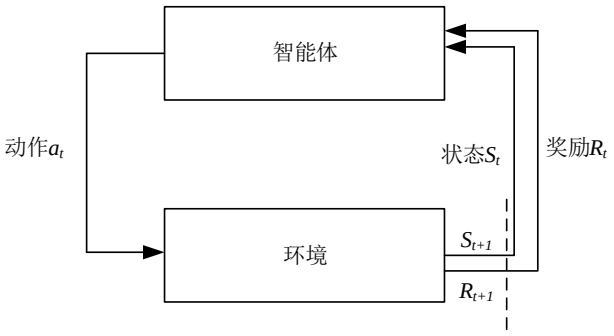


图 5-1 MDP 中智能体与环境的交互[96]

Fig. 5-1 The interaction between the agent and the environment in MDP[96]

使用 MDP 求解优化问题时，决策序列如下所示：

$$S_1, a_1, R_2, S_2, a_2, R_3, \ldots \tag{5-1}$$

在 MDP 中，每个状态 S_t 和的概率只与前一状态 $S_{t\text{-}1}$ 和动作 $a_{t\text{-}1}$ 相关，与更早

中国知网 https://www.cnki.net

的状态和动作均无关。在（5-1）中，若状态，动作和收益的个数均为有限的，则该决策过程称为有限 MDP。有限 MDP 是对序列决策的经典表达形式。

5.1.2 ADP 算法的基本思想

1957 年，Richard Bellman 提出了求解多阶段优化问题的方法，该方法为：找到一个策略 π，该策略能够将离散状态 $s(s\in S)$映射到动作 $a(a\in A)$，从而产生代价 $C(s, a)$。其中 S 为状态集，A 为动作集。系统状态 s 转移到新状态 s'的概率为 $p(s'|s, a)$。若定义智能体在状态 s 处的值为 $V(s)$，且优化问题为最小化某项指标，则有以下 Bellman 方程：

$$V(s)=\min_{a\in A}\left(C(s,a)+\gamma\sum_{s'\in S}p(s'|s,a)V(s')\right) \tag{5-2}$$

对于有限时间长度的决策问题，方程（5-2）可以改写成以下形式：

$$V_t(s_t)=\max_{a\in A}\left(C(s_t,a)+\gamma\sum_{s'\in S}p(s'|s_t,a)V_{t+1}(s')\right) \tag{5-3}$$

根据方程（5-3），可以将原先的多阶段决策问题转化为单步决策问题。在第 t 个决策时刻，选择此时的最优控制决策为：

$$a_t^*=\arg\max_{a\in A}\left(C(s_t,a)+\gamma\sum_{s'\in S}p(s'|s_t,a)V_{t+1}(s')\right) \tag{5-4}$$

根据方程（5-4）可知，每次求解最优控制决策时，需要对下一决策时刻所有可能的状态值函数进行比较，因此当系统状态数目增多时，DP 算法的计算量会有指数级的增长，导致在使用 DP 求解大规模优化问题时存在“维数灾难”的问题。如下图 5-2 所示[97]：

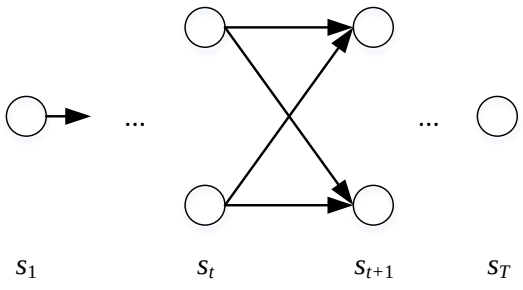


图 5-2 DP 寻优过程

Fig. 5-2 The optimization process of DP

中国知网 https://www.cnki.net

在图 5-2 中，假设智能体在每个状态 s_t 处，可选择的动作集合为 $A_t=[a_{t1},a_{t2}]$，每个决策时刻需考虑的状态数为 2。因此在这个决策过程中，可供使用的路径共有 2^T 条。在列车优化运行问题中，T 的取值一般比较大。当 T=100 时，可能的路径共有 $2^{100}\approx1.26\times10^{30}$ 条，远远超出了现有计算机的计算能力。

针对这个问题，Powell 提出了近似动态规划的方法，使用函数近似结构对值函数进行估计，避免对所有可能的状态值函数进行遍历，从而减少计算量。ADP 算法的关键即为找到合适的近似结构表示值函数。

5.1.3 值函数的近似方法

值函数的近似模型大致分为表格模型、参数模型和非参数模型三种，分别介绍如下[98]：

（1）表格模型

表格模型又叫表函数，用于存储每个离散状态 S_t 对应的值函数的估计值$\bar{V}_t(S_t)$。在每个决策时刻，首先确定该决策时刻对应的状态，之后根据表格中存储的这个状态对应的值函数的近似值，结合方程（5-3）即可计算出该决策时刻对应的最优决策。在实际求解过程中，表格模型具有结构简单、易构建的特点，但当优化问题的决策阶段较多时，将导致状态变量的数目不断增大，从而使得表格的容量迅速增大。在更新值函数时，需要遍历所有的状态，因此会导致算法的计算时间过长，同时也不易收敛。

（2）参数模型

参数模型将值函数使用基函数进行近似表示，如下所示：

$$\bar{V}(s|\theta)=\sum_{f\in F}\theta_f\emptyset_f(s) \tag{5-5}$$

在方程（5-5）中，$\emptyset_f(S)$为基函数，f 为基函数中的不同特征，θ_f为不同特征对应的参数。基函数的形式有多项式基函数，傅里叶基函数等。

1）多项式基函数

假设状态空间是二维的，即每个状态 s 对应的两个分量分别为 s_1, s_2；则基函数可以构造为 s_1, s_2 的组合，例如

$$\emptyset_f(s)=[1,s_1,s_2,s_1s_2]^T \tag{5-6}$$

其中$1,s_1,s_2,s_1s_2$为基函数$\emptyset_f(S)$对应的不同特征。当使用（5-6）所示的基函数表示近似值函数时，根据（5-5），近似值函数可以写成：

中国知网 https://www.cnki.net

$$\overline{V}(s|\theta) = \theta_1+\theta_2 s_1+\theta_3 s_2+\theta_4 s_1 s_2 \tag{5-7}$$

多项式基函数是一类最简单的基函数。在构造多项式基函数时，特征选取应结合具体的优化问题考虑。若需要近似复杂函数，通常采用增加基函数的阶数实现。

2）傅里叶基函数

假设函数 $f(x)$在区间$[x_1, x_2]$上可积，其中区间长度 $P=x_2-x_1$，则可以用三角函数形式的无穷级数表示 $f(x)$。$f(x)$的展开式可以表示为：

$$f(x)=\frac{a_0}{2}+\sum_{n=1}^{N}\left(a_n\cos\left(\frac{2\pi nx}{P}\right)+b_{\mathrm{n}}\sin\left(\frac{2\pi nx}{P}\right)\right) \tag{5-8}$$

其中：

$$\begin{cases} a_n=\dfrac{2}{P}\displaystyle\int_P f(x)\cos\left(\frac{2\pi nx}{P}\right)\mathrm{d}x \\ b_n=\dfrac{2}{P}\displaystyle\int_P f(x)\sin\left(\frac{2\pi nx}{P}\right)\mathrm{d}x \end{cases} \tag{5-9}$$

在（5-9）中，a_n，b_n为傅里叶系数，公式（5-8）为函数 $f(x)$的傅里叶展开式。

使用基函数逼近值函数时，需要对参数θ进行更新。求解最合适的参数θ等价于求解下面的最小化问题：

$$\min_{\theta}\frac{1}{2}(\overline{V}(s|\theta)-\hat{v})^2 \tag{5-10}$$

其中

$$\hat{v}=C(s_t,a_t)+\gamma\overline{V}(s_{t+1}) \tag{5-11}$$

接下来对（5-10）求梯度，可得参数θ的更新公式为：

$$\theta^n=\theta^{n-1}-\alpha_{n-1}\left(\overline{V}\left(s\middle|\theta^{n-1}\right)-\hat{v}^n\right)\nabla_\theta\left(\overline{V}(s|\theta^n)\right) \tag{5-12}$$

根据（5-5），得：

$$\nabla_\theta\left(\overline{V}(s|\theta^n)\right) = \emptyset(s^n) \tag{5-13}$$

1）非参数模型

构造基函数和调整参数是使用参数模型时遇到的两大难点。为了避开这两大难点，可以使用非参数模型对值函数进行近似。非参数模型主要是通过使用观测值构建局部逼近函数，而不是依赖于类似参数模型中基函数等函数逼近的形式，因此非参数模型无需重新构造基函数和调整参数。

局部逼近函数的构造方法如下图 5-3 所示[99]：

中国知网 https://www.cnki.net

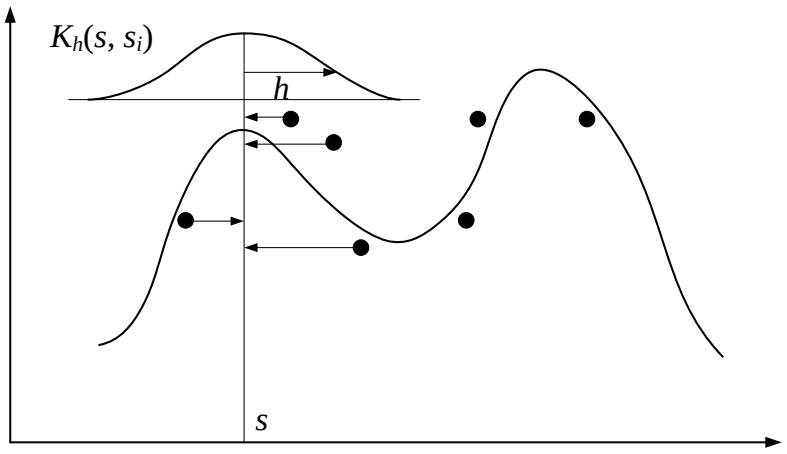


图 5-3 局部逼近函数的构造方法[99]

Fig. 5-3 Construction method of local approximation function[99]

如图 5-3 所示，黑色实心圆点表示采样点，下方曲线表示被逼近的函数，上方曲线表示需要构造的逼近函数，s 为对应的状态。要估计状态 s 处对应的值函数，首先需要进行多次采样得到观测值$\hat{v} = [\hat{v}^1, \hat{v}^2, \ldots, \hat{v}^n]$，接下来通过对局部观测值进行加权平均，进而得到该状态对应的值函数。计算公式如下：

$$\overline{V}(s)=\frac{\sum_{i=1}^{n} K_h(s,s^i)\hat{v}^i}{\sum_{i=1}^{n} K_h(s,s^i)} \tag{5-14}$$

其中$K_h(s,s^i)$为径向基函数，其表达式为：

$$K_h(s,s^i)=\exp\left[-\left(\frac{s-s^i}{h}\right)^2\right] \tag{5-15}$$

其中 h 表示抽样带宽，s^i 为每个抽样点对应的状态。

5.1.4 近似迭代算法

对值函数的逼近是近似动态规划算法的核心部分。基于值函数逼近的策略主要有两种，分别为近似值迭代和近似策略迭代。近似值迭代算法由于结构更为简单，因此相比近似策略迭代的应用更加广泛。但是近似策略迭代算法能够在使用线性模型去近似值函数时，保证算法的收敛性。

1）近似值迭代

近似值迭代的基本步骤如算法 5.1 所示。

2）近似策略迭代

近似策略迭代与近似值迭代的主要区别是，在策略估计循环的基础上，增加了

中国知网 https://www.cnki.net

一个外部循环对策略进行改进。近似策略迭代的基本步骤如算法 5.2 所示。

算法 5.1 近似值迭代

1. 初始化

   1.1 对于每个决策后状态S_t^a，设置初始值函数$\bar{V}_t^0(S_t^a)$，其中 t=[1,2,…,T]。

   1.2 设置迭代次数 n=1，最大迭代次数 N。

   1.3 设置初始状态S_1^a。

2. 选择抽样路径ω。

3. 对于 t=1,2,…,T，进行以下操作

   3.1 根据 ε-greedy 策略选择动作：智能体有 ε 的概率在动作集 A 中随机选择一个动作，有 1-ε 的概率根据以下公式选择动作：

$$\hat{v}_t^n=\arg\max_{a_t\in A_t}(C(S_t^n,a_t)+\gamma\bar{V}_t^{n-1}(S^{M,a}(S_t^n,a_t)))$$

   其中a_t^n是求解最大化问题所选择的动作。

   3.2 根据以下公式，更新值函数

$$\bar{V}_{t-1}^n(S_{t-1}^{a,n})=(1-\alpha_{n-1})\bar{V}_{t-1}^{n-1}(S_{t-1}^{a,n})+\alpha_{n-1}\hat{v}_t^n$$

   3.3 根据抽样路径$W_{t+1}^n=W_{t+1}(\omega^n)$，更新状态

$$S_{t+1}^n=S^M(S_t^n,a_t^n,W_{t+1})$$

4. n=n+1. 若 $n\leqslant N$，则返回步骤 2，否则进行下一步

5. 得到近似值函数$(\bar{V}_t^n)_{t=1}^T$

表 5-1 本章中使用的主要变量与含义

Table 5-1 The main variables and corresponding meaning in this chapter.

变量	含义
k	决策阶段
s_k	决策阶段 k 处的状态
a_k	决策阶段 k 处选择的动作
t_k	决策阶段 k 对应的时间
Δt	决策周期
A_k	决策阶段 k 处对应的动作集
A_{k1}	决策阶段 k 处对应的可选动作集
$\emptyset_f$	基函数
$C_k(S_k,a_k)$	在状态 S_k 处使用动作 a_k 获得的代价函数

中国知网 https://www.cnki.net

与算法 5.1 相比，算法 5.2 中增加了对 M 个不同策略的估计（算法 5.2 中步骤 3-步骤 8），为已设定的策略 π 找到一个合适的近似值函数。

5.2 基于 ADP 算法的优化问题建模

本节对重载列车在长大下坡区段的运行过程进行分析，将重载列车的运行过程描述为马尔科夫决策过程，从而使用 ADP 算法对优化问题进行求解。本节使用 Powell 的数学符号体系[99][100]，对决策过程中的各项要素进行详细说明，并且给出具体的求解算法。在本章中使用的一些主要变量及其对应的含义如表 5-1 所示。

算法 5.2 近似策略迭代

1. 初始化：包括设置初始值函数$\bar{V}^{\pi,0}$；迭代次数 n=1；最大迭代次数 N；决策阶段 t=1，其中 t=[1,2,…,T]；策略迭代相关参数 M。
2. 选择初始状态S_1^n，进行以下步骤：
3. 对于 m=1,2,…,M，进行以下步骤：
4. 选择一个抽样路径ω^m，该抽样路径为一个完整的片段（从 t=1 到 t=T）
5. 对于 t=1,2,…,T，进行以下步骤：

   5.1 根据下列公式，选择每个决策阶段的最优动作

$$a_t^{n,m}=\arg\max_{a_t\in A_t^{n,m}}(C(S_t^{n,m},a_t)+\gamma\bar{V}_t^{\pi,n-1}(S^{M,a}(S_t^{n,m},a_t)))$$

   5.2 根据下列公式，更新决策后的状态

$$S_{t+1}^{n,m}=S^M(S_t^{n,m},a_t^{n,m},W_{t+1}(\omega^m))$$

6. 初始化$\hat{v}_{t+1}^{n,m}=0$
7. 对于 t=T, T-1,…, 1，进行以下循环：

   7.1 根据以下公式，对$\hat{v}_t^{n,m}$累加求和

$$\hat{v}_t^{n,m}=C(S_t^{n,m},a_t)+\gamma\hat{v}_{t+1}^{n,m}$$

   7.2 更新近似策略值函数$\bar{v}_t^{n,m}$

$$\bar{v}^{n,m}=\frac{m\text{-}1}{m}\bar{v}^{n,m-1}+\frac{1}{m}\hat{v}_0^{n,m}$$

8. 更新值函数

$$\bar{V}^{\pi,n}=(1\text{-}\alpha_{n-1})\bar{v}^{n-1}+\alpha_{n-1}\hat{v}_0^{n,M}$$

9. n=n+1，如果 n<N，返回步骤 2。
10. 获得值函数$\bar{V}^{\pi,n}$

中国知网 https://www.cnki.net

5.2.1 决策时刻

机车乘务员在驾驶重载列车时，会在不同情况下使用不同的工况。当机车乘务员采用某种工况去控制列车时，做出这个决策的瞬间即为决策时刻。在本章中，决策时刻在时间轴上使用对应的决策阶段 k 标记，即在第 k 个决策阶段对应的决策时刻为 t_k。列车在决策时刻 t_k 对应的状态以及具体的动作（决策）分别表示为 S_k，a_k。决策时刻 t_k 和下一决策时刻 t_k+1 之间的时间段 Δt 定义为决策周期。

5.2.2 状态

根据 Powell 的定义，状态变量是关于历史信息的最小维度的函数，对于计算决策函数，状态转移函数和贡献函数（代价函数）是必要且足够的。考虑到重载列车在长大下坡区段运行时，必须考虑空气制动缓解后的缓解时间，为方便表示缓解时间的约束条件，本研究中使用列车的速度和当前的运行时分进行描述。设列车在整个区间内的运行时分为 T，在这个区间内列车共需要进行 N 次决策，则决策周期 $\Delta t=T/N$，决策时刻 t_k 可以视为列车的运行时分。本研究中，列车的状态变量 s_k 表示为：

$$s_k=(v_k, t_k), k=1, 2, \ldots, N \tag{5-16}$$

在（5-16）中，v_k 为列车在第 k 个决策阶段对应的速度。

5.2.3 动作

动作是智能体在当前状态下做出的决策。当重载列车在长大下坡区段运行时，机车乘务员通过在合适的时机施加空气制动和动力制动防止列车超速，同时也需要选择合适时机缓解空气制动，以便提高列车的运行效率，同时为下一次空气制动做好准备。在本研究中，动作定义为列车在每个决策时刻的控制量。结合第二章中已构建的列车动力学模型，决策时刻 t_k 对应的控制量的计算公式如下：

$$a_k=\frac{u_k(v_k)+F_{\text{aero}}(t_k)}{M} \tag{5-17}$$

在（5-17）中，$u_k(v_k)$为 t_k 时刻列车对应的动力制动力，可以根据列车在 t_k 时刻的速度 v_k 根据第二章中的公式（2-11）计算，$F_{\text{aero}}(t_k)$为 t_k 时刻对应的空气制动力，M 为列车质量。由于施加给列车的控制量与列车的加速度值成正比，因此为简化运算，本研究中直接使用加速度值代替对应的控制量。

中国知网 https://www.cnki.net

5.2.4 状态转移函数

智能体在不同状态之间的转移过程可以用状态转移函数来描述。假设列车当前状态为 $s_k=(v_k, t_k)$，根据当前策略在当前决策时刻下选择的动作为 a_k，则状态转移函数可以表示为：

$$s_{k+1}=S^M(s_k,a_k) \tag{5-18}$$

根据本研究中对状态的定义，状态转移函数中需要分别计算列车速度的变化以及决策时刻的变化。列车速度可以根据运动学公式进行计算，即：

$$v_{k+1}=v_k+a_k\Delta t \tag{5-19}$$

决策时刻的变化为：

$$t_{k+1}=t_k+\Delta t \tag{5-20}$$

5.2.5 代价函数

代价函数用来表示在当前决策时刻所选择动作的优劣。根据 2.1 节可知，当列车的运行时间一定时，为提高列车的运行效率，列车的运行距离应尽可能大。同时为了减少列车运行时的设备磨损，列车进行空气制动的时间应尽可能小。因此本研究中使用如下所示的代价函数：

$$C_k(s_k,a_k)=\delta_k\Delta k-\frac{\Delta t}{2}(v_k+v_{k+1}) \tag{5-21}$$

在代价函数（5-21）中，δ_k 为逻辑变量，取值集合为{0,1}，用于表示在决策时刻 t_k 是否使用了空气制动，若 δ_k=1 表示施加了空气制动，δ_k=0 表示未施加空气制动。（5-21）中的第一项表示施加空气制动的时间，第二项表示列车在这个决策周期内运行的距离。代价函数的值越小，说明空气制动的时间越短，或者列车在决策周期内的运行距离越长，因此可以用于评价不同动作的优劣。结合第二章中的目标函数，代价函数（5-21）可以改写为：

$$C_k(s_k,a_k)=\lambda_1\frac{\delta_k\Delta t}{T_{\mathrm{p1}}}-\lambda_2\frac{\frac{\Delta t}{2}(v_k+v_{k+1})}{L_{\max}} \tag{5-22}$$

在（5-22）中，T_{p1}和$L_{\max}$均用于对优化目标进行归一化。在实际计算中，$T_{\mathrm{p1}}=T/2$，$L_{\max}=v_{\max}T$，其中 T 表示区间运行时分，$v_{\max}$表示最高限速。（5-22）中λ_1和λ_2分别表示空气制动时间和运行距离这两项优化指标对应的权重。

中国知网 https://www.cnki.net

5.2.6 目标函数

目标函数表示列车在整个区间内运行时希望达到的目标。根据（5-22）可知，代价函数相当于每个决策周期内的目标函数，因此目标函数可以表示为对每个决策周期内得到的代价函数值求和：

$$f_{\text{obj}}=\min_{\pi\in\Pi}\sum_{k=1}^{T}C_k(s_k,a_k) \tag{5-23}$$

目标函数（5-23）中$C_k(s_k,a_k)$与（5-12）中含义相同。

5.2.7 重载列车运行过程描述

根据以上模型，重载列车在长大下坡区间的运行过程可以使用有限 MDP 描述为：

$$s_1 \xrightarrow{a_1} s_2 \xrightarrow{a_2} \cdots s_{T\text{-}1} \xrightarrow{a_{T\text{-}1}} s_T$$

其中 s_k（k=1, 2, … ,N）为列车不同决策时刻的状态，a_k（k=1, 2, … ,N-1）为列车在不同决策时刻选择的动作。当列车由状态 s_k 转移到状态 s_{k+1} 时，结合状态转移函数和列车动力学模型，这个过程可以表示为：

$$s_{k+1}=F(s_k,a_k,\Delta t) \tag{5-24}$$

5.3 基于 ADP 的求解方法

当列车在长大下坡区段的运行过程转化为有限 MDP 的模型后，可以使用 ADP 算法进行求解。本节基于 ADP 算法设计求解优化问题的方法，同时对诸如可行解的选择，如何构建近似值函数等关键问题进行详细分析。

5.3.1 基函数结构选取

在 5.1.3 节中介绍了几种不同的值函数近似方法。与目前在 ADP 算法中广泛应用的表格模型不同，基函数模型通过构造近似值函数，对涉及到的每个状态计算出近似值函数。虽然计算精度不如表格模型，但基函数模型无需构造表格存储每个状态对应的值函数，占用内存更少，且计算速度更快。考虑到本研究中涉及到的决策阶段较多，因此选用基函数模型构建近似值函数。

在基函数模型中，多项式基函数是一类最为简单的基函数。根据 5.1.3 节中的

中国知网 https://www.cnki.net

描述，多项式基函数中最重要的部分是如何选择基函数对应的不同特征。在 MDP 中，使用策略 π，在状态 s 处对应的值函数定义为如下形式：

$$v_\pi(s)=\mathrm{E}_\pi\left[\sum_{k=0}^{\infty}\gamma^k R_{t+k+1}\,|\,s_t=s\right] \tag{5-25}$$

其中$\mathrm{E}_\pi[.]$表示给定策略 π 时一个随机变量的期望值，R 表示对应的收益。根据 5.2.5 中对代价函数的介绍可知，值函数与代价函数密切相关，因此构建值函数时应包含构建代价函数所需的要素。根据公式（5-21）可知，代价函数中涉及到对时间和列车速度的计算，因此多项式基函数可以构建成如下形式：

$$\emptyset_f(v,t)=[1,v,t,v\cdot t,v^2,t^2] \tag{5-26}$$

为确保多项式基函数拟合的准确性，在（5-26）中，增加了时间和列车速度对应的二次方项。

5.3.2 约束条件处理

在 ADP 算法中，在每个决策时刻智能体将根据当前所处的状态选择可行的动作。在本研究中涉及到的多阶段决策问题中，重载列车在不同状态对应的可选动作集 A_t 与当前状态密切相关，如图 5-4 所示：

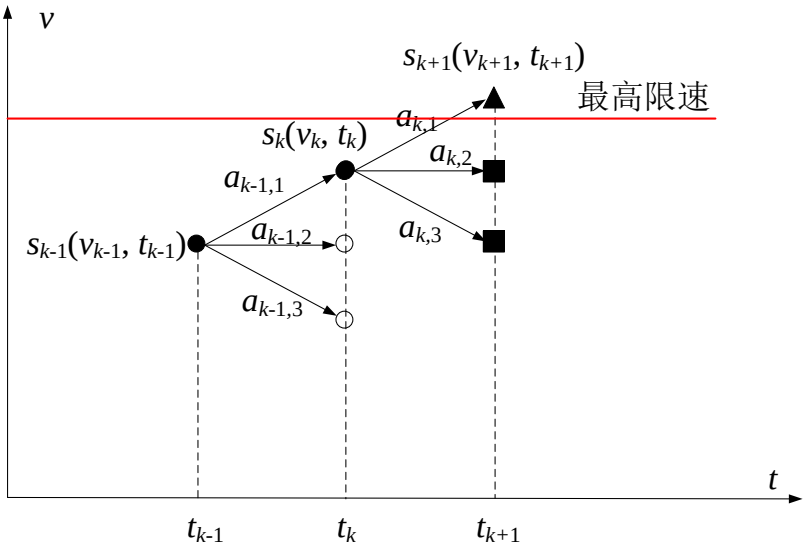


图 5-4 多阶段决策过程的动作选择部分

Fig. 5-4 The action selection part of the multi-stage decision process

在图 5-4 中，s_{k-1}，s_k 和 s_{k+1} 为该决策过程中对应的三个不同的状态，黑色实心圆点表示根据已选择的动作得到的状态，黑色空心圆点表示可选但未选择的状态，

中国知网 https://www.cnki.net

黑色三角表示不可行状态，黑色实心方块表示下一阶段的可选状态。如图所示，当列车状态为 s_{k-1} 时，可选动作集 $A_{k-1,1}=\{a_{k-1,1}, a_{k-1,2}, a_{k-1,3}\}$，列车在这个状态选择动作 $a_{k-1,1}$，之后列车状态转移到 s_k。当列车处于状态 s_k 时，若选择动作 $a_{k,1}$，列车运行到下一状态时速度 v_{k+1} 超过了最高限速，因此列车在状态 s_k 处的可选动作集为 $A_{k1}=\{a_{k,2}, a_{k,3}\}$。

结合 2.3 中的约束条件，下面给出根据列车状态和对应的动作，判定该状态是否满足各项约束条件的方法（假设当前列车状态为 $s_k(v_k, t_k)$）。选择动作为 a_k。

1）限速

与限速相关的约束条件包括最高限速 $v_{\max}$ 和最低缓解速度 v_{rmin}。对于最高限速，可根据列车当前的状态直接判断，即 $v_k \le v_{\max}$。

判断列车速度是否低于最低缓解速度，首先应结合列车当前决策时刻的动作 a_k 和前一决策时刻的动作 a_{k-1}，判断列车是否进行缓解。列车是否进行缓解可以通过列车当前的控制变量描述，若列车开始缓解，则此时的控制变量必定大于列车当前的加速度值。因此当列车开始缓解时，下面的条件成立：

$$|a_{k-1}|>|a_p|,\ |a_k|<|a_p| \tag{5-27}$$

其中 a_p 为空气制动力产生的加速度值。式（5-27）描述列车控制变量的变化过程为：前一时刻控制量的值大于空气制动产生的加速度值，表示此时仍有空气制动；后一时刻控制量的值小于空气制动产生的加速度值，表示列车已经开始缓解。当列车开始缓解时，应满足 $v_k \ge v_{\mathrm{rmin}}$。

2）缓解时间

计算缓解时间时，应首先根据列车当前决策时刻和上一决策时刻对应的动作，判断列车是否开始进行制动或者缓解。在 1）中给出了列车开始缓解的判定条件，假设列车已经根据 1）中的条件得到了缓解开始的时刻 t_{start}，下面给出列车开始制动的判定条件：

$$|a_{k-1}|<|a_p|,\ |a_k|>|a_p| \tag{5-28}$$

其中 a_p 以及其他符号的含义与 1）中相同。当列车开始制动时，记录此时的决策时刻 t_{end} 即为缓解过程结束的时刻。根据缓解开始和结束的时刻，可以计算出缓解过程的持续时间。因此相关约束条件可以转化为

$$(t_{\mathrm{end}}-t_{\mathrm{start}})\Delta t \ge t_{\mathrm{rmin}} \tag{5-29}$$

3）工况转换规则

列车在决策时刻 t 的工况可以根据 t-1 时刻选择的控制量 a_{t-1} 决定。列车工况与所选控制量的对应关系如下表所示（其中 a_{et}，a_{eb}，a_p 分别表示牵引力，动力制动力和空气制动力产生的加速度值，均取正值）：

中国知网 https://www.cnki.net

表 5-2 工况与动作的对应关系

Table 5-2 The relationship between train regimes and actions

a_t 的取值范围	t 时刻的工况
$0< a_t<a_{et}$	牵引（T）
0	惰行（C）
$-a_{eb} < a_t<0$	动力制动（EB）
$-a_p$	空气制动（PB）
$-a_p- a_t< a_t< -a_p$	动力制动+空气制动（EPB）

根据表 5-2 得到 t-1 时刻动作 a_{t-1} 对应的工况后，即可根据 2.3 节中表 2-1 的转换规则确定 t 时刻的可选动作。

结合以上三种不同类型约束条件的处理方法，针对图 5-4 中可能出现的不满足约束条件的情况，本文设计了一种根据奖励值确定可选动作的算法：在每个决策时刻，列车可选择的控制变量完全由当前列车的状态决定，对于每一个具体的动作，根据状态转移函数计算出列车下一决策时刻的状态。若下一时刻对应的状态满足约束条件，则奖励值根据 5.2.5 中的代价函数计算，否则奖励值指定为一个与目标函数取值范围差别较大的一个值。具体步骤算法 5.3 所示。

算法 5.3 可选动作确定算法

输入：列车在决策时刻 t_k 的状态 s_k，根据列车当前状态得到的动作集 $A_k=\{a_{k,1}, a_{k,2}, \dots, a_{k,I}\}$；

输出：列车在当前状态可选的动作集 A_{k1}

1. 根据列车当前状态以及动作集，使用状态转移函数计算出下一决策时刻所有可能的状态 $s_{k+1,i}$ (i=1, 2, … ,I)
2. 对于下一时刻所有可能的状态 $s_{k+1,i}$，分别判定该状态是否满足约束条件。若满足约束条件，则根据（5-18）计算代价函数值，否则令代价函数值 C=-200
3. 判断该动作对应的代价函数值是否等于-200，若是，则舍弃该动作；否则将该动作保存到动作集 A_{k1} 中。
4. 判断是否所有动作均已判定完毕，若是，则输出 A_{k1}，结束算法；否则转到步骤 2。

5.3.3 近似值函数算法设计

使用值函数近似的思想是构造一个近似值函数，在迭代过程中该近似值函数能够逼近真实的值函数，从而对涉及到的每个状态输出最优的值函数。当基函数的形式已确定后，训练过程转化为寻找合适的参数向量 θ，在对应状态下由这组参数

中国知网 https://www.cnki.net

和基函数构成的近似值函数，能够近似表示该状态下的状态值。

使用近似值函数求解重载列车优化驾驶策略的过程如下：首先对列车状态和近似值函数等相关参数进行初始化，之后在每个决策时刻，计算列车的状态以及对应的近似状态值函数，同时根据当前时刻的状态值更新列车在上一决策时刻对应的状态值，从而实现逼近近似状态值函数的真实值。具体流程如算法 5.4 所示。

算法 5.4 基于 ADP 的重载列车驾驶曲线优化算法

1.初始化

1.1 对于重载列车的近似值函数，设置初始值$\bar{V}_k^0(s_k^a)$，其中 k=1,2,…,N。

1.2 设置迭代次数 n=1，最大迭代次数 max_iter。

1.3 设置列车的初始状态s_1^a。

2.对于迭代次数 $n \le max_iter$，进行以下步骤

3.对于每个决策阶段 k=1,2,…,N，进行以下步骤

3.1 根据列车当前的状态和动作，使用算法 5.3 得到列车当前状态下的可选动作集 A_{k1}，表示列车在当前状态下可选的控制量。

3.2 根据 ε-greedy 策略选择动作：列车有 ε 的概率在动作集 A_{k1} 中随机选择一个控制量，有 1-ε 的概率根据以下公式选择控制量a_k^n：

$$\hat{v}_k^n=\arg\max_{a_k^n \in A_{k1}} (C(s_k^n,a_k)+\gamma \bar{V}_k^{n-1}(S^{M,a}(s_k^n,a_k)))$$

其中a_k^n是使得$\hat{v}_k^n$取最小值时对应的控制量。

3.3 根据以下公式，更新值函数：

$$\bar{V}_{k-1}^n(s_{k-1}^{a,n})=(1-\alpha_{n-1})\bar{V}_{k-1}^{n-1}(s_{k-1}^{a,n})+\alpha_{n-1}\hat{v}_k^n$$

3.4 使用随机梯度下降法，更新近似值函数中的参数 θ

3.5 根据列车控制量a_k^n和列车当前状态s_k^n，使用状态转移函数更新列车的状态

$$s_{k+1}^n=S^M(s_k^n,a_k^n)$$

4．令 n=n+1. 若 $n \le max_iter$，则返回步骤 2，否则进行下一步

5. 得到近似值函数$(\bar{V}_k^n)_{k=1}^N$

5.4 仿真结果与分析

5.4.1 算法有效性验证

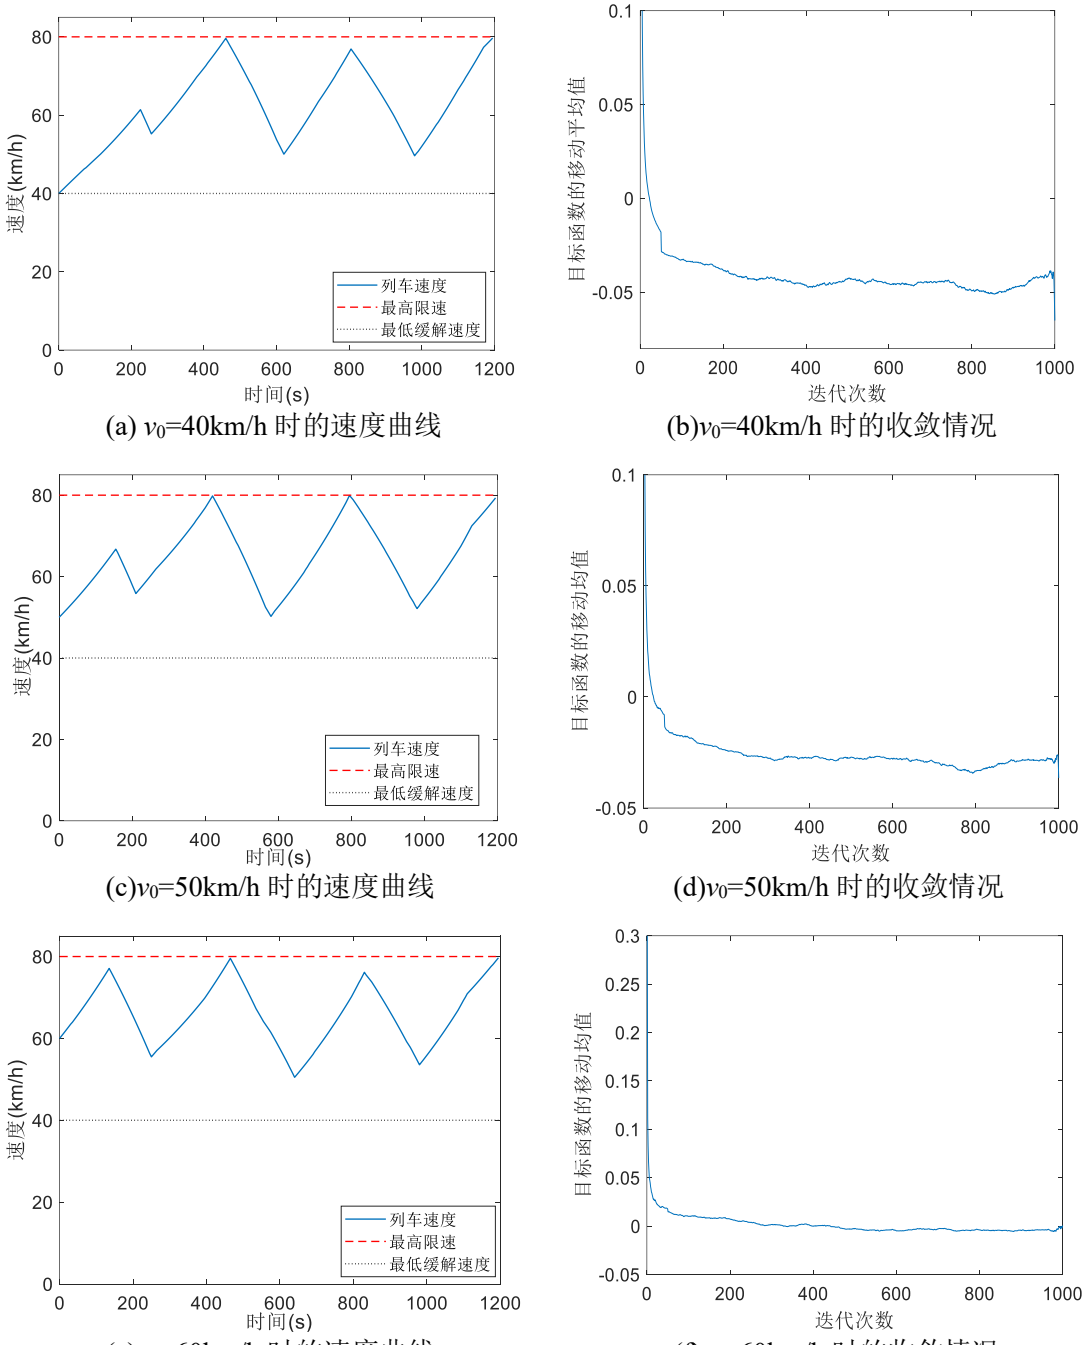
本节对 5.3 节中设计的基于 ADP 的重载列车驾驶曲线优化算法，使用 Matlab

中国知网 https://www.cnki.net

语言进行验证。在仿真算例中，使用的线路数据和车辆数据与第四章中的相同。分别改变列车的初速度和对应优化目标的权重，得到的仿真结果如下所示：

（1） 相同权重，不同初速度下得到的仿真结果

在（1）中，设置两种优化目标的权重均为 0.5，列车初速度分别取 40km/h，50km/h 和 60km/h。由此得到的仿真结果如图 5-5 所示。



(a) v_0=40km/h 时的速度曲线　(b)v_0=40km/h 时的收敛情况

(c)v_0=50km/h 时的速度曲线　(d)v_0=50km/h 时的收敛情况

(e)v_0=60km/h 时的速度曲线　(f)v_0=60km/h 时的收敛情况

图 5-5 列车速度曲线和目标函数的收敛情况

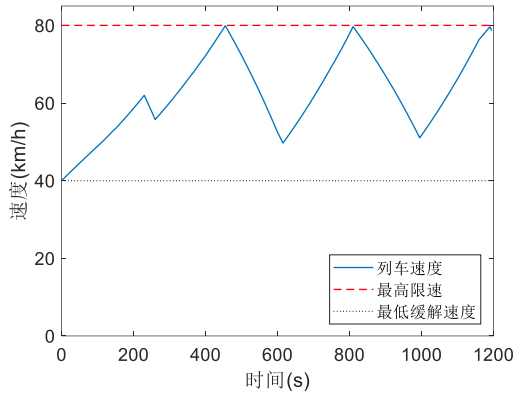
Fig. 5-5 Speed profile of the train and the convergence of objective value

中国知网 https://www.cnki.net

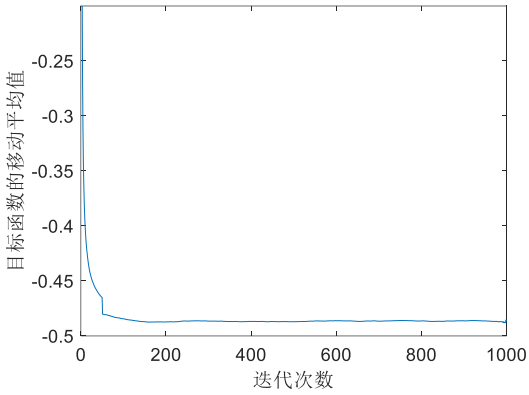
图 5-5 中展示了在两种优化目标的权重均为 0.5 时，对应的列车速度曲线和目标函数的收敛情况。为了更清晰地展现目标函数随着迭代次数增加而逐渐收敛的趋势，图 5-5 中使用目标函数的移动平均值表示。根据图 5-5 可知，算法能够在 1000 次迭代内收敛到最优值，表明此时已经求出最优的驾驶策略。根据最优驾驶策略得到的驾驶曲线均满足各项约束条件。因此可以证明算法 5.4 的有效性。

（2） 初速度相同，改变不同权重得到的仿真结果：

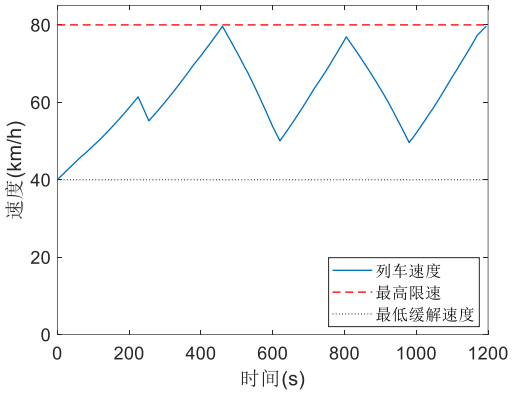
在（2）中，设置列车的初速度均为 40km/h，同时优化目标权重分别取 0.2,0.5 和 0.8，得到的仿真结果如下图所示：



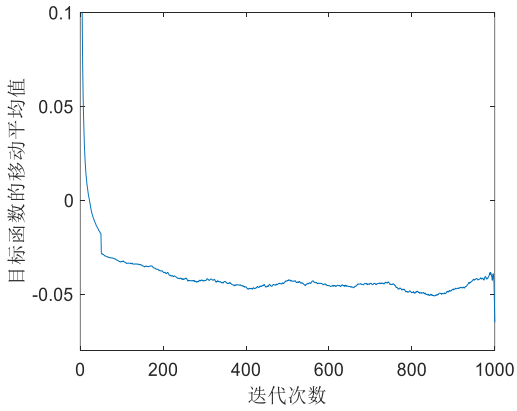
(a) λ_1=0.2，λ_2=0.8 对应的速度曲线



(b) λ_1=0.2，λ_2=0.8 对应的收敛情况

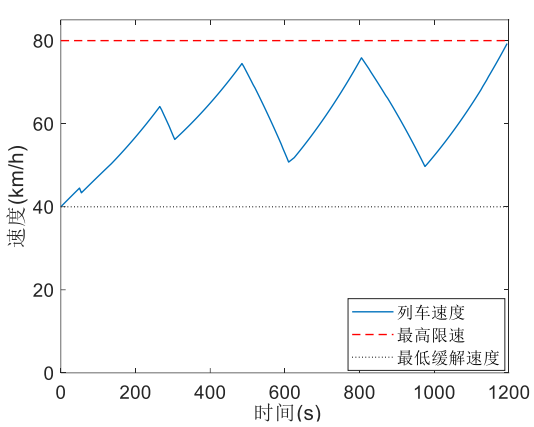


(c) λ_1=0.5，λ_2=0.5 对应的速度曲线

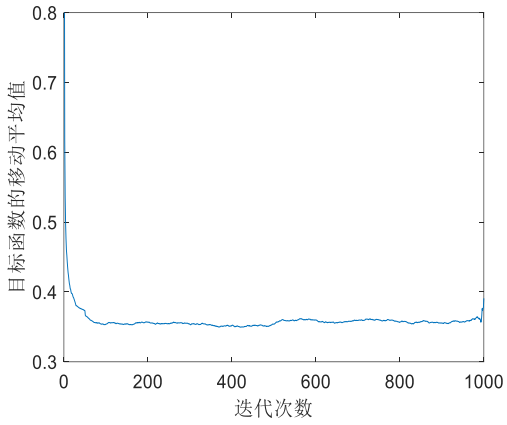


(d) λ_1=0.5，λ_2=0.5 对应的收敛情况

中国知网 https://www.cnki.net



(e) λ_1=0.8，λ_2=0.2 对应的速度曲线



(f) λ_1=0.8，λ_2=0.2 对应的收敛情况

图 5-6 不同权重对应的列车速度曲线和算法收敛情况

Fig. 5-6 Speed curve and algorithm convergence corresponding to different weights

根据图 5-6 所示，当不同优化目标对应的权重发生变化时，算法仍然能够在 1000 代以内收敛。由于目标函数的最优值与权重密切相关，因此图 5-6 中不同权重下目标函数收敛到的最优值有明显变化。所有的仿真结果如表 5-3 所示。

表 5-3 5.4.1 中对应算例的仿真结果

Table 5-3 Simulation results of the case in 5.4.1

v_0（km/h）	λ_1	λ_2	f_{obj}	T_{air}(s)	L_{dis}(m)
40	0.2	0.8	-0.497	375	20770
	0.5	0.5	-0.082	360	20572
	0.8	0.2	0.303	345	20079
50	0.5	0.5	-0.069	400	21449
60	0.5	0.5	-0.043	440	21823

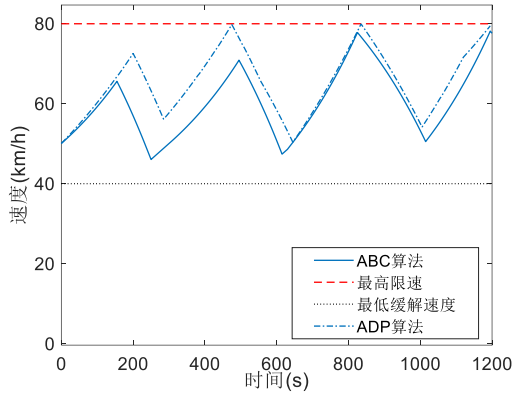
表 5-3 中展示了 5.4.1 节中算例中的所有仿真结果。对于不同初速度而言，当列车初速度越高，列车速度更容易接近最高限速，因此列车需要尽早采用空气制动以避免列车超速，在表 5-3 中所示即为列车在运行区间内所需的空气制动时间逐渐增加；同时列车的初速度越高，运行过程中的平均速度也越高，因此在相同时间内

中国知网 https://www.cnki.net

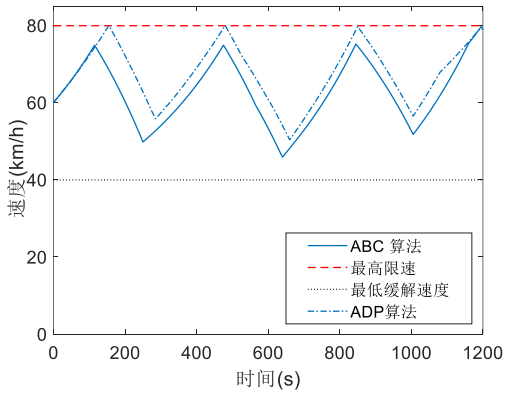
列车运行距离也就更长。目标函数值由空气制动时间和列车运行距离共同决定，空气制动时间越短，列车运行距离越长，则目标函数值越小。因此随着列车初速度增加，目标函数值也逐渐增大。根据相同初速度下不同权重得到的计算结果可知，两种优化目标随对应的权重变化趋势一致。

5.4.2 优化方法对比

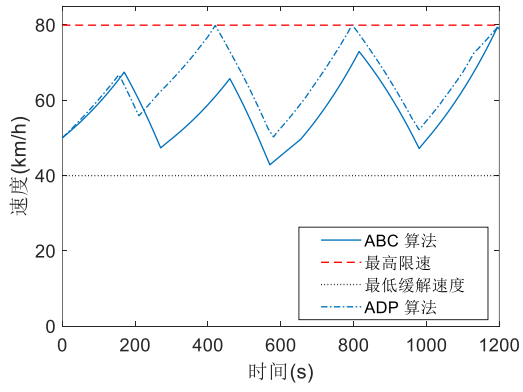
在接下来的算例中，分别将 ADP 算法求出的结果与第三章中的 ABC 算法以及第四章中的 MILP 方法进行对比。首先是 ADP 算法与 ABC 算法的比较。在仿真算例中，设置列车的初速度分别是 50km/h 和 60km/h，得到的速度曲线如下图 5-7 所示：



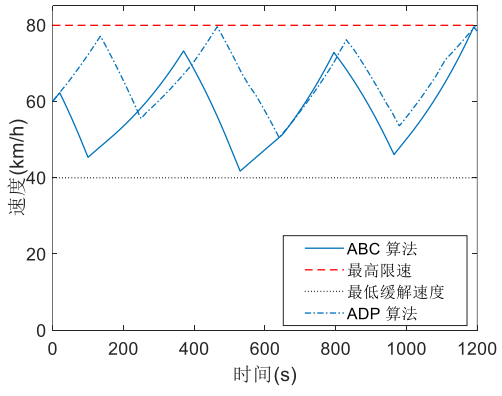
(a) λ_1=0.2，λ_2=0.8，初速度 50km/h



(b) λ_1=0.2，λ_2=0.8，初速度 60km/h

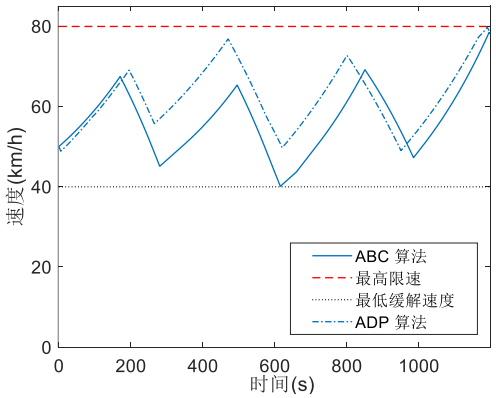


(c) λ_1=0.5，λ_2=0.5，初速度 50km/h

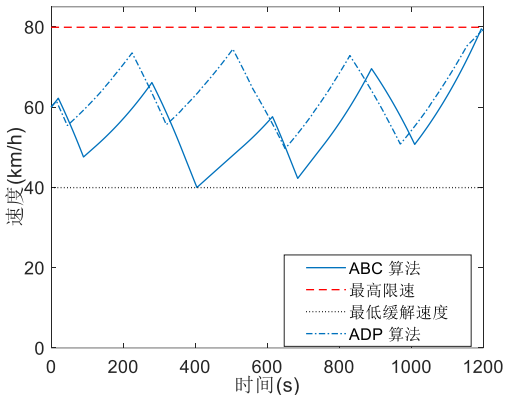


(d) λ_1=0.5，λ_2=0.5，初速度 60km/h

中国知网 https://www.cnki.net



(e) λ_1=0.8，λ_2=0.2，初速度 50km/h



(f) λ_1=0.8，λ_2=0.2，初速度 60km/h

图 5-7 ADP 算法与 ABC 算法得到的速度曲线对比

Fig. 5-7 The comparison of the speed curves between ADP and ABC algorithm

根据图 5-7 所示，ABC 算法和 ADP 算法均能够求出在指定区间内的列车速度曲线。驾驶策略可通过图 5-7 中速度曲线看出，对比两种算法计算得到的驾驶策略可知，列车进行空气制动与缓解的次数相同，但列车进行空气制动与缓解的速度值不同：使用 ADP 算法得到的驾驶策略中，列车进行空气制动和缓解的速度均明显高于使用 ABC 算法得到的结果。两种算法的具体仿真结果如表 5-4 所示。

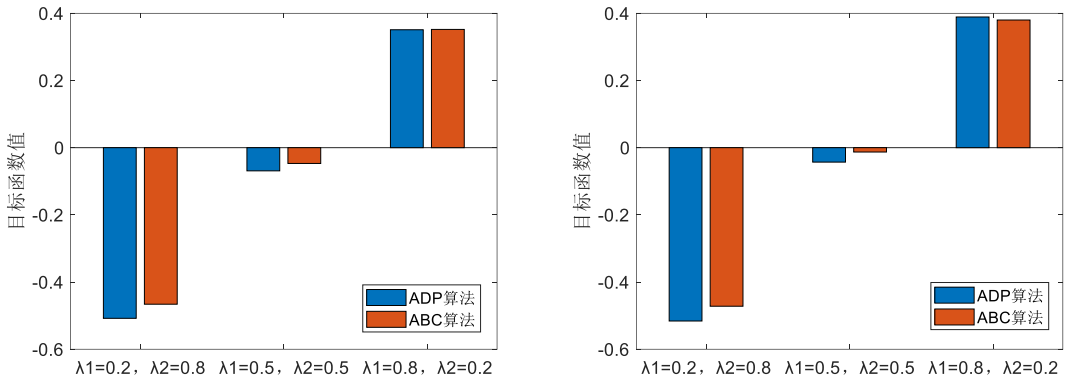
表 5-4 ADP 算法与 ABC 算法的仿真结果对比

Table 5-4 The comparison of simulation results between ADP and ABC algorithm

初速度（km/h）	λ_1	λ_2	算法	目标函数值	空气制动时间(s)	运行距离 (m)	计算时间(s)
50	0.2	0.8	ADP	-0.508	425	21664	45
			ABC	-0.466	410	20077	161
	0.5	0.5	ADP	-0.069	400	21449	45
			ABC	-0.047	380	19328	174
	0.8	0.2	ADP	0.351	380	20676	38
			ABC	0.352	370	18837	163
60	0.2	0.8	ADP	-0.516	465	22350	45
			ABC	-0.472	465	20896	171
	0.5	0.5	ADP	-0.043	440	21823	45
			ABC	-0.013	420	19377	168
	0.8	0.2	ADP	0.389	410	20956	38
			ABC	0.380	390	18577	168

中国知网 https://www.cnki.net

根据表 5-4 中的结果可知，对于不同的优化目标而言，ABC 算法对空气制动时间的优化效果好于 ADP 算法，而 ADP 算法对列车运行距离的优化效果更佳。结合图中的速度曲线可知，在一般情况下，使用 ABC 算法求出的驾驶策略中，列车进行空气制动时的速度值明显低于使用 ADP 算法求出的驾驶策略中列车进行空气制动时的速度值。由于列车进行空气制动时的速度值较低，因此在较短时间内可以使列车速度降低至一定范围内，计算得到的空气制动时间更短。对于 ADP 算法求出的驾驶策略而言，列车速度在达到或接近最高限速时才使用空气制动，因此列车平均速度较高，运行距离更长，但由于列车进行空气制动时速度较高，因此使得列车满足安全运行所需的空气制动时间也更长。为直观反映两种算法的优化性能，在图 5-8 中对 ADP 算法和 ABC 算法计算得到的目标函数值进行比较。



(a) 初速度 50km/h　　(b) 初速度 60km/h

图 5-8 ADP 算法与 ABC 算法得到的目标函数值比较

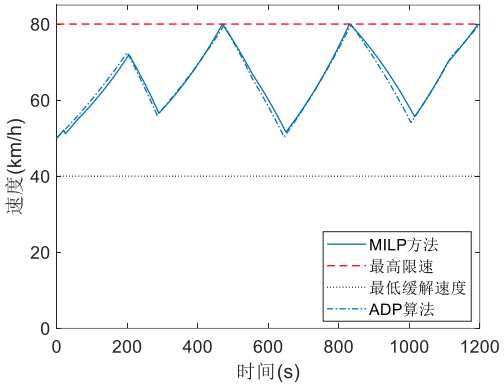
Fig. 5-8 The comparing of different objective values obtained by different ADP and ABC algorithm

由表 5-4 中 f_{obj} 对应的一列以及图 5-8 中的结果可知，仅当初速度为 60km/h，空气制动时间和列车运行距离的权重分别设置为 0.8 和 0.2 时，使用 ABC 算法能够得到更小的目标函数值；当初速度为 50km/h，空气制动时间和列车运行距离的权重分别设置为 0.8 和 0.2 时，两种方法得到的目标函数值基本相同；在其他情况下，使用 ADP 算法得到的目标函数值明显小于使用 ABC 算法得到的结果，意味着使用 ADP 算法能够得到更好的优化驾驶策略。

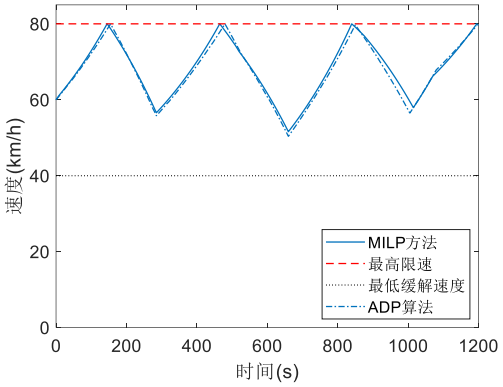
为了验证 ADP 算法的实时性，在表 5-4 中增加了对两种不同算法求解时间的比较。与 ABC 算法相比，ADP 算法在求解时间上具有明显的优势，能够在更短的时间内获得更好的结果。结合两种算法的优化效果以及运行时间可知，相比于 ABC 算法，ADP 算法的实时性更强，同时能够保证优化效果；而 ABC 算法的计算时间更长，且优化效果不如 ADP 算法。

中国知网 https://www.cnki.net

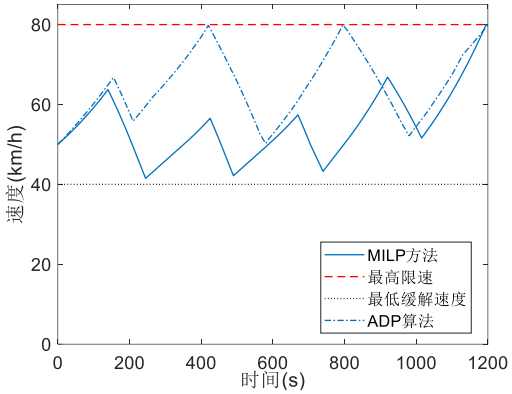
接下来比较 ADP 算法与 MILP 方法。在仿真算例中，同样设置列车初速度分别为 50km/h 和 60km/h，得到列车的速度曲线如图 5-9 所示：



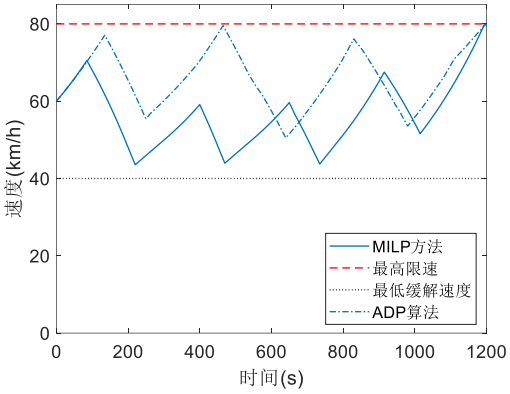
(a) λ_1=0.2，λ_2=0.8，初速度 50km/h



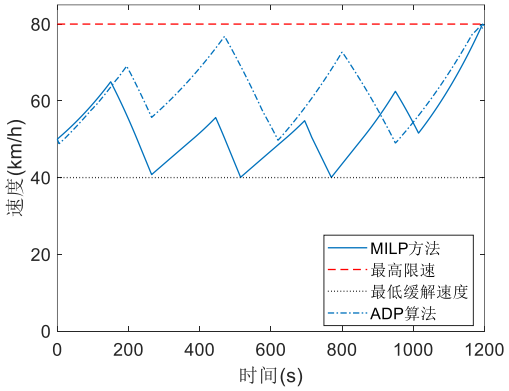
(b) λ_1=0.2，λ_2=0.8，初速度 60km/h



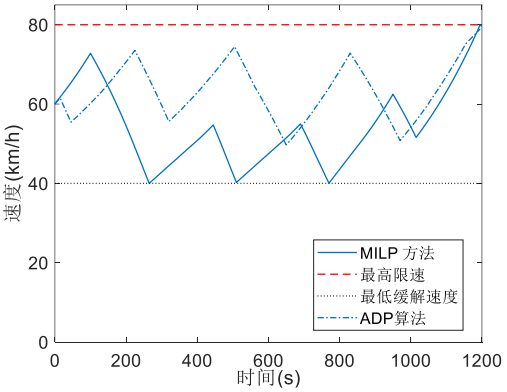
(c) λ_1=0.5，λ_2=0.5，初速度 50km/h



(d) λ_1=0.5，λ_2=0.5，初速度 60km/h



(e) λ_1=0.8，λ_2=0.2，初速度 50km/h



(f) λ_1=0.8，λ_2=0.2，初速度 60km/h

图 5-9 ADP 算法与 MILP 方法得到的速度曲线对比

Fig. 5-9 The comparison of the speed curves between ADP and MILP method

如图 5-9 所示，当列车运行距离对应的权重较大时，根据两种算法计算得到的速度曲线基本相同。而对于其他情况，使用两种算法计算得到的速度曲线的差别较大。与 ADP 算法生成的优化驾驶策略相比，MILP 方法生成的优化驾驶策略偏向

中国知网 https://www.cnki.net

于在速度较低的情况下进行空气制动，虽然生成的优化驾驶策略中使用空气制动的次数比使用 ADP 算法生成的优化驾驶策略更多，但由于每次空气制动时间较短，因此可以减少区间内总的空气制动时间。两种算法的具体仿真结果对比如表 5-5 所示：

表 5-5 ADP 算法与 MILP 方法的仿真结果对比

Table 5-5 The comparison of simulation results between ADP and MILP method

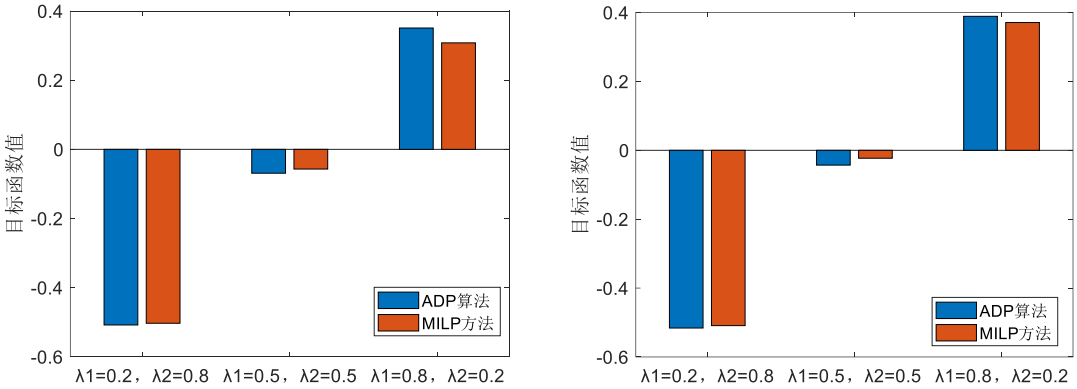
初速度（km/h）	λ_1	λ_2	算法	目标函数值	空气制动时间(s)	运行距离 (m)	计算时间(s)
50	0.2	0.8	ADP	-0.508	425	21664	45
			MILP	-0.503	455	21834	>300
	0.5	0.5	ADP	-0.069	400	21449	45
			MILP	-0.057	340	18146	>300
	0.8	0.2	ADP	0.351	380	20676	38
			MILP	0.308	330	17670	>300
60	0.2	0.8	ADP	-0.516	465	22350	45
			MILP	-0.509	515	22675	>300
	0.5	0.5	ADP	-0.043	440	21823	45
			MILP	-0.023	395	18791	>300
	0.8	0.2	ADP	0.389	410	20956	38
			MILP	0.371	380	18035	>300

结合表 5-5 中所示结果和图 5-9 中的速度曲线可知，与 ADP 算法求出的驾驶策略相比，MILP 方法求出的驾驶策略通过低速范围内进行多次较短时间的空气制动，尽管进行空气制动的次数更多，但由于每次进行空气制动的时间较短，所以总的空气制动时间。但 MILP 方法求出的驾驶策略中，列车运行时的平均速度更低，因此求出的区间运行距离明显小于使用 ADP 算法求出的列车运行距离。两种算法的优化性能可通过目标函数值判断，分别使用两种方法计算得到的目标函数值对比如图 5-10 所示。

根据图 5-10 可知，当空气制动时间和列车运行距离的权重分别设置为 0.8 和 0.2 时，使用 MILP 方法能够得到更小的目标函数值；在其他情况下，使用 ADP 算法得到的目标函数值小于使用 MILP 方法得到的结果。由于 MILP 方法是基于分支界定法对所有可行解进行比较，计算精度明显优于 ABC 算法，因此在图 5-10 中使用 ADP 算法得到的目标函数值更小的结果中，两种方法计算结果的差别不大；在初速度为 40km/h，且空气制动时间和列车运行距离的权重分别设置为 0.8 和 0.2

中国知网 https://www.cnki.net

时，使用 MILP 方法计算得到的结果明显小于使用 ADP 算法得到的结果。



(a) 初速度 50km/h　　(b) 初速度 60km/h

图 5-10 ADP 算法与 MILP 方法计算得到的目标函数值比较

Fig. 5-10 The comparing of different objective values obtained by different ADP and MILP method

根据表 5-5 中最后一列数据可知，MILP 方法和 ADP 算法的计算时间差别很大。尽管 MILP 方法在特定场景下求出的最优驾驶策略比 ADP 算法求出的最优驾驶策略更好，能够保证计算精度，但 MILP 方法所需的求解时间过长，均超过 300s，不具备实时优化的条件。因此相比于 MILP 方法，ADP 算法能够在较短时间内求出与 MILP 方法相类似的结果，更适用于实时优化。

5.5 本章小结

本章以列车在固定时间内的运行距离和列车的空气制动时间作为优化目标，研究如何生成重载列车在长大下坡区段的优化驾驶策略。提出了一种基于 ADP 算法的重载列车驾驶策略优化方法，该方法能够根据列车当前的状态，实时生成最优的列车驾驶策略，进而得到最优驾驶曲线。本章首先将重载列车在长大下坡区间的运行问题转化为 MDP 问题，通过构造近似值函数解决动态规划中存在的“维数灾难”问题，之后设计算法对优化问题进行求解。在仿真算例中，首先验证设计的 ADP 算法的有效性，接下来通过将 ADP 算法与 ABC 算法和 MILP 方法分别进行比较，通过对不同算法优化效果和计算时间进行对比，说明 ADP 算法能够在保证优化效果的前提下进行实时优化。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

6 总结与展望

6.1 研究总结

本文针对重载列车在长大下坡区间运行的优化控制问题，根据问题特点分别提出了三种不同类型的优化方法。论文完成的主要工作包括：

（1）总结目前国内外学者对列车优化运行问题和重载列车优化运行问题所使用的方法，结合我国重载列车及重载铁路的特征，提出本文的研究方法和主要内容。并结合重载列车的驾驶控制需求，构建重载列车驾驶策略优化问题的优化模型。

（2）根据重载列车在长大下坡区段的驾驶控制方式，设计了基于 ABC 算法求解列车工况转换点的方法，之后结合列车的工况和工况序列获得列车驾驶策略。该方法能够通过现有结果的质量，逐渐搜索到近似最优解。为提高搜索效率，将传统 ABC 算法中随机初始解生成的方法进行改进，针对列车运行的线路条件确定初始解的范围。

（3）为求得更为精确的最优解，本文设计了一种基于 MILP 方法的驾驶策略优化方法。MILP 方法能够对可行域内的所有解进行搜索，通过分支界定法获得最优解。针对 MILP 方法的适用条件，本章对优化模型中所有非线性条件进行了线性化，将问题转化为 MILP 模型，之后调用相关求解工具直接进行求解。MILP 方法与 ABC 算法的比较结果证明，与 ABC 算法相比，MILP 方法能够找到更优的驾驶策略。

（4）将重载列车驾驶策略转化为多步决策问题，使用 MDP 进行描述。接下来使用 ADP 算法求解列车在每个决策阶段的驾驶策略，进而获得列车在整个区间内的驾驶策略。本文使用多项式基函数的方法，构造近似值函数，克服传统动态规划中维数灾难的问题。与 ABC 算法和 MILP 方法相比，ADP 算法能够使用较短时间获得列车的最优驾驶策略，因此能适用于实时控制。

6.2 论文创新点

（1）提出了基于工况转换点的列车驾驶策略优化方法，该方法能够结合线路条件，自动计算出在指定区间运行时所需的工况转换点个数。进而结合工况和工况序列生成驾驶策略。对应的约束条件使用罚函数表示，整合到目标函数中，使得算法能够在寻优过程中舍弃不满足约束条件的解。

中国知网 https://www.cnki.net

（2）提出了针对重载列车驾驶策略优化问题的线性化转化方法，将优化模型中的非线性条件线性化，进而使用 MILP 方法进行求解。

（3）使用 ADP 算法，根据重载列车的运行状态，逐步求解并生成最优驾驶策略。考虑到使用表格型值函数进行求解时，表格的容量可能会随着状态的增加而急剧增大，因此本文使用多项式基函数近似表示值函数。针对列车在选择驾驶策略时可能出现的不满足约束条件的问题，设计了可选动作的确定方法，确保列车在每个阶段选择的驾驶策略均满足约束条件。

6.3 展望

本文研究的问题主要基于重载列车在长大下坡区段的运行场景。针对重载列车驾驶策略优化方法，今后应继续研究的内容如下：

在 ABC 算法中，跟随蜂是否跟随雇佣蜂前去采蜜由概率 P_i 决定，本文中使用传统 ABC 算法中对概率的定义，因此后续研究中应分析概率的定义式对优化效果的影响。

研究针对复杂运行环境下，重载列车优化运行模型的线性化方法。重载列车作为典型的非线性系统，如何进行合理的线性化是确保求解优化策略准确性的关键。

中国知网 https://www.cnki.net

参考文献

[1] 刘建新, 蔡久凤. 改革开放 40 年中国重载铁路的发展[J]. 长安大学学报(社会科学版), 2018, 20(06): 68-79.

[2] 杨建兵. 世界铁路重载运输现状及对我国的启示[J]. 中外企业家, 2019(18): 97-98.

[3] 张鹏. “公转铁”背景下我国煤炭供应格局变化研究[J/OL]. 煤炭经济研究: 1-10[2019-10-11]. https://doi.org/10.13202/j.cnki.cer.20190905.004.

[4] 连义平. 繁忙干线开行组合式重载列车初探[J]. 价值工程, 2010(204): 121-122.

[5] 张朝辉. 朔黄铁路万吨列车平稳操纵优化研究[M]. 成都：西南交通大学出版社, 2017.

[6] 王风洲, 李培署, 李国平.长大重载货物列车制动控制方案探讨[J]. 铁道车辆, 2014, 52(10): 31-35+6.

[7] 高春明, 冀彬, 张波, 等. 大秦线重载组合列车的 LOCOTROL 技术应用研究[J]. 电力机车与城轨车辆, 2006(06): 5-7+41.

[8] 耿志修. 大秦铁路重载运输技术[M]. 北京: 中国铁道出版社, 2009.

[9] Wei W, Lin Y. Simulation of a freight train brake system with 120 valves[J]. Proceedings of the Institution of Mechanical Engineers Part F, 2009, 223(1): 85-92.

[10] 陈浩, 魏伟. 重载列车制动特性的试验研究[J]. 大连交通大学学报, 2017, 38(02): 11-14.

[11] 杨辉, 马红萍, 付雅婷, 等. 基于多质点模型的重载列车制动策略[J]. 北京工业大学学报, 2020, 46(02): 169-179.

[12] 安中正. “和谐号”机车牵引 2 万吨重载列车的制动操纵技术探讨[J]. 机车电传动, 2010(1): 70-72.

[13] 魏伟, 赵连刚. 两万吨列车纵向动力学性能预测[J]. 大连交通大学学报, 2009, 30(2): 39-43.

[14] 魏伟. 两万吨组合列车制动特性[J]. 交通运输工程学报, 2007(6): 12-16.

[15] 嬴勇, 芦拥军. 和谐系列电力机车操纵办法[M]. 北京:中国铁道出版社, 2015.

[16] 孙树磊. 重载列车纵向冲动动力学研究[D]. 西南交通大学, 2014.

[17] Ichikawa K. Application of optimization theory for bounded state variable problems to the operation of train[J]. Bulletin of Jsme, 1968, 11: 857-865.

[18] Howlett P G. An optimal strategy for the control of a train[J]. The Journal of the Australian Mathematical Society Series B, 1990, 31: 454–471.

[19] Howlett P G, Milroy I P, Pudney P J. Energy-efficient train control[J]. Control Engineering Practice, 1994, 2(2):193-200.

[20] Howlett P G. Optimal strategies for the control of a train[J]. Automatica, 1996, 32(4): 519-532.

[21] Howlett P G, Cheng J X. Optimal driving strategies for a train on a track with continuously varying gradient[J]. Journal of the Australian Mathematical Society, 1997, 38(03): 388-410.

[22] Howlett P G, Leizarowitz A. Optimal strategies for vehicle control problems with finite control sets[J]. Dynamics of Continuous Discrete & Impulsive Systems, 2001, 8(1): 41-69.

[23] Liu R F, Iakov M. Golovitcher. Energy-efficient operation of rail vehicles[J]. Transportation Research Part A, 2003(37): 917-932.

[24] Tan Z X, Lu S F, Bao K, et al. Adaptive partial train speed trajectory optimization[J]. Energies, 2018, 11, 3302.

中国知网 https://www.cnki.net

[25] Wang Y H, De Schutter B, Ton J.J, et al. Optimal trajectory planning for trains – A pseudospectral method and a mixed integer linear programming approach[J]. Transportation Part C, 2013, 29: 97-114.
[26] Wang Y H, De Schutter B, Ton J.J, et al. Optimal trajectory planning for trains under fixed and moving signaling systems using mixed integer linear programming[J]. Control Engineering Practice, 2014, 22: 44-56.
[27] Jin B, Sun P F, Xu M J, et al. Train timetable and trajectory optimization using improved state-space MILP[C]. Proceedings of the 37th Chinese Control Conference, 2018: 7748-7753.
[28] Chang C S, Sim S S. Optimizing train movements through coast control using genetic algorithms[J]. IEE Proceedings Electric Power Applications, 1997, 144(1): 65-73.
[29] Ke B R, Lin C L, Yang C C. Optimization of train energy-efficient operation for mass rapid transit systems[J]. IET Intelligent Transport Systems, 2012, 6(1): 58-66.
[30] Khan M B, Zhou X. Stochastic optimization model and solution algorithm for robust doubletrack train-timetabling problem[J]. IEEE Transactions on Intelligent Transportation Systems, 2010, 11(1): 81-89.
[31] 金炜东, 王自力. 列车节能操纵优化方法研究[J]. 铁道学报, 1997(6): 58-62.
[32] 马超云, 毛保华, 梁肖, 等. 地铁列车节能运行惰行控制研究[J]. 交通信息与安全, 2010, 28(2): 37-42.
[33] 付印平. 列车追踪运行与节能优化建模及模拟研究[D]. 北京交通大学, 2009.
[34] 熊超彬. 基于 GSO 算法的列车运行节能操纵优化研究[D]. 西南交通大学, 2014.
[35] 李烨, 郭子立, 郭奕杉. 基于 PSO 的轨道交通列车节能控制优化研究[J]. 控制工程, 2018, 25(10): 1911-1915.
[36] 段玉琼, 朱爱红, 马晓娜, 等. 基于人工蜂群算法的高速列车运行节能优化研究[J]. 铁道标准设计, 2019, 63(09): 163-168.
[37] He Z Y, Yang Z J, Lv J Y. Trajectory optimization for high-speed train operation[C]. Proceedings of the 37th Chinese Control Conference. 2018: 2065-2070.
[38] Wang P, Ding S, Gao X J. Optimization of train energy saving based on golden ratio genetic algorithm[J]. 33rd Youth Academic Annual Conference of Chinese Association of Automation (YAC). 2018: 869-874.
[39] 杨杰, 吴佳焱, 王彪, 等. 基于启发式遗传算法的列车节能运行目标速度曲线优化算法研究[J]. 铁道学报, 2019, 41(08): 1-8.
[40] Chen R J, Chen D W, Gai W L, et al. Intelligent driving methods based on sparse LSSVM and ensemble CART algorithms for high-speed trains[J]. Computers & Industrial Engineering, 2019, 1(127): 1203-1213.
[41] 张淼, 张琦, 张梓轩. 基于 Q 学习算法的高速铁路列车节能优化研究[J]. 铁道运输与经济, 2019, 41(12): 111-117.
[42] Yin J T, Chen D W, Li L X. Intelligent train operation algorithms for subway by expert system and reinforcement learning[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 15(6): 2561-2571.
[43] 张淼, 张琦, 刘文韬, 等. 一种基于策略梯度强化学习的列车智能控制方法[J]. 铁道学报, 2020, 42(01): 69-75.
[44] 阴佳腾. 基于近似动态规划的城轨列车运行一体化调整方法研究[D]. 北京交通大学, 2018.

中国知网 https://www.cnki.net

[45] 王鹏. 基于多目标约束的重载列车自动驾驶控制算法研究[A]. 中国铁路总公司机辆部、中国铁道学会.2018 年中国重载铁路技术交流会论文集（下册）[C]. 中国铁路总公司机辆部、中国铁道学会:中国铁道学会, 2018: 6.

[46] Cheng J, Howlett P G. Application of critical velocities to the minimisation of fuel consumption in the control of trains[J]. Automatica, 1992, 28(1): 165-169.

[47] Cheng J, Howlett P G. A note on the calculation of optimal strategies for the minimization of fuel consumption in the control of trains[J]. IEEE Transactions on Automatic Control, 1993, 38(11): 1730-1734.

[48] Howlett P G, Pudney P J. Energy-efficient train control[M]. Berlin: Springer, 1995.

[49] Chou M, Xia X H. Optimal cruise control of heavy-haul trains equipped with electronically controlled pneumatic brake systems[J]. Control Engineering Practice, 2007, 15: 511-519.

[50] Chou M, Xia X H, C. Kayser. Modelling and model validation of heavy-haul trains equipped with electronically controlled pneumatic brake systems[J]. Control Engineering Practice, 2007, 15: 501-509.

[51] Zhuan X T. Optimal handing and fault-tolerant speed regulation of heavy haul trains[D]. University of Pretoria, Pretoria, 2006.

[52] Zhuan X T, Xia X H. Optimal scheduling and control of heavy haul trains equipped with electronically controlled pneumatic braking systems[J]. IEEE Transactions on Control Systems Technology, 2007, 15(6): 1159-1166.

[53] Zhuan X T, Xia X H. Fault-tolerant control of heavy-haul trains[J]. Vehicle System Dynamics, 2010, 48(6): 705-735.

[54] Zhang L J, Zhuan X T. Development of an optimal operation approach in the MPC framework for heavy-haul trains[J]. IEEE Transactions on Intelligent Transportation Systems, 2015, 16(3): 1391-1400.

[55] Wei W, Hu Y, Wu Q, et al. An air brake model for longitudinal train dynamics studies[J]. Vehicle System Dynamics, 2017, 55(4): 517-533.

[56] Wu Q, Luo S H, Cole C. Longitudinal dynamics and energy analysis for heavy haul trains[J]. Journal of Modern Transportation, 2014, 22(3): 127-136.

[57] Gao G J, Chen W, Zhang J, et al. Analysis of longitudinal forces of coupler devices in emergency braking process for heavy haul trains[J]. Journal of Central South University, 2017, 24: 2449-2457.

[58] Gao K, Huang Z W, Wang J, et al. Decentralized control of heavy-haul trains with input constraints and communication delays[J]. Control Engineering Practice, 2013, 21: 420-427.

[59] 孙俊勇. 基于车钩力约束的重载列车自动驾驶技术研究[A]. 中国铁路总公司机辆部、中国铁道学会. 2018 年中国重载铁路技术交流会论文集（上册）[C]. 中国铁路总公司机辆部、中国铁道学会: 中国铁道学会, 2018: 13.

[60] 赵巧妮. 基于模糊自适应 PID 控制的重载列车操纵优化研究[J]. 机车电传动, 2017(03): 72-76.

[61] 陆小红，郑木火，林宏泉. 重载列车智能化操控算法研究与实现[J]. 铁道学报，2017, 39(01): 11-18.

[62] Yu H Z, Huang Y N, Wang M Z. Research on operating strategy based on particle swarm optimization for heavy haul train on long down-slope[C]. IEEE 21st International Conference on

中国知网 https://www.cnki.net

Intelligent Transportation Systems(ITSC), 2018: 2735-2740.
[63] Huang Y N, Bai S, Meng X H, et al. Research on the driving strategy of heavy-haul train based on improved genetic algorithm[J]. Advances in Mechanical Engineering, 2018, 10(8): 1-16.
[64] 付雅婷, 原俊荣, 李中奇, 等. 基于钩缓约束的重载列车驾驶过程优化[J]. 自动化学报, 2019, 45(12): 2355-2365.
[65] 王新培. 基于多目标的重载列车优化操纵研究[D]. 西南交通大学，2016.
[66] 李玉生, 侯忠生. 基于遗传算法的列车节能控制研究[D]. 北京交通大学, 2006.
[67] Wang X, Tang T, He H. Optimal control of heavy haul train based on approximate dynamic programming[J]. Advances in Mechanical Engineering, 2017, 9(4): 1-15.
[68] Wang X, Tang T. Optimal control of heavy haul train on steep downward slope[C]. IEEE 19th International Conference on Intelligent Transportation Systems(ITSC), 2016: 778-783.
[69] Huang Y N, Tan L T, Chen L, et al. A neural network driving curve generation method for the heavy-haul train[J]. Advances in Mechanical Engineering, 2016, 8(5): 1-14.
[70] Bai Y, Mao B H, Tinkin H, et al. Station stopping of freight trains with pneumatic braking[J]. Mathematical Problems in Engineering, 2014: 1-7.
[71] Zhang J Y, Li K C. Optimization method of speed protection algorithm for heavy haul train[C]. IEEE Chinese Automation Congress(CAC), 2017: 7063-7068.
[72] Wang X, Li S K, Tang T, et al. Intelligent operation of heavy haul train with data imbalance: A machine learning method[J]. Knowledge-Based Systems, 2019, 163: 36-50.
[73] Tang H Y, Wang Y, Liu X, et al. Reinforcement learning approach for optimal control of multiple electric locomotives in a heavy-haul freight train: A Double-Switch-Q-network architecture[J]. Knowledge-Based Systems, 2020, 190.
[74] 申燕飞, 张瑞国, 秦勇. 基于红外光传感器的铁路货车闸瓦磨耗监测方法研究[J]. 内燃机与配件, 2019(10): 201-202.
[75] 黄丽珍. 货运机车牵引能耗影响因素分析[D]. 中国铁道科学研究院, 2014.
[76] 周光海. SS4B 型电力机车(1)-特点及技术参数[J]. 机车电传动, 1995, 03: 12-14.
[77] 段振枢. 操纵方式对重载列车纵向冲动的影响研究[D]. 兰州交通大学，2019.
[78] 丁莉芬. 重载列车纵向动力学建模研究[D]. 北京交通大学，2012.
[79] 1998 T. 列车牵引计算规程[S]. 1998
[80] 刘海娜. 基于人工蜂群算法的推荐速度曲线节能优化[D]. 北京交通大学, 2019.
[81] Karaboga D. An idea based on honey bee swarm for numerical optimization[J]. Technical Report TR06, Erciyes University, Engineering Faulty, Computer Engineering Department, 2005.
[82] 何宣虎. 基于人工蜂群算法的最优潮流相关技术研究[D]. 北京交通大学，2016.
[83] Karaboga D, Akay B. A modified artificial bee colony algorithm for constrained optimization problems[J]. Applied Soft Computing, 2011(11): 3021-3031.
[84] 李瑶. 基于人工蜂群算法的城轨列车运行节能优化研究[D]. 兰州交通大学, 2020.
[85] 方春林，刘晓娟，辛营营，等. 基于人工蜂群算法的轨道交通列车行车间隔优化[J]. 计算机应用，2018, 38(9): 2725-2729, 2752.
[86] 卢艺, 卢苑, 梁俊文, 等. 含抽水蓄能电网安全约束机组组合问题的混合整数线性规划算法[J]. 电力系统保护与控制, 2019, 47(03): 39-47.
[87] 李大东, 孙秀霞, 孙彪, 等.基于混合整数线性规划的无人机任务规划[J]. 飞行力学, 2010, 28(05): 88-91.

中国知网 https://www.cnki.net

[88] 岳荣刚, 王少萍. 基于混合整数线性规划的爬壁机器人路径规划[J]. 北京航空航天大学学报, 2013, 39(06): 792-797.

[89] Kang L J, Zhu X N, Sun H J, et al. Last train timetabling optimization and bus bridging service management in urban railway transit networks[J]. Omega-International Journal of Management Science, 2019, 84: 31-44.

[90] Wang Y H, Tang T, Ning B, et al. Integrated optimization of regular train schedule and train circulation plan for urban rail transit lines[J]. Transportation Research Part E, 2017, 105: 83-104.

[91] Luan X J, Wang Y H, De Schutter B, et al. Integration of real-time traffic management and train control for rail networks - Part 1: Optimization problems and solution approaches[J]. Transportation Research Part B, 2018, 115: 41-71.

[92] Lai Q Y, Liu J, Haghani A. Energy-efficient speed profile optimization for medium-speed maglev trains[J]. Transportation Research Part E, 2020, 141, DOI: 10.1016/j.tre.2020.102007.

[93] Williams H P. Model building in mathematical programming[M]. 4th ed. John Wiley & Sons, Chichester England, 1999.

[94] 孙岚. CPLEX 在优化调度中的应用[J]. 福建电脑, 2005, 11: 38-40.

[95] Franke R, Terwiesch P, Meyer M. An algorithm for the optimal control of the driving of trains[C]. Proceedings of the 39th IEEE conference on decision and control. Sydney, Australia, 2003: 2123-2128.

[96] Sutton R S, Barto A G. Reinforcement Learning: An Introduction [M]. Cambridge, MA, USA: MIT Press, 1998.

[97] 龙丹丽. 大规模电力系统机组组合问题的近似动态规划模型与算法[D]. 广西大学, 2014.

[98] Fang J, Zhao L, Fransoo J C, et al. Sourcing strategies in supply risk management: An approximate dynamic programming approach[J]. Computers & Operations Research, 2013, 40(5): 1371-1382.

[99] Powell W B. Approximate Dynamic Programming: Solving the curses of dimensionality[M]. John Wiley & Sons, 2007.

[100] Powell W B. Perspectives of approximate dynamic programming[J]. Annals of Operations Research. DOI: 10.1007/s10479-012-1077-6.

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作和取得的研究成果，除了文中特别加以标注和致谢之处外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京交通大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

学位论文作者签名：黄宇澄　　签字日期：2021 年 5 月 31 日

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net

学位论文数据集

表 1.1： 数据集页

关键词*	密级*	中图分类号	UDC	论文资助
学位授予单位名称*		学位授予单位代码*	学位类别*	学位级别*
北京交通大学		10004		
论文题名*		并列题名		论文语种*
作者姓名*			学号*	
培养单位名称*		培养单位代码*	培养单位地址	邮编
北京交通大学		10004	北京市海淀区西直门外上园村 3 号	100044
学科专业*		研究方向*	学制*	学位授予年*
论文提交日期*				
导师姓名*			职称*	
评阅人	答辩委员会主席*		答辩委员会成员	
电子版论文提交格式 文本（ ） 图像（ ） 视频（ ） 音频（ ） 多媒体（ ） 其他（ ） 推荐格式：application/msword；application/pdf				
电子版论文出版（发布）者		电子版论文出版（发布）地		权限声明
论文总页数*				
共 33 项，其中带*为必填数据，为 21 项。				

中国知网 https://www.cnki.net